



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD DE INGENIERÍA

**PROGRAMA ACADÉMICO DE INGENIERÍA DE SISTEMAS DE
INFORMACIÓN**

**Plataforma web basada en Machine Learning híbrido para la detección
de la ansiedad digital en estudiantes universitarios de Lima
Metropolitana**

Para optar el grado de bachiller en Ingeniería de Sistemas de Información

AUTOR(ES)

Núñez Alvarez, Sebastian Andre (0009-0001-1448-2552)

Salazar Gutiérrez, Darwin Karl (0009-0004-8184-2273)

ASESOR(ES)

Santisteban Pazos, José Luis (0000-0003-4526-642X)

Lima, 5 de julio de 2026

Dedicatoria

A Dios, por darnos la fortaleza y la claridad necesarias para culminar esta etapa. A nuestras familias, por su apoyo incondicional, su paciencia y su aliento constante a lo largo de este camino. A todas las personas que, de alguna u otra manera, creyeron en nuestras capacidades y nos motivaron a seguir adelante en la búsqueda de soluciones que aporten al bienestar de la comunidad universitaria.

Agradecimientos

Agradecemos a la Universidad Peruana de Ciencias Aplicadas por brindarnos la formación académica y los recursos necesarios para el desarrollo de esta investigación. A nuestro asesor, José Luis Santisteban Pazos, por su orientación, disponibilidad y valiosos aportes durante todo el proceso. Asimismo, agradecemos a los docentes y compañeros que compartieron sus conocimientos y experiencias, y a nuestras familias, por su apoyo constante y comprensión durante esta etapa.

Resumen

La creciente demanda académica, social y económica que enfrentan los estudiantes universitarios ha derivado en un incremento sostenido de trastornos emocionales asociados al uso intensivo de tecnologías digitales, entre ellos la ansiedad digital. A pesar de su impacto negativo en el rendimiento académico y el bienestar psicológico, más del 80 % de los estudiantes afectados no recibe tratamiento oportuno debido a barreras logísticas, económicas y al estigma social vinculado a la búsqueda de apoyo psicológico presencial. Frente a esta problemática, la presente investigación tiene como objetivo implementar una plataforma web basada en Machine Learning híbrido que permita detectar la ansiedad digital en estudiantes universitarios de Lima Metropolitana. Para ello, se analizaron los factores técnicos, psicológicos y contextuales asociados a este fenómeno, se diseñó una arquitectura que integra módulos de Procesamiento de Lenguaje Natural y computación afectiva, y se definió un motor de inferencia híbrido que combina reglas de conocimiento experto con el algoritmo Random Forest, seleccionado mediante un proceso de benchmarking tecnológico. El desarrollo se sustenta en una revisión sistemática de la literatura científica, que permitió identificar vacíos metodológicos en las soluciones existentes, principalmente su carácter reactivo y la ausencia de mecanismos predictivos automatizados. Los resultados de este trabajo sientan las bases teóricas y de diseño para una solución tecnológica escalable, culturalmente adaptada y éticamente responsable, orientada a fortalecer la detección temprana y la autoeficacia académica de los estudiantes, contribuyendo así a mejorar los procesos de intervención en salud mental dentro del entorno universitario.

Palabras clave: ansiedad digital; Machine Learning híbrido; procesamiento de lenguaje natural; plataforma web; estudiantes universitarios.

Abstract

Las crecientes exigencias académicas, sociales y económicas a las que se enfrentan los estudiantes universitarios han provocado un aumento constante de los trastornos emocionales asociados al uso intensivo de la tecnología digital, incluida la ansiedad digital. A pesar de su impacto negativo en el rendimiento académico y el bienestar psicológico, más del 80 % de los estudiantes afectados no reciben tratamiento oportuno debido a barreras logísticas y económicas, así como al estigma social que rodea al apoyo psicológico presencial. En respuesta a este problema, esta investigación tiene como objetivo implementar una plataforma web basada en aprendizaje automático híbrido capaz de detectar la ansiedad digital entre los estudiantes universitarios de la zona metropolitana de Lima. Para ello, se analizaron los factores técnicos, psicológicos y contextuales asociados a este fenómeno, se diseñó una arquitectura que integra módulos de procesamiento del lenguaje natural y computación afectiva, y se definió un motor de inferencia híbrido que combina reglas basadas en el conocimiento de expertos con el algoritmo Random Forest, seleccionado mediante un proceso de evaluación comparativa de tecnologías. El desarrollo se basa en una revisión sistemática de la literatura, que identificó brechas metodológicas en las soluciones existentes, principalmente su naturaleza reactiva y la ausencia de mecanismos predictivos automatizados. Los resultados de este trabajo sientan las bases teóricas y de diseño para una solución tecnológica escalable, adaptada cultural y éticamente responsable, cuyo objetivo es fortalecer la detección temprana y la autoeficacia académica entre los estudiantes, contribuyendo así a mejorar los procesos de intervención en materia de salud mental en el entorno universitario.

Palabras clave: ansiedad digital; Machine Learning híbrido; procesamiento de lenguaje natural; plataforma web; estudiantes universitarios.

Student Outcomes

ABET – EAC – Student Outcome 5: Trabaja efectivamente en un equipo cuyos miembros juntos proporcionan liderazgo; crea un entorno colaborativo e inclusivo y establece metas, planifica tareas y cumple objetivos.

El desarrollo del proyecto estuvo a cargo de un equipo de dos integrantes que asumieron roles de liderazgo complementarios: Nuñez Alvarez, Sebastian Andre como Project Manager y Salazar Gutiérrez, Darwin Karl como Scrum Master. Esta distribución permitió que el liderazgo del equipo no recayera en una sola persona, sino que ambos integrantes condujeran de manera conjunta la planificación, seguimiento y toma de decisiones a lo largo de las distintas fases del proyecto.

El equipo adoptó la metodología ágil Scrum como marco de trabajo colaborativo, definiendo de manera conjunta el Product Backlog organizado en épicas e historias de usuario. La construcción participativa de este backlog, así como las ceremonias de planificación de sprints, propició un entorno inclusivo en el que ambos integrantes aportaron criterios técnicos y de negocio para la toma de decisiones del proyecto.

El cumplimiento de metas y objetivos se evidencia en la gestión del cronograma del proyecto, donde se establecieron hitos, líneas base y sprints por fase, permitiendo planificar tareas específicas para cada integrante y realizar seguimiento constante del avance hasta el cumplimiento de los objetivos definidos en cada etapa.

ABET – CAC – Student Outcome 5: La capacidad de funcionar efectivamente como miembro o líder en un equipo cuyos miembros juntos proporcionan liderazgo, crean un entorno de colaboración e inclusivo, establecen objetivos, planifican tareas y cumplen objetivos.

A lo largo del proyecto, ambos integrantes alternaron funciones de miembro y de líder según la naturaleza de cada tarea. Como Project Manager, Nuñez Alvarez, Sebastian Andre lideró la planificación del alcance, cronograma y costos, mientras que, como Scrum Master, Salazar Gutiérrez, Darwin Karl condujo las ceremonias ágiles y veló por el cumplimiento del marco Scrum, evidenciando la capacidad de ambos de desempeñarse tanto como miembros como líderes del equipo.

El establecimiento de objetivos comunes se realizó mediante la definición conjunta de las épicas del producto, que abarcan desde la evaluación psicométrica hasta la continuidad operativa de la plataforma, garantizando que las metas del proyecto respondieran a una visión compartida y no a decisiones unilaterales.

La planificación y el cumplimiento de tareas se sustentó en criterios de aceptación y en la Definition of Done (DoD) global del proyecto, la cual exige que toda historia de usuario sea revisada y aprobada mediante Pull Request por al menos un integrante del equipo, asegurando la validación cruzada del trabajo y el cumplimiento efectivo de los objetivos planteados.

ICACIT – Student Outcome D: La capacidad de desenvolverse eficazmente como individuo, como miembro o líder de equipos diversos.

Cada integrante asumió responsabilidades individuales acordes a su rol y fortalezas técnicas: mientras uno lideró la gestión del proyecto y el análisis del problema, el otro condujo la definición ágil del producto y los aspectos de arquitectura y desarrollo del modelo de Machine Learning híbrido, evidenciando un desempeño individual sólido dentro de un objetivo común.

El equipo interactuó con actores diversos más allá de sus propios integrantes, entre ellos el asesor del proyecto, José Luis Santisteban Pazos, y los perfiles de usuario considerados en las historias de usuario lo que exigió adaptar la comunicación y las decisiones técnicas a las necesidades de un entorno de trabajo heterogéneo.

El desempeño individual y colectivo fue monitoreado mediante la matriz de calidad y la matriz de riesgos del proyecto, instrumentos que permitieron evaluar tanto el aporte de cada integrante como el desenvolvimiento conjunto del equipo, demostrando la capacidad de operar eficazmente tanto de manera individual como en un equipo diverso.

Tabla de contenido

1. Definición del Problema.....	1
1.1 Antecedentes.....	1
1.2 Problema de Investigación.....	7
1.2.1 Descripción e Importancia del Problema.....	7
1.2.2 Análisis del Problema.....	13
1.2.3 Caso de Estudio	16
1.2.4 Formulación del Problema.....	19
1.3 Objetivos.....	20
1.3.1 Objetivo General.....	20
1.3.2 Objetivos Específicos	20
1.4 Propuesta de Investigación	21
1.4.1 Diseño de Solución.....	21
1.4.2 Arquitectura Lógica.....	24
1.4.3 Arquitectura Física	26
1.4.4 Arquitectura Integrada.....	28
1.5 Gestión del Proyecto.....	30
1.5.1 ALCANCE	30
1.5.2 CRONOGRAMA	40
1.5.3 COSTOS.....	42
1.5.4 CALIDAD	45
1.6 BENCHMARKING	48
2. Marco Teórico	56
2.1 Definiciones.....	56
2.1.1 Inteligencia Artificial (IA).....	56
2.1.2 IA Generativa (GenAI).....	57

2.1.3 Procesamiento de Lenguaje Natural (PLN).....	57
2.1.4 Machine Learning.....	57
2.1.5 Machine Learning Híbrido	58
2.1.6 Técnica de Voting (Votación)	58
2.1.7 Computación Afectiva.....	60
2.1.8 Ansiedad Digital y Tecnoestrés.....	60
2.1.9 Autoeficacia Académica.....	61
2.2 Estándares, buenas prácticas y frameworks	61
2.2.1 Metodologías Ágiles (Scrum).....	61
2.2.2 Framework de Terapia Cognitivo-Conductual Digital (iCBT)	63
2.2.3 Modelo de Aceptación Tecnológica (TAM)	63
2.2.4 Arquitecturas en la Nube (Serverless/AWS/Firebase)	64
2.3 Cumplimiento normativo.....	64
2.3.1 Ley N° 29733 - Ley de Protección de Datos Personales (Perú).....	64
2.3.2 Ley N° 30096 - Ley de Delitos Informáticos	65
2.3.3 Ley N° 31814 - Ley que promueve el uso de la Inteligencia Artificial en el Perú	65
2.3.4 Estándares Éticos de la Organización Mundial de la Salud (OMS) para la IA en Salud	66
3. Estado del Arte	67
3.1 Introducción.....	67
3.2 Metodología de Búsqueda	69
3.2.1 Fases o Etapas de la Búsqueda	69
3.2.2 Fase: Planificación de la Revisión.....	70
3.2.3 Fase: Conducción de la Revisión.....	72
3.2.4 Fase: Documentación de la Revisión.....	73
3.3 Análisis de Resultados.....	80

3.3.1 Matriz de Artículos Seleccionados	80
3.3.2 Resumen de Artículos Seleccionados.....	90
3.3.3 Discusión	115
3.3.4 Conclusiones.....	124
Conclusiones.....	128
Referencias Bibliográficas.....	130

Lista de Tablas

Tabla 1 <i>Evidencia estadística de predictores de salud mental en universitarios peruanos</i> ..	9
Tabla 2 <i>Brecha tecnológica y metodológica en la gestión de la ansiedad digital</i>	11
Tabla 3 <i>Brecha tecnológica y metodológica en la gestión de la ansiedad digital</i>	30
Tabla 4 <i>Lista de Hitos del Proyecto</i>	40
Tabla 5 <i>Linea Base Global de Cronograma</i>	41
Tabla 6 <i>Desarrollo de Cronograma – Sprints por Fase</i>	41
Tabla 7 <i>Costos de Personal</i>	43
Tabla 8 <i>Costos de Gastos Generales</i>	43
Tabla 9 <i>Costos de Bienes y Subcontrata</i>	44
Tabla 10 <i>Resumen de Costos</i>	44
Tabla 11 <i>Matriz de Calidad del Proyecto</i>	46
Tabla 12 <i>Matriz de Riesgos del Proyecto</i>	47
Tabla 13 <i>Selección Final — Framework de Backend</i>	49
Tabla 14 <i>Selección Final — Framework de Frontend</i>	50
Tabla 15 <i>Selección Final — Base de Datos</i>	51
Tabla 16 <i>Selección Final — Lenguaje de Programación</i>	52
Tabla 17 <i>Selección Final — Algoritmo de Machine Learning</i>	53
Tabla 18 <i>Selección Final — Métrica de Evaluación ML</i>	54
Tabla 19 <i>Selección Final — Infraestructura Cloud</i>	55
Tabla 20 <i>Comparativa de características entre Agile, Scrum y Kanban</i>	62
Tabla 21 <i>Preguntas de investigación</i>	70
Tabla 22 <i>Palabras claves</i>	70
Tabla 23 <i>Criterios de selección</i>	71
Tabla 24 <i>Criterios de exclusión</i>	71

Tabla 25 <i>Artículos potencialmente elegibles y seleccionados</i>	73
Tabla 26 <i>Relación de los artículos analizados por categoría</i>	80
Tabla 27 <i>Resumen: Pregunta 1</i>	92
Tabla 28 <i>Resumen: Pregunta 2</i>	97
Tabla 29 <i>Resumen: Pregunta 3</i>	101
Tabla 30 <i>Resumen: Pregunta 4</i>	107
Tabla 31 <i>Resumen: Pregunta 5</i>	113

Lista de Figuras

Figura 1 <i>Diagrama de Ishikawa</i>	13
Figura 2 <i>Diseño de solución de la plataforma web</i>	23
Figura 3 <i>Arquitectura lógica de la plataforma web</i>	25
Figura 4 <i>Arquitectura física de la plataforma web</i>	27
Figura 5 <i>Arquitectura física de la plataforma web</i>	29
Figura 6 <i>Panorama general del PLN en el ámbito de la IA</i>	59
Figura 7 <i>Etapas de una búsqueda</i>	69
Figura 8 <i>Proceso de revisión de la literatura</i>	72
Figura 9 <i>Número de artículos por banco de datos</i>	74
Figura 10 <i>Número de artículos clasificados año</i>	75
Figura 11 <i>Número de artículos clasificados por país del autor</i>	76
Figura 12 <i>Número de artículos clasificados por cuartil</i>	77
Figura 13 <i>Número de artículos clasificados por tipo</i>	78
Figura 14 <i>Número de artículos clasificados por año y banco de datos</i>	79

1. Definición del Problema

La integración acelerada del Machine Learning y la inteligencia artificial en la educación superior ha transformado las dinámicas de aprendizaje, pero también ha introducido nuevos desafíos para el bienestar emocional del alumnado, destacando fenómenos emergentes como la ansiedad digital. En esta sección se establece la base del problema de investigación, analizando los antecedentes y factores críticos que justifican el desarrollo de una plataforma web orientada a detectar la ansiedad digital en estudiantes de Lima Metropolitana.

1.1 Antecedentes

Antecedentes Internacionales:

De acuerdo con el estudio de Choudhary y Sybol (2026), se analizó el impacto de la inteligencia artificial en la salud mental y el bienestar de los estudiantes universitarios. La investigación empleó un diseño de aprendizaje centrado en el ser humano, enfocándose en cómo la interacción constante con sistemas inteligentes puede modificar el estado psicológico del alumnado. Los autores determinaron que, si bien la IA facilita procesos académicos, también puede actuar como un catalizador de estrés emocional si no se gestiona correctamente. Este trabajo es fundamental para la tesis, ya que proporciona la base teórica sobre los efectos ambivalentes de la tecnología en la psique estudiantil, permitiendo orientar el diseño de la plataforma hacia un modelo de soporte emocional preventivo.

Se investigó el papel de los acompañantes virtuales basados en inteligencia artificial para fomentar la regulación emocional adaptativa en estudiantes con ansiedad social (Isaiah et al., 2026). Mediante un modelo de soporte adaptativo, se evaluó cómo estos agentes virtuales interactúan con usuarios que presentan dificultades de comunicación. Los

hallazgos principales revelaron una mejora significativa en la capacidad de los estudiantes para gestionar sus respuestas emocionales frente a estresores digitales (Isaiah et al., 2026). El aporte técnico de este antecedente reside en la validación de algoritmos de acompañamiento, los cuales pueden ser replicados en la plataforma propuesta para ofrecer respuestas personalizadas según el nivel de ansiedad del usuario.

De acuerdo con la investigación de Puente-Torre et al. (2025), se evaluó el efecto de la tecnología en el manejo de la ansiedad en entornos universitarios mediante un enfoque cuantitativo. El estudio utilizó instrumentos de medición del impacto tecnológico para determinar cómo las herramientas digitales influyen en la estabilidad emocional de los jóvenes. Las conclusiones indicaron que el uso de medios digitales bien estructurados puede reducir los síntomas ansiosos en lugar de incrementarlos. Esta fuente contribuye a la investigación al identificar métricas y procedimientos de recolección de datos que servirán para evaluar la efectividad de la plataforma web en la detección de la ansiedad.

Se exploró cómo las aplicaciones educativas integradas con IA influyen en la creatividad y las emociones de los alumnos universitarios (Lin y Chen, 2024). A través de un análisis de las percepciones y actitudes de docentes y estudiantes, se identificó que la tecno-ansiedad es un factor que limita el aprovechamiento de estas herramientas. Lin y Chen (2024) concluyeron que el diseño de las aplicaciones debe priorizar la facilidad de uso para evitar emociones negativas. El aporte para este trabajo es la necesidad de desarrollar una interfaz intuitiva que minimice la resistencia tecnológica y el estrés operativo.

Se indaga sobre la importancia de la autoeficacia y la curiosidad en la adopción de herramientas de inteligencia artificial por parte de los estudiantes. Mediante una evaluación de factores motivacionales, se determinó que la confianza del usuario en sus propias capacidades tecnológicas es un predictor del uso exitoso y saludable de la IA. Los

resultados sugieren que fomentar la autoeficacia puede disminuir la frustración y la ansiedad digital (Schutte y Li, 2025). Esta investigación aporta a la tesis la justificación para incluir módulos que refuercen la confianza del estudiante al interactuar con la plataforma de detección de ansiedad.

Se analizó el estrés, la ansiedad y la depresión en estudiantes que cursan estudios en línea, relacionándolos con sus estrategias de afrontamiento y hábitos de vida (Jiménez Boraita et al., 2026). El estudio utilizó una metodología descriptiva para establecer cómo el comportamiento académico virtual se vincula con el deterioro de la salud mental. Se concluyó que los alumnos que carecen de hábitos saludables presentan mayores niveles de sintomatología ansiosa en entornos digitales (Jiménez Boraita et al., 2026). Este antecedente permite sustentar la inclusión de consejos de higiene mental y hábitos de estudio dentro de la solución propuesta.

Según el estudio de Cudris-Torres et al. (2026), se examinó la innovación en las intervenciones digitales para la salud mental en el contexto universitario latinoamericano. Los autores realizaron una revisión de los desafíos y avances tecnológicos, destacando la necesidad de adaptar las soluciones digitales a las realidades culturales de la región. Los resultados indicaron que existe una brecha significativa en la implementación de herramientas preventivas eficaces. Este trabajo justifica la creación de la plataforma para el mercado de Lima Metropolitana, cubriendo un vacío en la oferta de soluciones digitales locales.

Se analizó el impacto de la IA y la ansiedad computacional en entornos de aprendizaje virtual (Almaiah et al., 2022). El estudio se centró en medir las percepciones de los universitarios respecto a cómo el miedo a la tecnología influye en su desempeño académico. Se determinó que la ansiedad social y computacional reduce la disposición del

estudiante para adoptar nuevas plataformas digitales (Almaiah et al., 2022). Este antecedente es relevante para comprender las barreras psicológicas que la plataforma propuesta debe superar para ser aceptada por los estudiantes de Lima.

Antecedentes Nacionales:

En el ámbito nacional, según el estudio de Morales-García et al. (2025), se investigó cómo la autoeficacia y la ansiedad hacia la inteligencia artificial influyen en la dependencia tecnológica de los universitarios peruanos. La investigación empleó modelos cuantitativos para demostrar que niveles bajos de confianza tecnológica incrementan el riesgo de dependencia y estrés digital. Los hallazgos confirmaron que la ansiedad hacia el uso de la IA es un fenómeno creciente en el país. Esta fuente provee a la tesis una definición contextualizada de la ansiedad digital y datos estadísticos actuales sobre la población estudiantil local.

Se evaluó el papel del estrés y la autoeficacia como predictores de la ansiedad en estudiantes universitarios de Perú y México (Anicama et al., 2025). A través de un estudio transversal, se concluyó que el estrés académico crónico es el factor que más influye en el desarrollo de estados ansiosos. Los resultados subrayan la importancia de intervenir sobre la autoeficacia para mitigar el impacto del estrés (Anicama et al., 2025). El aporte principal es la validación de la relación entre estrés y ansiedad digital, lo que fundamenta la incorporación de técnicas de gestión del tiempo en la plataforma.

De acuerdo con la investigación de Ampuero-Tello et al. (2022), se analizó la autoeficacia académica como un factor de protección para la salud mental de los estudiantes locales. El estudio utilizó escalas de autoeficacia para demostrar que los alumnos que se sienten capaces académicamente presentan menores niveles de malestar psicológico durante

situaciones de incertidumbre. Se determinó que la confianza personal actúa como un escudo contra la ansiedad. Esta investigación aporta la base para diseñar una plataforma que refuerce los logros académicos del usuario como estrategia para reducir su ansiedad.

Se estudió el uso de medios virtuales como predictores de depresión y agotamiento emocional en alumnos universitarios peruanos (Carranza Esteban et al., 2022). Utilizando un diseño predictivo, los autores establecieron que la satisfacción con los estudios y el uso racional de la tecnología previene el agotamiento mental. Se concluyó que el uso excesivo de entornos virtuales no supervisados incrementa la ansiedad (Carranza Esteban et al., 2022). Este trabajo valida la necesidad de una plataforma de monitoreo que ayude al estudiante a regular su exposición a estresores digitales.

Según el estudio de Tantalean-Terrones et al. (2025), se llevó a cabo la validación psicométrica de la escala Mental Health Continuum en una muestra de universitarios en el Perú. La investigación confirmó que este instrumento es confiable para medir el bienestar mental de forma integral en el contexto nacional. Los resultados ofrecen una herramienta validada para evaluar el estado emocional de los estudiantes. El aporte metodológico reside en el uso de esta escala para realizar el diagnóstico inicial de los usuarios dentro de la plataforma web propuesta.

Se realizó un diagnóstico sobre la salud mental estudiantil frente a los desafíos actuales en el Perú (Estrada-Araoz y Cruz-Laricano, 2025). A través de un análisis descriptivo, se identificó que la adaptación a entornos de incertidumbre digital es una de las principales fuentes de estrés académico. Los autores recomendaron el desarrollo de estrategias preventivas mediadas por tecnología (Estrada-Araoz y Cruz-Laricano, 2025). Este antecedente refuerza la justificación del proyecto al evidenciar que el propio entorno digital es el canal idóneo para combatir la ansiedad de los universitarios nacionales.

Por último, se analizó el impacto de los entornos lúdicos en línea en el rendimiento y la salud mental de los estudiantes peruanos (Suxe-Ramírez et al., 2025). Mediante una revisión sistemática, se determinó que el uso de dinámicas interactivas puede mejorar el estado anímico si se implementan bajo criterios pedagógicos y de salud. Se concluyó que la gamificación es una herramienta útil para la regulación emocional. El aporte de esta investigación es la recomendación de usar elementos de juego en la plataforma para que el proceso de detección de ansiedad sea percibido de forma amigable y no estresante.

1.2 Problema de Investigación

1.2.1 Descripción e Importancia del Problema

De acuerdo con la investigación de Choudhary y Sybol (2026), se ha identificado que la transformación digital acelerada y la integración de la inteligencia artificial han reconfigurado las dinámicas de aprendizaje, introduciendo fenómenos psicopatológicos emergentes en la educación superior. El estudio evaluó el impacto de la IA en la salud mental estudiantil mediante un enfoque cualitativo de diseño centrado en el humano, determinando que dicha tecnología opera de forma ambivalente: mientras optimiza procesos cognitivos, actúa simultáneamente como un estresor que eleva la fatiga mental. Los resultados confirmaron que esta contradicción técnica y psicológica convierte el entorno digital en un espacio de vulnerabilidad donde la carga cognitiva y la dependencia tecnológica exacerban cuadros de ansiedad que los sistemas universitarios convencionales no logran mitigar de manera proactiva. En consecuencia, se concluye que existe una urgencia por desarrollar marcos de soporte que equilibren la eficiencia algorítmica con el bienestar emocional.

Por otra parte, a nivel internacional se observa que la interacción con sistemas inteligentes no solo genera beneficios operativos, sino que induce estados específicos de desajuste emocional como la "tecno-ansiedad". Esta problemática fue analizada mediante una metodología mixta que exploró las percepciones de control de los alumnos sobre los algoritmos educativos, encontrando que la falta de transparencia del sistema correlaciona con emociones académicas negativas (Lin y Chen, 2024). Complementando esta visión, se investigaron mediante modelos cuantitativos cómo una baja autoeficacia en el manejo de estas herramientas actúa como un predictor de frustración y rechazo tecnológico. Los hallazgos principales sugieren que el problema se agrava por la falta de competencias de

autogestión, lo que permite concluir que es imperativo incorporar capas de soporte psicológico adaptativo dentro de las soluciones funcionales para neutralizar estos efectos adversos (Schutte y Li, 2025).

Asimismo, en el ámbito de Latinoamérica, de acuerdo con el diagnóstico de Cudris-Torres et al. (2026), la situación presenta desafíos estructurales adicionales vinculados a la brecha en salud digital y la escasez de herramientas personalizadas para la prevención psicopatológica. A través de una revisión sistemática de las intervenciones regionales, los autores demostraron que las instituciones enfrentan una orfandad tecnológica que deja a los estudiantes sin mecanismos de contención ante el estrés digital. Esta realidad se ve reforzada por el estudio de Jiménez Boraita et al. (2026), quienes emplearon escalas de salud mental para evaluar a estudiantes en línea, determinando que la ausencia de estrategias de afrontamiento y hábitos saludables deteriora profundamente la estabilidad mental. La conclusión compartida es que la región requiere una innovación en salud digital que atienda las particularidades del comportamiento académico virtual latinoamericano.

Específicamente en el contexto peruano, los indicadores de salud mental han mostrado un deterioro vinculado al uso de tecnologías. La Tabla 1 sintetiza la evidencia estadística reciente sobre los predictores de malestar psicológico en universitarios locales:

Tabla 1

Evidencia estadística de predictores de salud mental en universitarios peruanos

Autor(es) y año	Variable Predictora	Hallazgo / Impacto Estadístico	Resultado en Salud Mental
Morales-García et al. (2025a)	Ansiedad hacia la IA	Correlación positiva significativa	Dependencia digital negativa
Carranza Esteban et al. (2022)	Uso desordenado de medios virtuales	Coefficiente predictivo robusto	Agotamiento emocional y depresión
Anicama et al. (2025)	Estrés académico crónico	Principal predictor clínico	Cuadros de ansiedad severa
Ampuero-Tello et al. (2022)	Autoeficacia académica	Factor protector (correlación inversa)	Reducción de malestar psicológico

En relación con el contexto peruano, según la investigación de Morales-García et al. (2025), la realidad problemática en Lima Metropolitana adquiere matices de urgencia sanitaria debido a la alta correlación entre la ansiedad hacia la IA y una dependencia digital negativa. Mediante un análisis multivariado en universidades locales, se confirmó que este fenómeno compromete el bienestar general y el rendimiento académico de los jóvenes. Del mismo modo, de acuerdo con Carranza Esteban et al. (2022), se utilizó una metodología

predictiva de regresión para demostrar que el uso desordenado de medios virtuales en la población peruana es un predictor robusto de agotamiento emocional y depresión. Los resultados subrayan que, a pesar de esta evidencia, los servicios de bienestar universitario en la capital siguen utilizando métodos de detección reactivos y manuales, ignorando el potencial de la inteligencia artificial para una intervención preventiva eficaz.

Del mismo modo, a nivel local, la problemática en las universidades de Lima se sintetiza en la carencia de una arquitectura digital integrada capaz de detectar indicadores tempranos de ansiedad digital. El estudio, fundamentado en un análisis descriptivo de los estresores nacionales, concluyó que la adaptación constante a entornos de incertidumbre tecnológica es la principal fuente de estrés psicológico en el país (Estrada-Araoz y Cruz-Laricano, 2025). No obstante, existe una oportunidad metodológica subutilizada mediante el uso de instrumentos validados; al respecto, Tantalean-Terrones et al. (2025) confirmaron la confiabilidad de la escala MHC-SF para el diagnóstico local, mientras que Suxe-Ramírez et al. (2025) demostraron mediante una revisión sistemática que las estrategias de gamificación reducen la resistencia del usuario. Por lo tanto, el problema central radica en la ausencia de un sistema computacional que fusione la precisión algorítmica con el soporte psicoterapéutico adaptativo para abordar la salud mental del estudiante limeño.

Finalmente, la importancia de resolver esta problemática reside en la brecha existente entre la situación actual de saturación de los centros de ayuda universitaria y la situación deseada de un monitoreo preventivo autónomo. Según Puente-Torre et al. (2025), la implementación de herramientas tecnológicas para el manejo de la ansiedad genera beneficios tangibles en la reducción de síntomas mediante intervenciones estructuradas. Asimismo, de acuerdo con Anicama et al. (2025), el fortalecimiento de la autoeficacia a través de plataformas digitales permite mitigar el estrés académico, validando la necesidad

de invertir en soluciones de este tipo. De igual manera, Isaiah et al. (2026) y Almaiah et al. (2022) coinciden en que el uso de acompañantes virtuales y modelos de aceptación tecnológica es crítico para superar las barreras de ansiedad social y computacional. En suma, la ejecución de este proyecto es vital no solo por su novedad técnica, sino por su impacto social al garantizar una formación universitaria saludable y resiliente frente a los retos de la industria tecnológica global.

La Tabla 2 describe esta disparidad técnica y operativa que justifica la inversión en el presente proyecto:

Tabla 2

Brecha tecnológica y metodológica en la gestión de la ansiedad digital

Dimensión	Situación Actual (Deficiente)	Situación Deseada (Propuesta)
Detección	Reactiva, basada en encuestas manuales episódicas.	Proactiva, mediante algoritmos de monitoreo en tiempo real.
Soporte	Atención humana saturada y fuera de horario académico.	Acompañantes virtuales con soporte adaptativo 24/7.
Metodología	Protocolos intrusivos y estandarizados (fríos).	Marcos gamificados y protocolos no intrusivos (Suxe-Ramírez, 2025).
Precisión	Uso de escalas genéricas no adaptadas al Perú.	Integración de escalas validadas (MHC-SF) (Tantalean, 2025)

Bajo una justificación técnica, el proyecto aporta una novedad significativa al proponer una arquitectura basada en agentes inteligentes para la regulación emocional. Asimismo, según lo validado por Isaiah et al. (2026), la implementación de acompañantes virtuales con soporte adaptativo permite una intervención en tiempo real que los sistemas estáticos no ofrecen. La optimización de estos modelos representa un avance en la ingeniería de software aplicada a la salud mental.

Desde una justificación práctica, esta investigación resuelve la ineficiencia operativa de los centros de ayuda universitaria. Por otra parte, según Puente-Torre et al. (2025), el uso de herramientas tecnológicas estructuradas genera beneficios tangibles al automatizar el monitoreo de la ansiedad, liberando recursos humanos para casos de alta complejidad clínica y mejorando la seguridad de la información del paciente.

En cuanto a la justificación social, el impacto beneficia directamente a la comunidad estudiantil de Lima. De acuerdo con el estudio de Anicama et al. (2025), al mitigar el estrés académico y fortalecer la autoeficacia, se promueve una población joven más resiliente y capaz de enfrentar los retos de la transformación digital en el país.


Finalmente, en la justificación metodológica, se propone un nuevo protocolo de detección no intrusiva. Según el aporte psicométrico de Tantalean-Terrones et al. (2025), la integración de escalas validadas localmente como la MHC-SF asegura la precisión diagnóstica. Además, siguiendo a Suxe-Ramírez et al. (2025), la aplicación de marcos de trabajo gamificados establece un estándar metodológico innovador para recolectar datos psicológicos sin generar resistencia en el usuario.

1.2.2 Análisis del Problema

En virtud del diagnóstico previo, el análisis técnico del problema central, definido como la deficiencia estructural en la detección de la ansiedad digital, se aborda mediante un enfoque sistémico que permite identificar las variables críticas que alimentan este fenómeno en el entorno universitario. Para este propósito, se utiliza la lógica del Diagrama de Ishikawa (Causa-Efecto), la cual facilita la clasificación de las causas en dimensiones tecnológicas, humanas y de proceso, permitiendo una visión holística de las fallas en los sistemas de bienestar actuales. Según lo expuesto por Choudhary y Sybol (2026), el problema no es solo la presencia de la tecnología, sino cómo la integración de la inteligencia artificial sin un diseño centrado en el humano actúa como un estresor que eleva la carga cognitiva, lo que requiere un análisis detallado de los mecanismos que disparan la fatiga mental en el estudiante.

Figura 1

Diagrama de Ishikawa de la deficiencia en la detección y mitigación de la ansiedad digital



Como se observa en el análisis sistémico representado en la Figura 1, la problemática se articula a través de una convergencia de factores que impiden una respuesta eficiente ante el deterioro de la salud mental estudiantil.

En primera instancia, desde la dimensión tecnológica, se identifica una carencia crítica de arquitecturas digitales integradas que permitan el monitoreo de indicadores de comportamiento en tiempo real. La solución actual en las instituciones locales se limita a plataformas reactivas y estáticas que no incorporan algoritmos predictivos ni modelos de soporte adaptativo. De acuerdo con lo analizado, esta infraestructura obsoleta impide capturar la naturaleza volátil del estrés tecnológico, dejando un vacío en la trazabilidad de los datos de conexión y la multitarea académica, factores que son determinantes en el desarrollo de psicopatologías digitales (Estrada-Araoz y Cruz-Laricano, 2025).

Complementariamente, según Lin y Chen (2024), esta falta de transparencia y control sobre los procesos algorítmicos educativos induce estados de tecno-ansiedad, lo que sugiere que la arquitectura técnica actual es insuficiente para gestionar las emociones académicas negativas derivadas del entorno virtual.

Por otra parte, en la dimensión humana, se observa que el sobreuso de dispositivos móviles y la baja autoeficacia digital actúan como causas determinantes de la vulnerabilidad psicológica. Según las investigaciones de Morales-García et al. (2025a) y Santander-Hernández et al. (2022), existe una correlación significativa entre la dependencia al smartphone y la aparición de síntomas de depresión (78 %) y ansiedad (69 %) en universitarios peruanos, lo cual se ve agravado por la ansiedad específica hacia el uso de la IA. Esta fragilidad se ve exacerbada por lo que Cassaretto et al. (2024) definen como una "cultura de hiperconectividad" en Lima, donde la falta de competencias para la autogestión emocional digital incrementa el riesgo de desajuste. Al respecto, Schutte y Li (2025)

sostienen que la baja autoeficacia y la falta de curiosidad tecnológica son predictores de frustración, lo que confirma que el factor humano, sin un refuerzo preventivo, es el eslabón más débil ante la presión de la transformación digital acelerada.

Asimismo, respecto a la dimensión de proceso, se detecta una metodología de intervención fragmentada, episódica y tardía que no responde a las necesidades del estudiante moderno. Actualmente, la identificación del malestar se realiza mediante encuestas ocasionales que no consideran los patrones de uso en tiempo real ni los factores predictivos del agotamiento. Según los hallazgos de Yslado-Méndez et al. (2025), incluso las intervenciones digitales existentes en el país presentan desafíos críticos de usabilidad y carecen de módulos específicos de "desconexión consciente" o higiene digital, lo que reduce drásticamente su eficacia preventiva. En esta misma línea, Tantalean-Terrones et al. (2025) señalan que la falta de uso de instrumentos validados y adaptados culturalmente, como la escala MHC-SF, impide una medición precisa del bienestar mental, lo que genera diagnósticos sesgados que no permiten una intervención oportuna basada en evidencia científica.

Finalmente, la síntesis de estas causas genera consecuencias críticas que impactan tanto en el individuo como en la institución: el deterioro silencioso de la salud mental hasta niveles severos, un incremento sostenido en la deserción académica y una sobrecarga operativa insostenible en los servicios psicológicos universitarios. Al respecto, Carranza Esteban et al. (2022) advierten que el uso desordenado de medios virtuales es un predictor robusto de agotamiento emocional, lo que, sumado a la falta de soluciones inteligentes mencionada por Isaiah et al. (2026), deja al estudiante sin un soporte adaptativo eficaz. Por consiguiente, el análisis técnico demuestra que el problema radica en la ausencia de una solución que fusione la detección inteligente mediante IA con estrategias de soporte

práctico y gamificado, como propone Suxe-Ramírez et al. (2025), para cerrar la brecha entre la situación reactiva actual y un modelo de bienestar digital preventivo y escalable.

1.2.3 Caso de Estudio

1.2.3.1 Datos Generales

Identificación de la Organización: Instituciones de Educación Superior (IES) de gestión pública y privada ubicadas en Lima Metropolitana. Dado el carácter transversal de la problemática evaluada y para salvaguardar la confidencialidad de las entidades de procedencia de los estudiantes, el caso de estudio se analizará bajo la denominación de "Entorno Universitario de Lima Metropolitana".

Rubro o Actividad Económica: Sector de Educación Superior.

Ubicación y Alcance: Operaciones a nivel local y nacional en Perú, con un impacto representativo para el contexto de los países de América Latina (Cudris-Torres et al., 2026).

Misión/Visión Tecnológica: Transformar el ecosistema educativo integrando la inteligencia artificial (IA) para optimizar de forma simultánea el aprendizaje y el bienestar mental, mediante intervenciones digitales escalables como asistentes virtuales y chatbots que ofrezcan apoyo emocional 24/7 sin prejuicios (Choudhary y Sybol, 2026; Isaiah et al., 2026). La meta transversal es promover una adopción tecnológica que refuerce la autoeficacia del estudiante y evite la dependencia perjudicial (Morales-García et al., 2025).

1.2.3.2 Datos Específicos

Área o Departamento Específico: El problema reside directamente en el Departamento de Bienestar Universitario (o Servicio Psicopedagógico), la unidad orgánica encargada de hacer frente a los crecientes retos de salud mental, como la

ansiedad, el estrés y la depresión, entre la comunidad estudiantil (Estrada-Araoz y Cruz-Laricano, 2025).

Descripción del Proceso Crítico: El flujo crítico actual es el proceso de detección, triaje y manejo clínico del estrés y la ansiedad. Actualmente, la atención es mayormente reactiva y padece graves cuellos de botella, por lo que más del 80% de los estudiantes con trastornos emocionales de la Región no logra acceder a un tratamiento oportuno, debido a la escasez de profesionales y a las largas listas de espera (Cudris-Torres et al., 2026). El proceso también se ve interrumpido por el miedo al estigma social, lo que provoca que los jóvenes eviten la búsqueda de ayuda presencial hasta que la crisis emocional deteriora significativamente su concentración y rendimiento académico (Anicama et al., 2025; Isaiah et al., 2026).

Infraestructura Tecnológica Actual:

- **Software:** Se emplean sistemas convencionales de gestión del aprendizaje estáticos que carecen de modelos analíticos o de procesamiento de lenguaje natural predictivo para brindar soporte emocional (Choudhary y Sybol, 2026). Según Almaiah et al. (2022) la poca adaptación del software actual a menudo fomenta la "ansiedad computacional" en los alumnos.
- **Hardware:** Servidores institucionales orientados estrictamente al alojamiento de datos académicos, complementados por los dispositivos finales de los usuarios, que en su mayoría son teléfonos móviles (smartphones) y computadoras portátiles (Suxe-Ramírez et al., 2025).

Actores y Roles:

- **Estudiantes Universitarios (Usuarios finales):** Son la población vulnerable expuesta a las presiones académicas y al tecnoestrés; demandan canales de interacción seguros, anónimos y libres de estigmatización social para poder externalizar su ansiedad y gestionar sus emociones (Anicama et al., 2025; Isaiah et al., 2026).
- **Psicólogos y Consejeros (Administradores/Especialistas):** Personal de Bienestar Universitario que proporciona la intervención clínica humana, pero cuya capacidad de cobertura se encuentra desbordada por la alta demanda (Cudris-Torres et al., 2026).
- **Administradores de TI (Soporte):** Personal encargado de asegurar la operatividad de la red institucional, la gestión de bases de datos y la privacidad de la información estudiantil.

Volumetría de Datos: La implementación de una solución basada en IA es crítica debido a la enorme volumetría del problema. La prevalencia de la ansiedad entre universitarios a nivel global ronda el 41 % (Anicama et al., 2025). Específicamente en el Perú, diversos estudios han registrado que el cansancio emocional severo puede afectar a más del 50.4 % de los universitarios en ciertas regiones (Carranza Esteban et al., 2022). En un consorcio institucional, esto implica el procesamiento continuo y en tiempo real de decenas de miles de interacciones, registros de asistencia, desempeño y estados anímicos mensuales; un volumen de datos que hace indispensable la adopción de arquitecturas escalables de análisis predictivo (Choudhary y Sybol, 2026).

1.2.4 Formulación del Problema

¿De qué manera la implementación de una plataforma web basada en Machine Learning híbrido detectará la ansiedad digital en estudiantes universitarios de Lima Metropolitana?

Anicama et al. (2025) y Estrada-Araoz y Cruz-Laricano (2025) coinciden en que la presente investigación se justifica ante la alarmante crisis de salud mental que viven los estudiantes de educación superior. Las actuales demandas académicas, sociales y económicas constituyen un riesgo permanente para el surgimiento de problemas emocionales, siendo el estrés un predictor importante de los trastornos de ansiedad y el agotamiento en la población universitaria. A pesar de lo grave de esta situación y su impacto negativo en el rendimiento, más del 80 % de los estudiantes con trastornos emocionales en la región no reciben tratamiento adecuado y oportuno, debido a barreras logísticas, económicas y, fundamentalmente, a la estigmatización social que aún existe alrededor de la búsqueda de apoyo psicológico presencial (Cudris-Torres et al., 2026; Isaiah et al., 2026).

Según Choudhary y Sybol (2026), frente a estas severas limitaciones, la integración de la Inteligencia Artificial (IA) y el Machine Learning surge como una alternativa viable, escalable y accesible para la intervención temprana. Los asistentes y plataformas conversacionales basados en IA que se apoyan en enfoques tales como la terapia cognitivo-conductual, pueden ofrecer un espacio privado, anónimo y disponible permanentemente. Varios estudios demuestran que estos “compañeros de IA” disminuyen el miedo al estigma social y permiten un espacio seguro y libre de juicios para que los jóvenes puedan expresar sus emociones, reduciendo la inhibición y fomentando la autorregulación emocional en situaciones que desencadenan sus emociones. (Isaiah et al., 2026). De esta manera, la tecnología puede actuar como un mecanismo de contención primario y oportuno frente a las crisis de ansiedad.

Sin embargo, el diseño y despliegue de esta tecnología debe ser hecho con rigor para evitar efectos adversos probados, tales como la dependencia tecnológica y la "ansiedad de IA" (Morales-García et al., 2025). La literatura advierte que las intervenciones digitales no solo deben estar profundamente adaptadas a la cultura local para asegurar su efectividad (Cudris-Torres et al., 2026), sino que también deben estructurarse para fortalecer la autoeficacia académica (Ampuero-Tello et al., 2022; Carranza Esteban et al., 2022). De acuerdo con Morales-García et al. (2025) es fundamental fomentar la autoeficacia, ya que el estudiante que confía en sus capacidades académicas y cognitivas tiende a gestionar mejor los estresores y utiliza la IA de forma estratégica, en lugar de caer en el uso compulsivo de las herramientas automatizadas. El presente proyecto evaluará, entonces, cómo una plataforma web basada en Machine Learning híbrido puede detectar la ansiedad digital del estudiante.

1.3 Objetivos

1.3.1 Objetivo General

Implementar una plataforma web basada en Machine Learning híbrido que permita detectar la ansiedad digital en estudiantes universitarios de Lima Metropolitana

1.3.2 Objetivos Específicos

OE1: Analizar los factores técnicos, psicológicos y contextuales que condicionan la aparición de ansiedad digital en estudiantes universitarios de Lima Metropolitana para definir las variables del modelo predictivo.

OE2: Diseñar la arquitectura de la plataforma web basada en Machine Learning híbrido, integrando módulos de PLN y computación afectiva para el procesamiento de datos textuales y conductuales en la nube.

OE3: Validar el modelo de Machine Learning híbrido mediante métricas de evaluación clínica y pruebas con datos reales de estudiantes universitarios de Lima Metropolitana, garantizando su precisión y pertinencia diagnóstica.

OE4: Elaborar un plan de continuidad operativa de la plataforma web que asegure la disponibilidad, escalabilidad y sostenibilidad del sistema de detección de ansiedad digital a largo plazo.

1.4 Propuesta de Investigación

1.4.1 Diseño de Solución

La solución propuesta consiste en una plataforma web inteligente orientada a la detección temprana de la ansiedad digital en estudiantes universitarios mediante la integración de cuestionarios psicométricos, reglas de conocimiento experto y técnicas de Machine Learning híbrido. El sistema permitirá automatizar el proceso de evaluación, facilitando la identificación de estudiantes con diferentes niveles de riesgo y proporcionando información útil para apoyar la toma de decisiones de los profesionales de salud mental.

El funcionamiento del software inicia cuando el estudiante accede a la plataforma web mediante un proceso de autenticación. Posteriormente, completa una evaluación conformada por cuestionarios psicométricos validados e indicadores relacionados con el uso de tecnologías digitales. La información recopilada es almacenada en la base de datos y enviada al motor de procesamiento para su análisis.

El núcleo de la solución está compuesto por un motor de inferencia híbrido que combina una base de conocimiento basada en reglas definidas por especialistas en psicología con un algoritmo de Machine Learning, específicamente Random Forest, seleccionado mediante el benchmarking realizado. Este enfoque permite aprovechar tanto el conocimiento experto


como la capacidad predictiva del aprendizaje automático para clasificar el nivel de ansiedad digital del estudiante.

Una vez procesada la información, el sistema genera un resultado que incluye el nivel de ansiedad detectado y un puntaje de riesgo asociado. Además, el software presenta una explicación de los factores que influyeron en la clasificación obtenida, favoreciendo la interpretabilidad del modelo y brindando mayor confianza a los profesionales responsables del seguimiento.

Finalmente, la plataforma ofrece recomendaciones personalizadas orientadas a promover hábitos digitales saludables y reducir los factores de riesgo identificados. Los profesionales de salud mental podrán consultar el historial de evaluaciones, monitorear la evolución de cada estudiante y utilizar la información generada como apoyo para la planificación de intervenciones oportunas. De esta manera, la solución contribuye a mejorar el proceso de detección temprana de la ansiedad digital, reduciendo la dependencia de evaluaciones exclusivamente manuales y proporcionando un mecanismo automatizado, escalable y basado en evidencia para el entorno universitario.

Figura 2

Diseño de solución de la plataforma web



1.4.2 Arquitectura Lógica


La arquitectura lógica de la plataforma se organiza en cinco capas independientes que separan responsabilidades y facilitan la escalabilidad del sistema, tal como se ilustra en la Fig. 3. En la capa de usuarios interactúan tres roles: el estudiante universitario, que completa las evaluaciones psicométricas; el psicólogo u orientador, que supervisa los resultados; y el administrador, que gestiona la plataforma. Estos usuarios acceden mediante la capa de presentación, desarrollada en Angular, seleccionada tras el proceso de benchmarking por su arquitectura tipada (TypeScript), su integración nativa con servicios REST mediante RxJS/HttpClient, y su capa de seguridad frente a vulnerabilidades como Cross-Site Scripting (XSS).

Las solicitudes del cliente son procesadas por la capa de aplicación, cuyo núcleo es Spring Boot, framework elegido por su soporte nativo de microservicios y su robusto ecosistema de seguridad. Dentro de esta capa se aloja también el servicio de Machine Learning, desarrollado en Python, que ejecuta el algoritmo Random Forest previamente validado en el benchmarking por su balance entre precisión estadística y explicabilidad clínica. Los resultados y la información recolectada se persisten en la capa de datos, sustentada en PostgreSQL, motor seleccionado por su cumplimiento estricto de las propiedades ACID y su soporte híbrido para estructuras JSONB, necesario para almacenar tanto datos relacionales como las salidas no estructuradas del modelo predictivo.

Finalmente, toda la plataforma se despliega sobre infraestructura cloud de AWS, aprovechando servicios gestionados (EC2, RDS, S3, IAM y CloudWatch) que garantizan disponibilidad y cumplimiento normativo. Esta organización por capas permite que cada componente evolucione de forma independiente y sienta las bases para las arquitecturas física e integrada descritas a continuación.

Figura 3

Arquitectura lógica de la plataforma web




1.4.3 Arquitectura Física

La arquitectura física detalla dónde y cómo se despliegan los componentes lógicos sobre recursos concretos de cómputo y red, como se muestra en la Fig. 4. El sistema se ejecuta íntegramente en la nube (AWS), dentro de una VPC de producción organizada en tres subredes que segmentan el tráfico según su nivel de exposición. La subred pública aloja el Load Balancer (ALB), único punto de entrada desde Internet, y el NAT Gateway, que permite la salida de tráfico desde las subredes privadas sin exponerlas externamente. La subred privada de aplicación contiene dos instancias EC2: una que ejecuta la API REST en Spring Boot (dimensionada como t3.medium, 2 vCPU y 4 GB de RAM) y otra que aloja el servicio de Machine Learning en Python (t3.large, 2 vCPU y 8 GB de RAM, dado el mayor consumo de memoria del modelo). La subred privada de datos aloja la instancia de Amazon RDS con PostgreSQL 15 (db.t3.medium, 100 GB de almacenamiento SSD con respaldos automáticos), inaccesible directamente desde Internet.

La seguridad perimetral se sustenta en un esquema de mínimo privilegio: los Security Groups solo permiten que el ALB reciba tráfico externo por el puerto 443 (HTTPS), mientras que las instancias EC2 y la base de datos únicamente aceptan conexiones internas provenientes de la capa inmediatamente anterior. Los roles y permisos de cada servicio se gestionan mediante IAM, evitando credenciales embebidas en el código. Por último, el entrenamiento del modelo Random Forest se realiza de forma offline, fuera del entorno de producción, y el artefacto entrenado se despliega posteriormente en la instancia del servicio de Machine Learning. Esta separación entre entrenamiento y ejecución en producción reduce el riesgo operativo y permite actualizar el modelo sin afectar la disponibilidad de la plataforma.

Figura 4

Arquitectura física de la plataforma web



1.4.4 Arquitectura Integrada


La arquitectura integrada ofrece la visión holística del sistema, mostrando cómo la plataforma propuesta se comunica con el ecosistema institucional existente, tal como se representa en la Fig. 5. La interoperabilidad se resuelve mediante tres mecanismos complementarios. Para operaciones que requieren respuesta inmediata se emplean APIs REST síncronas: la validación de identidad se delega a Auth0, actuando como proveedor de inicio de sesión único (SSO) institucional, mientras que el estado de matrícula del estudiante se verifica contra el sistema académico legado de la universidad. Para el procesamiento del modelo predictivo se utiliza una cola de mensajería (RabbitMQ), que desacopla la API del servicio de Machine Learning: la API publica un evento cuando el estudiante completa una evaluación, y el servicio de ML lo consume de forma asíncrona, evitando que la latencia del modelo afecte la experiencia del usuario. Finalmente, para notificar eventos hacia afuera de la plataforma se emplean webhooks salientes, que alertan al servicio de notificaciones (correo o SMS) cuando el estudiante recibe retroalimentación, y al sistema de Bienestar Universitario cuando el modelo detecta un nivel de riesgo elevado que amerita intervención humana.

El flujo de datos completo puede resumirse así: el estudiante interactúa con la aplicación Angular, cuya solicitud llega vía Internet a la API de Spring Boot; esta valida la sesión con Auth0 y, de ser necesario, la matrícula con el sistema académico; persiste la respuesta en PostgreSQL y publica un evento en RabbitMQ; el servicio de Machine Learning consume dicho evento, ejecuta el modelo Random Forest y retorna el resultado; y, según el nivel de riesgo detectado, la API dispara los webhooks correspondientes hacia el estudiante y/o hacia Bienestar Universitario. Cabe precisar que el sistema no contempla pasarelas de pago, dado que no involucra transacciones económicas. Esta arquitectura evidencia que es posible integrar monitoreo, detección automatizada y soporte emocional dentro del

ecosistema universitario existente sin comprometer la experiencia ni la autonomía del estudiante.

Figura 5

Arquitectura física de la plataforma web



1.5 Gestión del Proyecto

1.5.1 ALCANCE

La gestión de los requerimientos del proyecto se realiza mediante la metodología Scrum, utilizando el Product Backlog como artefacto central de planificación y control. Este artefacto recoge la totalidad de las funcionalidades, mejoras y restricciones técnicas que el sistema debe implementar, ordenadas por prioridad y distribuidas en sprints según su complejidad y dependencia. El detalle completo del Product Backlog se encuentra en el Anexo 1.

Product Backlog

El Product Backlog de la plataforma web está organizado en 7 épicas que agrupan las 20 Historias de Usuario del proyecto. Cada épica representa un dominio funcional o técnico independiente que contribuye al objetivo general del sistema.

Tabla 3

Brecha tecnológica y metodológica en la gestión de la ansiedad digital

Épica	Descripción	User Stories	Sprint(s)	OE asociado
É1 — Autenticación y Onboarding	Gestión del acceso seguro, registro con correo institucional y obtención del consentimiento informado del estudiante	US-01, US-02, US-03	Sprint 4	OE1
É2 — Evaluación Psicométrica	Implementación del cuestionario con escalas TS4US/ASAIDAS, captura de indicadores conductuales y tecnológicos, y persistencia del progreso	US-04, US-05, US-06	Sprint 5	OE1, OE2
É3 — Módulo de PLN	Procesamiento del texto libre del estudiante mediante análisis de sentimientos,	US-07, US-08, US-09	Sprint 6	OE2

	vectorización y preprocesamiento lingüístico adaptado al contexto universitario limeño			
É4 — Motor ML Híbrido	Fusión multimodal de datos, clasificación Random Forest en tres niveles (Bajo, Moderado, Alto), capa de reglas clínicas expertas y generación del reporte de Feature Importance	US-10, US-11, US-12, US-13	Sprint 7	OE2, OE3
É5 — Dashboard y Retroalimentación	Informe personalizado al estudiante, dashboard de Bienestar Universitario con filtros por cohorte y exportación de reportes institucionales	US-14, US-15, US-16	Sprint 9	OE3
É6 — Seguridad y Privacidad	Cifrado de datos en reposo y tránsito (AWS), cumplimiento de la Ley N° 29733 y ejercicio de derechos ARCO por parte del usuario	US-17, US-18	Sprints 5, 8	OE2, OE3
É7 — Continuidad y MLOps	Pipeline automatizado de reentrenamiento del modelo y documento del Plan de Continuidad Operativa	US-19, US-20	Sprint 11	OE4

Historias de Usuario

El alcance del proyecto se define a través de las necesidades concretas de los tres perfiles de usuario identificados: el estudiante universitario (usuario final del sistema de detección), el Área de Bienestar Universitario (usuaria del dashboard institucional) y el equipo de desarrollo (responsable de la sostenibilidad técnica). A continuación se presentan las Historias de Usuario representativas de cada épica:

Épica 1 — Autenticación y Onboarding

- *"Como estudiante universitario, quiero registrarme en la plataforma con mi correo institucional y completar un perfil inicial, para que el sistema pueda personalizar mi evaluación de ansiedad digital según mi contexto académico." (US-01)*
- *"Como estudiante universitario, quiero iniciar sesión de forma anónima y segura con autenticación JWT, para proteger mi privacidad y sentirme seguro al compartir datos psicológicos sensibles." (US-02)*
- *"Como estudiante universitario, quiero ver una pantalla de bienvenida con la explicación del propósito de la plataforma y la política de privacidad, para dar mi consentimiento informado antes de comenzar cualquier evaluación." (US-03)*

Épica 2 — Evaluación Psicométrica

- *"Como estudiante universitario, quiero completar un cuestionario psicométrico validado (escala TS4US / ASADAS) sobre mis hábitos digitales, para que el motor de ML pueda recopilar las variables necesarias para clasificar mi nivel de ansiedad digital." (US-04)*
- *"Como estudiante universitario, quiero responder preguntas sobre el tiempo de uso de mis dispositivos, redes sociales y carga académica virtual, para que el sistema capture indicadores conductuales y tecnológicos como variables de entrada del modelo predictivo." (US-05)*
- *"Como estudiante universitario, quiero guardar mi progreso y retomar el cuestionario si salgo de la plataforma sin completarlo, para no perder mis respuestas y completar la evaluación en varios momentos según mi disponibilidad." (US-06)*

Épica 3 — Módulo de PLN

- *"Como estudiante universitario, quiero escribir libremente cómo me siento respecto al uso de tecnología en mis estudios en un campo de texto abierto, para que el módulo de PLN identifique indicadores emocionales como desesperanza o agotamiento en mi discurso." (US-07)*
- *"Como sistema (PLN), quiero preprocesar y vectorizar el texto ingresado por el estudiante usando técnicas de análisis de sentimientos, para transformar el texto no estructurado en representaciones numéricas que el modelo Random Forest pueda procesar." (US-08)*
- *"Como sistema (PLN), quiero detectar automáticamente el idioma del texto ingresado y aplicar el preprocesamiento lingüístico correspondiente al argot universitario limeño, para garantizar la precisión del análisis semántico en el contexto sociocultural de Lima Metropolitana." (US-09)*

Épica 4 — Motor ML Híbrido

- *"Como sistema (ML Híbrido), quiero combinar las respuestas del cuestionario psicométrico con los vectores del análisis de texto en un único vector de características, para alimentar el modelo Random Forest con datos multimodales que mejoren la precisión diagnóstica del nivel de ansiedad." (US-10)*
- *"Como sistema (ML Híbrido), quiero aplicar el modelo Random Forest entrenado para clasificar el nivel de ansiedad digital del estudiante en las categorías: Bajo, Moderado o Alto, para emitir un diagnóstico predictivo explicable que el personal de Bienestar Universitario pueda interpretar y validar clínicamente." (US-11)*
- *"Como sistema (ML Híbrido), quiero aplicar reglas de conocimiento experto definidas por el psicólogo consultor como capa de validación sobre la salida del*

modelo, para garantizar que el motor híbrido no emita clasificaciones que contradigan criterios clínicos fundamentales de salud mental." (US-12)

- *"Como sistema (ML Híbrido), quiero generar un reporte de Importancia de Características (Feature Importance) que identifique los factores digitales con mayor influencia en el nivel de ansiedad, para que el equipo de Bienestar pueda auditar y comprender las razones detrás de cada clasificación." (US-13)*

Épica 5 — Dashboard y Retroalimentación

- *"Como estudiante universitario, quiero recibir un informe personalizado con mi nivel de ansiedad detectado, los factores que más influyeron y recomendaciones de hábitos digitales saludables, para tomar conciencia de mi situación emocional y contar con orientación concreta para reducir mi tecnoestrés." (US-14)*
- *"Como Área de Bienestar Universitario, quiero filtrar los resultados del dashboard por carrera, ciclo académico y rango de fechas, para identificar patrones de ansiedad digital por cohorte y tomar decisiones estratégicas basadas en evidencia." (US-15)*
- *"Como Área de Bienestar Universitario, quiero exportar reportes de los niveles de ansiedad en formato PDF o Excel, para documentar el impacto del sistema y sustentar su continuidad ante las autoridades institucionales." (US-16)*

Épica 6 — Seguridad y Privacidad

- *"Como estudiante universitario, quiero que todos mis datos de evaluación sean almacenados cifrados en reposo y en tránsito mediante protocolos seguros en AWS, para garantizar que mi información de salud mental sea protegida conforme a la Ley N° 29733 de Protección de Datos Personales del Perú." (US-17)*

- *"Como estudiante universitario, quiero poder solicitar la eliminación de mis datos personales y evaluaciones previas desde la plataforma, para ejercer mis derechos ARCO (Acceso, Rectificación, Cancelación y Oposición) sobre mi información psicológica sensible."* (US-18)

Épica 7 — Continuidad y MLOps

- *"Como equipo de desarrollo, quiero configurar un pipeline automatizado de reentrenamiento del modelo Random Forest cuando se acumule un nuevo lote de datos de estudiantes, para mantener la precisión diagnóstica del sistema (F1-Score $\geq 85\%$) a medida que los patrones de ansiedad digital evolucionan en el tiempo."* (US-19)
- *"Como Portafolio Manager, quiero contar con un documento de Plan de Continuidad Operativa que describa los procedimientos de mantenimiento, escalabilidad y recuperación ante fallos del sistema, para asegurar la disponibilidad, sostenibilidad y gobernanza del sistema a largo plazo."* (US-20)

Criterios de Aceptación (Definition of Done)

Para que una Historia de Usuario se considere terminada, debe cumplir la totalidad de los criterios de la Definition of Done (DoD) global del proyecto, más los criterios específicos de su épica.

DoD Global (aplica a todas las US)

Toda Historia de Usuario se considera completada únicamente cuando cumple todos los criterios siguientes sin excepción:

- El código fuente está implementado, revisado mediante Pull Request y aprobado por al menos un miembro del equipo.
- Las pruebas unitarias correspondientes han sido escritas y pasan al 100%.
- La funcionalidad ha sido demostrada en la Sprint Review y aceptada por el Product Owner.
- La documentación técnica asociada (comentarios en código, diagrama actualizado, acta de reunión) ha sido registrada.
- No existen vulnerabilidades de seguridad críticas ni advertencias en el análisis estático de código.
- El incremento está desplegado en el entorno de staging (AWS) y es accesible sin errores.

Criterios específicos por épica:

É1 — Autenticación y Onboarding: El registro opera exclusivamente con correo institucional. El token JWT expira en 24 horas y se renueva automáticamente. El formulario de consentimiento informado es obligatorio; sin su aceptación, el estudiante no puede acceder al cuestionario. La política de privacidad está redactada en lenguaje claro conforme a la Ley N° 29733.

É2 — Evaluación Psicométrica: El cuestionario implementa la escala TS4US o ASADAS con todos sus ítems validados. El progreso se guarda automáticamente al cerrar sesión. Los datos capturados son almacenados en PostgreSQL con cifrado a nivel de columna para los campos sensibles. El tiempo de respuesta del guardado es inferior a 2 segundos.

É3 — Módulo de PLN: El módulo procesa textos de entre 50 y 500 palabras. La vectorización produce embeddings compatibles con el pipeline del modelo Random Forest. El preprocesamiento incluye eliminación de stopwords en español peruano, lematización y normalización de jerga universitaria local. La latencia de procesamiento no supera los 3 segundos por solicitud.

É4 — Motor ML Híbrido: El modelo Random Forest alcanza un F1-Score (macro) $\geq 85\%$ en validación cruzada K-Fold ($k=5$) con datos reales de estudiantes. La capa de reglas expertas está documentada y validada por el psicólogo consultor. El reporte de Feature Importance muestra las 10 variables más influyentes en formato visual. El tiempo de inferencia no supera los 3 segundos por predicción. La certificación de QA (OE3-II) ha sido emitida.

É5 — Dashboard y Retroalimentación: El informe personalizado al estudiante incluye el nivel de ansiedad, las 3 principales variables de riesgo identificadas y al menos 3 recomendaciones concretas de hábitos digitales saludables. El dashboard de Bienestar Universitario actualiza los datos en tiempo real (latencia ≤ 5 segundos). Los filtros por carrera, ciclo y fecha funcionan sin errores. La exportación genera archivos PDF/Excel correctamente formateados en menos de 10 segundos. La aprobación UX ha sido obtenida con puntaje SUS $\geq 70/100$.

É6 — Seguridad y Privacidad: Todos los datos en tránsito usan TLS 1.3. Los datos en reposo en PostgreSQL están cifrados con AES-256 mediante AWS KMS. El mecanismo de eliminación de cuenta borra de forma irrecuperable todos los datos del usuario en un plazo máximo de 72 horas. Se ha realizado una prueba de penetración básica sin vulnerabilidades críticas. El Consentimiento Informado queda registrado con marca de tiempo en la base de datos.

É7 — Continuidad y MLOps: El pipeline de reentrenamiento en Amazon SageMaker se ejecuta automáticamente al superar el umbral de nuevos registros definido. El modelo reentrenado pasa por validación de métricas antes de ser promovido a producción. El documento del Plan de Continuidad Operativa ha sido revisado y aprobado por el Portafolio Manager (OE4-I1). Los protocolos de recuperación ante fallos han sido probados con un ejercicio de simulación de caída del servidor.

Exclusiones

Con el fin de mantener el alcance controlado y evitar el crecimiento desmedido del proyecto (*scope creep*), se declaran explícitamente las siguientes exclusiones:

- **No reemplaza la atención psicológica clínica presencial.** La plataforma es una herramienta de detección temprana y soporte digital; no emite diagnósticos clínicos oficiales ni sustituye la intervención de un profesional de la salud mental.
- **No contempla instalación ni ejecución local.** El sistema opera exclusivamente en la nube (AWS); no se desarrollarán versiones de escritorio, instalables ni compatibles con servidores on-premise.
- **No incluye el mantenimiento de hardware físico.** La infraestructura es completamente administrada en AWS; el equipo no es responsable de la gestión de servidores físicos, redes locales ni dispositivos de la IES.
- **No contempla instituciones educativas fuera de Lima Metropolitana.** La validación, el entrenamiento del modelo y el despliegue están acotados a universidades de Lima Metropolitana.

- **No incluye una aplicación móvil nativa.** El sistema es una plataforma web responsiva accesible desde cualquier navegador; no se desarrollará una aplicación iOS ni Android en el alcance de este proyecto.
- **No procesa datos biométricos.** El sistema no captura señales fisiológicas como frecuencia cardíaca, EEG, cámara web ni sensores wearables; la detección se basa exclusivamente en cuestionarios psicométricos y análisis de texto.
- **No incluye módulo de videollamadas ni chat en tiempo real con psicólogos.** La plataforma proporciona recomendaciones automatizadas y derivación al servicio de Bienestar, pero no implementa canales de comunicación directa entre estudiante y terapeuta.
- **No almacena historial médico clínico.** El sistema gestiona únicamente los resultados de las evaluaciones de ansiedad digital realizadas en la plataforma; no se integra con historiales clínicos preexistentes de las IES ni con sistemas como el SIS o HIS hospitalario.
- **No contempla funcionalidades de gamificación o recompensas** en esta versión del proyecto; dichas mejoras podrán considerarse en versiones futuras como trabajo de investigación complementario.

1.5.2 CRONOGRAMA

Tabla 4

Lista de Hitos del Proyecto

Hito	Descripción del Hito	Fecha
H1	Sprint 0: Plan de Trabajo de Investigación aprobado	30/03/2026
H2	Sprint 1: Marco Teórico y Estado del Arte completados	27/04/2026
H3	Trabajo de Investigación Parcial entregado	10/05/2026
H4	Sustentación Parcial — Taller de Desempeño Profesional	15/05/2026
H5	Sprint 2: Acta de Constitución del Proyecto v1.0 aprobada	28/06/2026
H6	Sprint 3: Trabajo de Investigación Final completado	05/07/2026
H7	Sustentación Final — Taller de Desempeño Profesional	06/07/2026
H8	Sprint 4: Plan de Trabajo y User Stories aprobados	03/08/2026
H9	Sprint 5: Arquitectura Física y Lógica certificada por QA (OE2-I1)	31/08/2026
H10	Validación con Comité de Proyectos — User Stories con cliente (OE1-I1)	07/09/2026
H11	Sprint 6: Módulo PLN implementado y certificado por IT-SERVICE (OE2-I2)	05/10/2026
H12	Sprint 7: Modelo ML Híbrido integrado con PLN y computación afectiva	02/11/2026
H13	Sustentación Parcial — Taller de Proyectos I (OE1 y OE2 completados)	16/11/2026
H14	Sustentación Final — Taller de Proyectos I	07/12/2026
H15	Sprint 8: Modelo validado clínicamente, precisión $\geq 85\%$ (OE3-I1)	18/01/2027
H16	Sprint 9: Dashboard y módulo de retroalimentación aprobados por UX	15/02/2027
H17	Sprint 10: Validación con Bienestar Universitario completada (OE3-I2, OE4-I2)	15/03/2027
H18	Sprint 11: Plan de Continuidad Operativa aprobado por Portafolio Manager (OE4-I1)	12/04/2027
H19	Sustentación Parcial — Taller de Proyectos II (OE3 y OE4 completados)	26/05/2027

H20	Sprint 12: Memoria final y documentación completa del sistema	23/06/2027
H21	Sustentación Final — Taller de Proyectos II	11/07/2027

Tabla 5

Línea Base Global de Cronograma

Fase	Curso	Período	Duración
Fase 1: Investigación y Diagnóstico	Taller de Desempeño Profesional (SI639)	Mar 2026 – Jul 2026	4 meses
Fase 2: Diseño y Arquitectura del Sistema	Taller de Proyectos I (SI644)	Ago 2026 – Dic 2026	5 meses
Fase 3: Implementación, Validación y Cierre	Taller de Proyectos II (SI646)	Ene 2027 – Jul 2027	7 meses

Tabla 6

Desarrollo de Cronograma – Sprints por Fase

Sprint	Actividades Principales	Inicio	Fin	Responsable
Sprint 0	Plan TI, identificación del problema, Product Backlog	30/03/2026	26/04/2026	PM + SM
Sprint 1	Marco Teórico, Estado del Arte, revisión sistemática	27/04/2026	09/05/2026	PM + SM
Sprint 2	Acta de Constitución, stakeholders, riesgos	16/05/2026	27/06/2026	PM
Sprint 3	TI Final, correcciones post-sustentación	28/06/2026	05/07/2026	PM + SM
Sprint 4	Plan de Trabajo, User Stories, arquitectura preliminar	03/08/2026	30/08/2026	PM + SM
Sprint 5	Arquitectura Física/Lógica, pipeline de datos, QA	31/08/2026	04/10/2026	SM
Sprint 6	Módulo PLN, ingesta de datos, certificación IT-SERVICE	05/10/2026	01/11/2026	SM

Sprint 7	Integración ML Híbrido con PLN y computación afectiva	02/11/2026	15/11/2026	SM
Sprint 8	Pruebas clínicas, métricas $\geq 85\%$, certificación QA	18/01/2027	14/02/2027	SM
Sprint 9	Dashboard de ansiedad, retroalimentación, aprobación UX	15/02/2027	14/03/2027	PM + SM
Sprint 10	Validación Bienestar Universitario, actas OE3-I2/OE4-I2	15/03/2027	11/04/2027	PM
Sprint 11	Plan de Continuidad Operativa, protocolos de mantenimiento	12/04/2027	25/05/2027	PM + SM
Sprint 12	Memoria final, correcciones, documentación completa	23/06/2027	10/07/2027	PM + SM

1.5.3 COSTOS

El presupuesto proyectado del proyecto considera tres categorías: costos de personal (recursos humanos bajo metodología Scrum), gastos generales operativos y bienes/servicios subcontratados. La tarifa hora para los integrantes del equipo de desarrollo se determinó tomando como referencia el rango salarial de egresados de Ingeniería de Sistemas de Información en Lima Metropolitana, donde el sueldo promedio para jóvenes entre 18 y 29 años asciende a S/ 4,349 mensuales según el portal Mi Carrera del MTPE, equivalente a S/ 27 por hora considerando una jornada de 160 horas mensuales. Para el rol de consultor psicólogo, se tomó como referencia el rango de honorarios profesionales en Lima, donde los centros de psicoterapia establecen tarifas entre S/ 50 y S/ 150 por sesión, aplicando S/ 60 por hora para validaciones técnicas puntuales. Los porcentajes de participación reflejan la dedicación parcial del equipo en un proyecto académico de investigación aplicada.

Tabla 7*Costos de Personal*

N°	Rol	Miembro	Participación (%)	Tiempo (meses)	Costo/hora (S/.)	Horas/mes	Total (S/.)
1	Project Manager	Nuñez Alvarez, Sebastian Andre	40%	16	27	64	27,648
2	Scrum Master	Salazar Gutiérrez, Darwin Karl	35%	16	27	56	24,192
3	Psicólogo Consultor	Por definir	15%	4	60	24	5,760
						Total Personal	57,600

Tabla 8*Costos de Gastos Generales*

N°	Descripción	Unidad	Cantidad	Costo unit. (S/.)	Total (S/.)
1	Transporte (reuniones presenciales)	Mes	16	80	1,280
2	Impresiones y empastados	Global	1	350	350
3	Teléfono / Plan de datos	Mes	16	60	960
4	Luz y agua (home office)	Mes	16	45	720
5	Material de escritorio	Global	1	120	120
				Total Gastos Generales	3,430

Tabla 9*Costos de Bienes y Subcontrata*

Nº	Descripción	Unidad	Cantidad	Costo unit. (S/.)	Total (S/.)
1	AWS (EC2, S3, SageMaker — Free Tier + pago por uso)	Mes	16	120	1,920
2	Firebase (autenticación y base de datos tiempo real)	Mes	16	60	960
3	Licencia GitHub Pro (repositorio privado)	Mes	16	20	320
4	Herramienta de gestión ágil — Jira	Mes	16	35	560
5	Laptop adicional (equipo de respaldo)	Unidad	1	2,800	2,800
6	Router Wi-Fi de alta velocidad	Unidad	1	350	350
7	Dominio web y certificado SSL	Año	2	180	360
				Total Bienes y Subcontrata	7,270

Tabla 10*Resumen de Costos*

Nº	Descripción	Total (S/.)
1	Personal	57,600
2	Gastos Generales	3,430
3	Bienes y Subcontrata	7,270
Subtotal		68,300
	Contingencia (10%)	6,830
TOTAL GENERAL		75,130

1.5.4 CALIDAD

La gestión de la calidad del proyecto garantiza que la plataforma web basada en Machine Learning híbrido cumpla con los estándares técnicos, clínicos y éticos requeridos. Se adopta un enfoque de calidad por diseño (*Quality by Design*), en el que los controles de calidad se integran desde las primeras fases del desarrollo y no solo al final.

Normas y estándares aplicables:

ISO/IEC 25010:2023 — Calidad del Producto de Software. Define el modelo de calidad para sistemas y productos de software, evaluando características como funcionalidad, fiabilidad, usabilidad, eficiencia de desempeño, seguridad, mantenibilidad y portabilidad. Para este proyecto, se priorizan la precisión funcional (el sistema detecta correctamente los niveles de ansiedad), la seguridad (protección de datos clínicos sensibles) y la usabilidad (interfaz accesible para estudiantes y personal de Bienestar Universitario).

ISO/IEC 27001:2022 — Gestión de la Seguridad de la Información. Al procesar datos psicológicos sensibles de estudiantes universitarios, el sistema debe implementar un Sistema de Gestión de Seguridad de la Información (SGSI) que garantice la confidencialidad, integridad y disponibilidad de la información. Esto incluye el cifrado de datos en reposo y en tránsito, el control de acceso basado en roles y la gestión de incidentes de seguridad.

ISO/IEC 42001:2023 — Gestión de Sistemas de Inteligencia Artificial. Establece los requisitos para implementar, mantener y mejorar continuamente un sistema de gestión de IA, asegurando que el modelo de ML híbrido opere de forma transparente, explicable y éticamente responsable, alineado con los estándares de la OMS para IA en salud.

Actividades de aseguramiento de la calidad:

Tabla 11

Matriz de Calidad del Proyecto

Atributo de Calidad	Métrica	Criterio de Aceptación	Responsable	Momento de verificación
Precisión del modelo ML	F1-Score (macro)	$\geq 85\%$ en validación cruzada K-Fold	Scrum Master / QA	Sprint 8
Seguridad de datos	Cumplimiento ISO 27001	0 vulnerabilidades críticas en pruebas de penetración	IT-SERVICE	Sprints 5 y 9
Usabilidad de la plataforma	Escala SUS (System Usability Scale)	Puntaje $\geq 70/100$	UX / Bienestar Universitario	Sprint 9
Disponibilidad del sistema	Uptime del servidor (AWS)	$\geq 99\%$ en condiciones normales	SM / Infraestructura	Sprint 11
Privacidad de datos	Conformidad Ley N° 29733	Consentimiento informado al 100% de usuarios	PM / Legal	Sprint 6
Explicabilidad del modelo	Importancia de características (Feature Importance)	Informe clínico validado por psicólogo	Psicólogo Consultor	Sprint 8
Latencia de respuesta	Tiempo de respuesta del sistema	≤ 3 segundos por predicción	SM	Sprint 12

Revisiones y auditorías de calidad: Al término de cada sprint se realizará una *Sprint Review* con demostración funcional del incremento desarrollado, y una *Sprint Retrospective* para identificar mejoras en el proceso. Las certificaciones de arquitectura (OE2-I1), de

ingesta de datos (OE2-I2) y del modelo de detección (OE3-I1) constituyen hitos formales de auditoría de calidad con el área de QA.

1.5.5 RIESGOS

Tabla 12

Matriz de Riesgos del Proyecto

ID	Descripción del Riesgo	Probabilidad	Impacto	Estrategia de Mitigación
R01	Sesgos o insuficiencia en los datos de entrenamiento del modelo de ML	Alto (50%)	Alto	Aplicar técnicas de aumento de datos (<i>data augmentation</i>); validar con psicólogo consultor; solicitar datasets complementarios de entornos universitarios similares.
R02	Dificultades técnicas en la implementación del modelo híbrido o la infraestructura cloud (AWS)	Alto (50%)	Medio	Consultar con el equipo de TI; realizar pruebas progresivas por sprint; capacitarse en las herramientas ML y cloud antes del Sprint 5.
R03	Baja participación de estudiantes por desconfianza en el manejo de datos de salud mental	Medio (40%)	Alto	Garantizar anonimato total; comunicar claramente la política de privacidad y el cumplimiento de la Ley N° 29733; diseñar la plataforma con enfoque de confianza y botón de salida rápida.
R04	Baja precisión del modelo en las primeras iteraciones de detección	Bajo (30%)	Medio	Ajustar hiperparámetros del Random Forest; incluir nuevas variables relevantes; mejorar el preprocesamiento y validar con el equipo de Bienestar Universitario.
R05	Incumplimiento de acuerdos establecidos	Medio (40%)	Alto	Agendar sesiones de revisión periódicas; llevar actas y minutas por sprint; designar

	con el cliente (IES) o áreas usuarias			un punto de contacto único por institución colaboradora.
R06	Cambios en la normativa peruana sobre IA o protección de datos durante el desarrollo	Bajo (20%)	Alto	Monitorear actualizaciones del reglamento de la Ley N° 31814 (PCM); mantener comunicación con asesor legal especializado en protección de datos.
R07	Rotación o indisponibilidad del psicólogo consultor durante las fases de validación clínica	Bajo (20%)	Medio	Identificar un psicólogo consultor de respaldo desde el Sprint 0; documentar todos los criterios clínicos de validación para facilitar la transferencia.

1.6 BENCHMARKING

Introducción

El acelerado proceso de transformación digital en el ámbito académico ha introducido nuevos fenómenos psicológicos como la ansiedad digital y el tecnoestrés, especialmente en estudiantes de educación superior de Lima Metropolitana. Si bien existe un número creciente de recursos en salud digital y aplicaciones de cribado emocional, el estado del arte evidencia que muchas de estas propuestas presentan limitaciones críticas: operan con arquitecturas monolíticas vulnerables a la privacidad de datos clínicos, emplean modelos de inferencia no explicables (*cajas negras*) o carecen de intervenciones sostenidas en el tiempo.

Para abordar esta problemática de forma rigurosa, el presente benchmarking constituye el pilar metodológico de las decisiones tecnológicas del proyecto. Su objetivo es llevar a cabo un análisis comparativo de las principales plataformas, frameworks, lenguajes de programación, algoritmos de ML, métricas de evaluación e infraestructuras cloud disponibles, evaluando variables críticas como la exactitud diagnóstica, la escalabilidad, la seguridad, la explicabilidad clínica y el cumplimiento de la Ley N° 29733 de Protección de Datos Personales del Perú y la norma ISO 27001. Los resultados sirven de sustento técnico

para justificar la adopción de una arquitectura de microservicios, el modelo de ML híbrido basado en Random Forest y la infraestructura AWS, garantizando así la construcción de una plataforma segura, escalable y culturalmente adaptada al entorno universitario de Lima Metropolitana.

A continuación, se presentan las tablas de decisión final de cada benchmarking realizado:

Tabla 13

Selección Final — Framework de Backend

Criterio	Impacto	Frameworks para backend							
		Django		Spring Boot		Laravel		Koa	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento	30%	4	1.20	5	1.50	5	1.50	3	0.90
Seguridad	20%	5	1.00	5	1.00	4	0.80	5	1.00
Escalabilidad	20%	4	0.80	5	1.00	4	0.80	3	0.60
Integración IA	15%	4	0.60	5	0.75	3	0.45	4	0.60
Privacidad	5%	4	0.20	5	0.25	4	0.20	3	0.15
Complejidad	10%	3	0.30	4	0.40	3	0.30	3	0.30
Promedio Total	100%	-	4.10	-	4.90	-	4.05	-	3.55

Spring Boot fue seleccionado por su superioridad en rendimiento concurrente, seguridad nativa (Spring Security), escalabilidad mediante microservicios y fluida integración con modelos de IA mediante REST APIs y gRPC.

Tabla 14*Selección Final — Framework de Frontend*

Criterio	Impacto	Frameworks para frontend					
		Angular		React		Vue.js	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento y Carga	10%	4	0.4	5	0.5	5	0.5
Usabilidad UX/UI	15%	4	0.6	5	0.75	4	0.6
Escalabilidad Arq.	30%	5	1.5	4	1.2	4	1.2
Integración APIs	25%	5	1.25	4	1	4	1
Seguridad Frontend	10%	5	0.5	3	0.3	4	0.4
Ecosistema (Visual)	10%	4	0.4	5	0.5	4	0.4
Promedio Total	100%	-	4.65	-	4.25	-	4.1

Angular fue seleccionado por su arquitectura estricta (TypeScript nativo, MVC), integración asíncrona nativa mediante HttpClient y RxJS, y protección integrada contra ataques XSS, crítica para una plataforma de salud mental.

Tabla 15

Selección Final — Base de Datos

Criterio	Impacto	Bases de datos					
		PostgreSQL		MySQL		MongoDB	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Integridad (ACID)	25%	5	1.25	4	1	3	0.75
Seguridad y Cifrado	30%	5	1.5	4	1.2	4	1.2
Escalabilidad	10%	4	0.4	4	0.4	5	0.5
Soporte de Datos	10%	5	0.5	3	0.3	5	0.5
Integración Backend	20%	5	1	5	1	4	0.8
Mantenibilidad	5%	4	0.2	5	0.25	4	0.2
Promedio Total	100%	-	4.85	-	4.15	-	3.95

PostgreSQL fue seleccionado por su cumplimiento estricto de propiedades ACID, cifrado avanzado nativo, soporte híbrido para datos relacionales y vectoriales (JSONB, pgvector), e integración madura con Spring Boot vía JPA/Hibernate.

Tabla 16

Selección Final — Lenguaje de Programación

Criterio	Impacto	Lenguajes de Programación					
		Python		Java		C#	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento y Concurrency	15%	4	0.6	5	0.75	5	0.75
Ecosistema de ML	30%	5	1.5	3	0.9	3	0.9
Soporte Análisis Datos	20%	5	1	3	0.6	3	0.6
Seguridad y Tipado	15%	4	0.6	5	0.75	5	0.75
Curva de Aprend. / Agilidad	10%	5	0.5	3	0.3	4	0.4
Interoperabilidad (APIs)	10%	5	0.5	5	0.5	5	0.5
Promedio Total	100%	-	4.7	-	3.8	-	3.9

Python fue seleccionado por ser el estándar de la industria para ML (Scikit-Learn, TensorFlow, HuggingFace), con soporte nativo para análisis de datos (Pandas, NumPy) y la capacidad de exponer el modelo como microservicio mediante FastAPI.

Tabla 17*Selección Final — Algoritmo de Machine Learning*

Criterio	Impacto	Algoritmos de Machine Learning					
		Regresión Lineal		Random Forest		Red Neuronal	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Precisión (F1-Score)	30%	3	0.9	5	1.5	5	1.5
Explicabilidad	25%	5	1.25	4	1	2	0.5
Tolerancia Ruido	20%	3	0.6	5	1	4	0.8
Integración Híbrida	10%	3	0.3	5	0.5	2	0.2
Eficiencia Comput.	10%	5	0.5	4	0.4	3	0.3
Escalabilidad	5%	3	0.15	4	0.2	5	0.25
Promedio Total	100%	-	3.7	-	4.6	-	3.55

Random Forest fue seleccionado por el balance óptimo entre precisión clínica y explicabilidad (Feature Importance), su tolerancia a datos psicométricos ruidosos o incompletos, y su integración natural con arquitecturas híbridas de reglas clínicas expertas.

Tabla 18

Selección Final — Métrica de Evaluación ML

Criterio	Impacto	Métricas de evaluación ML							
		Accuracy		Precision		Recall		F1-Score	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Pen. Falsos Negativos	30%	2	0.6	1	0.3	5	1.5	4	1.2
Desbalance de Clases	25%	1	0.25	4	1	4	1	5	1.25
Balance Armónico	20%	2	0.4	2	0.4	2	0.4	5	1
Relevancia Clínica	10%	3	0.3	3	0.3	5	0.5	4	0.4
Pen. Falsos Positivos	10%	3	0.3	5	0.5	1	0.1	4	0.4
Estabilidad Valid.	5%	2	0.1	3	0.15	3	0.15	5	0.25
Promedio Total	100%	-	1.95	-	2.65	-	3.65	-	4.5

El F1-Score fue seleccionado por ser la única métrica que mantiene el balance armónico entre Precisión y Recall, siendo robusta ante clases desbalanceadas y minimizando simultáneamente los falsos negativos (estudiantes con ansiedad no detectados) y los falsos positivos (saturación del servicio de Bienestar). El Recall se monitorea como métrica secundaria por su equivalencia a la Sensibilidad clínica.

Tabla 19*Selección Final — Infraestructura Cloud*

Criterio	Impacto	Proveedores Cloud					
		AWS		Azure		GCP	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Seguridad y Compliance	34%	5	1.7	5	1.7	4	1.36
Orquestación Microserv.	27%	5	1.35	4	1.08	5	1.35
Servicios Machine Learning	20%	5	1	4	0.8	5	1
Entrega de Contenido	7%	5	0.35	4	0.28	4	0.28
Escalabilidad	6%	5	0.3	5	0.3	4	0.24
Costo-Eficiencia	6%	4	0.24	3	0.18	4	0.24
Promedio Total	100%	-	4.94	-	4.34	-	4.47

AWS fue seleccionado por su liderazgo en seguridad y cumplimiento normativo (34%), su madurez en orquestación de microservicios con EKS/ECS y el ecosistema completo de MLOps con Amazon SageMaker, que permite desplegar el modelo Random Forest en Python como API predictiva con latencia mínima y cifrado de extremo a extremo de la base de datos PostgreSQL.

2. Marco Teórico

El desarrollo de una plataforma web orientada a la salud mental estudiantil en un contexto de alta digitalización académica exige un sustento teórico que armonice los avances de la ciencia de datos con los paradigmas de la psicología contemporánea. La interrelación entre el machine learning y la inteligencia artificial, con el bienestar emocional no es meramente instrumental; representa una reconfiguración de la interacción humano-computadora en la que los sistemas dejan de ser simples procesadores de información para convertirse en agentes con capacidad de reconocimiento afectivo. El presente marco teórico estructura esta convergencia mediante tres ejes: las bases conceptuales técnicas y psicológicas, los estándares de ingeniería y marcos de intervención clínica, y la normativa legal que rige el uso ético de tecnologías emergentes en el Perú.

2.1 Definiciones

En esta sección se establece la base conceptual técnica y psicológica del proyecto, profundizando en la evolución de las tecnologías que permiten la interpretación de estados humanos y las variables psicológicas que definen la problemática del estudiante universitario frente a la tecnología.

2.1.1 Inteligencia Artificial (IA)

Se define como la capacidad de algoritmos integrados en sistemas para aprender de los datos y realizar tareas automatizadas sin una programación humana explícita para cada paso (Organización Mundial de la Salud, 2024). Históricamente, la IA ha evolucionado desde sistemas basados en reglas hacia el aprendizaje automático estadístico (*Machine Learning*), el cual se divide en modelos discriminativos, que aprenden a clasificar y decidir, y modelos generativos, que buscan modelar la distribución de los datos para sintetizar contenido original (Quiroz Martinez, 2025).

2.1.2 IA Generativa (GenAI)

La transición hacia la Inteligencia Artificial Generativa (GenAI) se caracteriza por el uso de modelos multimodales a gran escala (LMM) capaces de generar texto, imágenes y video (Organización Mundial de la Salud, 2024). En la educación superior, Quiroz Martinez (2025) sostiene que la GenAI no solo automatiza la gestión, sino que personaliza el aprendizaje y mejora la retroalimentación individualizada. No obstante, López del Castillo (2024) advierte que esta evolución requiere un compromiso ético para evitar la deshumanización de los procesos académicos.

2.1.3 Procesamiento de Lenguaje Natural (PLN)

Es el campo de la IA que permite a las máquinas interpretar y generar lenguaje humano mediante el análisis de sentimientos (Ishfaq et al., 2025). Además de ello, según Wan et al. (2025), el PLN permite identificar indicadores de salud mental, como sentimientos de desesperanza o aislamiento, transformando publicaciones de redes sociales en datos estructurados para modelos de aprendizaje profundo.

Como se observa en la Figura 2, el PLN se sitúa en una intersección crítica entre la inteligencia artificial, el aprendizaje automático (Machine Learning) y el aprendizaje profundo (Deep Learning), integrando además fundamentos de las ciencias de la computación y la lingüística. Esta convergencia permite que los sistemas no solo procesen datos textuales, sino que comprendan la estructura y el contexto del lenguaje humano para aplicaciones de alta precisión.

2.1.4 Machine Learning

El *Machine Learning* (ML) se define como una subdisciplina de la inteligencia artificial que se especializa en la creación de algoritmos capaces de aprender patrones intrínsecos a partir de conjuntos de datos heterogéneos. En el ámbito de la salud digital, Meneses Ayala

et al. (2025) señalan que el ML permite transformar la gestión de diagnósticos y la atención temprana al automatizar la interpretación de variables clínicas y conductuales, las cuales, en entornos con infraestructura limitada, suelen ser subutilizadas. Este enfoque no solo optimiza la precisión en la identificación de riesgos, sino que facilita una gestión proactiva frente a métodos tradicionales que carecen de escalabilidad.

2.1.5 Machine Learning Híbrido

La arquitectura híbrida representa una evolución necesaria frente a los modelos monolíticos. De acuerdo con el marco propuesto por Mateus et al. (2026), la complejidad inherente a la era digital y a los datos de salud exige sistemas que integren diversas fuentes de información, como biométricas, textuales y contextuales, garantizando, simultáneamente, la ética y la privacidad del usuario. Un sistema de *Machine Learning* híbrido combina técnicas de procesamiento de lenguaje natural (NLP) para la detección de indicadores psicosociales (ansiedad digital) con modelos predictivos estadísticos, logrando una mayor robustez diagnóstica al mitigar los sesgos propios de un único método de análisis.


2.1.6 Técnica de Voting (Votación)

Dentro de la arquitectura de ensamble (*Ensemble Learning*), la técnica de *Voting* se posiciona como una estrategia crítica para la toma de decisiones algorítmica. En un entorno donde la precisión es vital para no generar falsos positivos en la detección de ansiedad, el *Voting* permite la agregación de predicciones provenientes de múltiples clasificadores base. Como se infiere de los estudios sobre estrategias digitales analizados en la *Revista Científica de Sistemas e Informática* (2025), la combinación de diversos modelos (votantes) mediante reglas de consenso o votación ponderada reduce la varianza del modelo final. Esta técnica asegura que el sistema sea capaz de realizar un diagnóstico más

resiliente, compensando las debilidades individuales de cada sub-algoritmo frente a la variabilidad de los datos recolectados en estudiantes universitarios

Figura 6

Panorama general del PLN en el ámbito de la IA



Nota. Adaptado de *NLP 101* por E2E Networks, 2023

A partir de esta estructura jerárquica, se han desarrollado modelos avanzados de aprendizaje profundo que optimizan la detección de patologías. En el análisis de trastornos mentales, Ishfaq et al. (2025) reportan que el modelo RoBERTa-Large alcanza una precisión del 97% en la clasificación de estados emocionales, superando a otros modelos como ELECTRA. Esta precisión es fundamental para detectar la ansiedad digital en entornos universitarios, permitiendo que la plataforma identifique matices lingüísticos y patrones de estrés en tiempo real (Wan et al., 2025; PHD Assistance, 2024).

2.1.7 Computación Afectiva

La computación afectiva se define como el diseño de sistemas capaces de reconocer, procesar y responder a las emociones humanas (Baldassarri Santalucía, 2016). De acuerdo con ITDO (2023), su premisa central es que las emociones son determinantes en la toma de decisiones, por lo que dotar a las máquinas de "empatía artificial" mejora significativamente la experiencia del usuario.

Estos sistemas deben ser capaces de capturar estados emocionales a través de señales en la cara, la voz o el texto (Baldassarri Santalucía, 2016). En adición, según ITDO (2023) destaca que aplicaciones de esta tecnología incluyen la adaptación de interfaces (colores, música) según el ánimo del usuario, aunque advierte sobre riesgos éticos relacionados con la privacidad de los datos afectivos. Chanchí-Golondrino et al. (2022) mencionan el uso de modelos como el de Plutchik para clasificar sentimientos complejos a partir de la interacción digital.

2.1.8 Ansiedad Digital y Tecnoestrés

El tecnoestrés se define como un estado psicológico negativo resultante de la incapacidad de adaptarse a las nuevas tecnologías (Solano Castro y Núñez Lira, 2025). Este fenómeno, introducido por Brod (1984), se manifiesta en dimensiones como la tecno-fatiga, la tecno-ansiedad y el sentimiento de ineficacia. En Lima Metropolitana, Solano Castro y Núñez Lira (2025) reportan que el 45.74% de los estudiantes universitarios perciben niveles medios de tecnoestrés.

Por su parte, Tudose (2025) describe la ansiedad digital como el miedo a no estar actualizado tecnológicamente, lo que genera tensión e incluso *burnout*. Investigaciones en la región indican que los estudiantes que utilizan principalmente el celular para estudiar presentan un nivel medio de tecnoestrés significativamente mayor (32.3%) en comparación

con los usuarios de laptops (Solano Castro y Núñez Lira, 2025). Este cuadro clínico afecta negativamente el autoconcepto laboral del estudiante (Escudero, 2023).

2.1.9 Autoeficacia Académica

La autoeficacia académica se refiere a las creencias del estudiante sobre su propia capacidad para alcanzar el éxito académico (Chumbimuni-Aguirre y Pequeña Constantino, 2023). Basada en la teoría de Bandura (1977), influye en la persistencia ante obstáculos tecnológicos (More, 2020). En Lima Metropolitana, Dominguez-Lara y Fernández-Arata (2019) hallaron que el 17.4% de estudiantes universitarios reportan niveles bajos de autoeficacia académica.

Existe una correlación positiva y significativa entre el bienestar psicológico y la autoeficacia académica en estudiantes de Lima (Chumbimuni-Aguirre y Pequeña Constantino, 2023). Asimismo, More (2020) señala que la autoeficacia actúa como un factor protector ante el estrés. Estudios locales refuerzan que la buena conectividad a internet se asocia con mayores puntuaciones de autoeficacia académica (More, 2020).

2.2 Estándares, buenas prácticas y frameworks

Esta sección detalla las metodologías y marcos de referencia que garantizan la viabilidad técnica y la efectividad terapéutica de la plataforma digital.

2.2.1 Metodologías Ágiles (Scrum)

Scrum es un marco de trabajo liviano que ayuda a equipos a generar valor mediante soluciones adaptables para problemas complejos. Se basa en el empirismo, que sostiene que el conocimiento proviene de la experiencia y la toma de decisiones basada en lo observado (Schwaber y Sutherland, 2020). Sus pilares son la transparencia, la inspección y la adaptación (Asana, 2024).

Para comprender adecuadamente el alcance de Scrum, es fundamental diferenciarlo de la filosofía general que lo enmarca. Mientras que *Agile* representa una mentalidad de gestión basada en el desarrollo iterativo y la mejora continua, Scrum es la estructura específica que aplica dichos principios, diferenciándose de otros métodos visuales como Kanban. La Tabla 3 detalla las diferencias operativas y estructurales entre estos enfoques.

Tabla 20

Comparativa de características entre Agile, Scrum y Kanban

Característica	Agile	Scrum	Kanban
Tipo	Filosofía o mentalidad	Marco de trabajo estructurado	Método visual de gestión
Ciclos de trabajo	Iterativos (sin formato fijo)	Sprints de 1 a 4 semanas	Flujo continuo
Roles definidos	No	Sí (Scrum Master, Product Owner, equipo)	No
Reuniones obligatorias	No	Sí (Daily, sprint review, retrospectiva)	No
Mejor para	Cualquier equipo que busque flexibilidad	Proyectos con entregas frecuentes	Trabajo continuo sin fechas fijas

Nota. Adaptado de Asana, 2024.

Dentro de este marco estructurado, el equipo Scrum consta de un *Product Owner*, un *Scrum Master* y Desarrolladores, quienes trabajan en ciclos cortos denominados *Sprints* de

una a cuatro semanas (Schwaber y Sutherland, 2020). Según Asana (2024) destaca que la integración de IA en Scrum puede ayudar a identificar bloqueos y resumir el estado del proyecto de forma automatizada.

2.2.2 Framework de Terapia Cognitivo-Conductual Digital (iCBT)

La Terapia Cognitivo-Conductual por Internet (iCBT) es considerada el "estándar de oro" de la psicoterapia digital, adaptando la TCC tradicional a plataformas web y móviles (Onyeka et al., 2024). Cudris-Torres et al. (2026) sostienen que la iCBT es esencial para reducir la brecha de atención en salud mental de estudiantes universitarios en América Latina.

Estos programas suelen estructurarse en 8 a 12 módulos que incluyen ejercicios de respiración y reestructuración cognitiva (Onyeka et al., 2024; Gkintoni et al., 2025). Según Onyeka et al. (2024), la iCBT guiada presenta mejores resultados a corto plazo, aunque ambos modelos (guiado y no guiado) demuestran una eficacia clínica significativa comparable a la terapia cara a cara.

2.2.3 Modelo de Aceptación Tecnológica (TAM)

Se utiliza para predecir si un usuario elegirá adoptar una tecnología basándose en la Utilidad Percibida y la Facilidad de Uso Percibida (Walumbe, 2024). León-Garrido et al. (2025) señalan que la integración de apps móviles en educación superior mejora el aprendizaje siempre que el estudiante perciba control sobre su formación.

Investigaciones indican que el 75.1% de estudiantes están dispuestos a usar apps de salud mental, valorando la rapidez y la información confiable (Garay y Celleri, 2024). Para maximizar la aceptación, (Schorr, 2023) enfatiza la necesidad de incorporar factores adicionales como la confianza y la seguridad de los datos en el diseño de la plataforma.

2.2.4 Arquitecturas en la Nube (Serverless/AWS/Firebase)

La arquitectura *Serverless* es un modelo de computación en la nube donde el proveedor gestiona automáticamente la infraestructura, permitiendo que el desarrollador se enfoque solo en el código (Baigorria, 2024; Meegle, 2024). Entre sus ventajas destacan la escalabilidad automática (de 10 a millones de usuarios) y el modelo de pago por uso (Digital Exp, 2024).

AWS Lambda ofrece servicios de computación FaaS (*Function-as-a-Service*) para flujos de datos complejos y asíncronos (Baigorria, 2024). Firebase, por su parte, es una plataforma BaaS (*Backend-as-a-Service*) ideal para aplicaciones móviles que requieren bases de datos NoSQL en tiempo real (Digital Exp, 2024). Meegle (2024) subraya que estas arquitecturas son críticas en salud para manejar picos de demanda durante crisis de salud pública.

2.3 Cumplimiento normativo

Esta sección describe el marco legal peruano e internacional que rige el tratamiento de datos sensibles y el uso de inteligencia artificial.

2.3.1 Ley N° 29733 - Ley de Protección de Datos Personales (Perú)

La Ley N° 29733 tiene como objeto garantizar el derecho fundamental a la protección de datos personales a través de su adecuado tratamiento (Congreso de la República, 2011). En el Perú, los datos relativos a la salud se consideran "datos sensibles", lo que exige el consentimiento previo, informado, expreso e inequívoco del titular (Congreso de la República, 2011; Defensoría del Pueblo, 2019).

La ley establece principios como la legalidad, la finalidad (uso solo para lo declarado) y la seguridad de los bancos de datos (Congreso de la República, 2011). Asimismo, faculta al estudiante para ejercer sus derechos ARCO (Acceso, Rectificación, Cancelación y

Oposición) sobre su información emocional (Congreso de la República, 2011; Defensoría del Pueblo, 2019).

2.3.2 Ley N° 30096 - Ley de Delitos Informáticos

La Ley N° 30096 sanciona las conductas ilícitas que afectan los sistemas y datos informáticos (Congreso de la República, 2013). Villanueva (2023) señala que esta ley penaliza delitos dolosos como el acceso ilícito (Art. 2) y el atentado contra la integridad de los datos (Art. 3), con penas privativas de libertad de hasta seis años.

Recientemente, el Decreto Legislativo 1700 incorporó el delito de tráfico ilícito de datos informáticos obtenidos sin consentimiento (Jurispol, 2026). Esta norma garantiza la "tutela penal reforzada" del derecho a la autodeterminación informativa, fundamental cuando se manejan perfiles psicológicos sensibles de estudiantes (Jurispol, 2026; Villanueva, 2023).

2.3.3 Ley N° 31814 - Ley que promueve el uso de la Inteligencia

Artificial en el Perú

La Ley N° 31814 promueve el uso de la IA privilegiando el respeto de los derechos humanos y la seguridad de la persona (Congreso de la República, 2023). Su reglamento establece una clasificación de la IA por niveles de riesgo, prohibiendo usos que vulneren la privacidad o bienestar de los ciudadanos (Presidencia del Consejo de Ministros [PCM], 2025).

La autoridad responsable de supervisar el desarrollo ético de la IA en el país es la Secretaría de Gobierno y Transformación Digital de la PCM (Congreso de la República, 2023; PCM, 2025). Según el reglamento, los sistemas de IA deben operar bajo principios de transparencia y supervisión humana, asegurando que la tecnología no transgreda la privacidad (Congreso de la República, 2023).

2.3.4 Estándares Éticos de la Organización Mundial de la Salud (OMS) para la IA en Salud

La Organización Mundial de la Salud (Organización Mundial de la Salud, 2024) ha publicado guías de ética y gobernanza para modelos de IA en salud, enfatizando la protección de la autonomía humana y el bienestar público. Se advierte sobre el "sesgo de automatización" (confianza excesiva en el algoritmo) y el riesgo de generar información inexacta que afecte la seguridad del paciente.

Los principios fundamentales incluyen la transparencia, la explicabilidad (que el funcionamiento sea inteligible para el usuario) y la equidad (acceso sin discriminación).

Según la Organización Mundial de la Salud (2024), es imperativo que los desarrolladores de IA en salud involucren a pacientes y médicos en el diseño para asegurar que los modelos sean sostenibles y respetuosos con los valores humanos.

3. Estado del Arte

En este capítulo se desarrolla la revisión sistemática de la literatura del proyecto de investigación, aplicando una metodología de búsqueda que permite identificar, analizar y sintetizar los avances más relevantes sobre la detección de la ansiedad digital en estudiantes universitarios mediante el uso de algoritmos de Machine Learning y técnicas híbridas. Esta revisión se llevó a cabo considerando fuentes académicas indexadas en bases de datos de alto impacto como Scopus, Web of Science, IEEE Xplore y PubMed, siguiendo criterios de selección y exclusión rigurosos que aseguran la calidad y actualidad de los estudios analizados. El objetivo principal de este capítulo es presentar una visión global del panorama científico existente, evidenciar las tendencias tecnológicas en modelos predictivos y procesamiento de datos, identificar las brechas de conocimiento actuales y sustentar la pertinencia técnica y clínica de la plataforma de detección propuesta en la presente investigación.

3.1 Introducción

La transformación digital en la educación ha cambiado muchas cosas, y no todas para bien. Entre sus efectos más documentados está el incremento de la ansiedad digital y el tecnoestrés en estudiantes universitarios, fenómenos que se alimentan mutuamente con la presión académica, el uso intensivo de dispositivos móviles y la necesidad de adaptarse de forma continua a entornos de aprendizaje virtual. Araya-Ugarte et al. (2025) lo describen con precisión: la aceleración digital genera sobrecarga de información y fatiga mental que acaban obstaculizando un aprendizaje sostenible. Y el problema no se detiene ahí. La literatura es consistente en señalar que este fenómeno deteriora tanto la salud mental del estudiante como su rendimiento académico y su satisfacción general, con la autoeficacia y

el clima organizacional como variables mediadoras relevantes (Acosta-Enriquez et al., 2025; Reyes & Libaque-Saenz, 2023).

La razón por la que este problema merece atención urgente es bastante directa: la ansiedad digital que no se detecta ni se gestiona a tiempo puede derivar en cuadros clínicos más severos, con consecuencias que van mucho más allá del rendimiento académico y se extienden a la vida personal y social del estudiante. La educación superior es, por su propia naturaleza, una etapa de alta vulnerabilidad, lo que hace que los mecanismos de detección temprana no sean un lujo sino una necesidad (Estrada-Araoz et al., 2024). López-Armes y Javier-Ninahuaman (2023) lo confirman al señalar que una proporción significativa de la población universitaria presenta niveles de estrés que requieren atención prioritaria, e identificar las variables psicosociales y tecnológicas que desencadenan estas crisis en el período pospandemia es un paso ineludible.

Frente a ese panorama, las respuestas tecnológicas han seguido una trayectoria interesante. Los enfoques han evolucionado desde la validación de escalas psicométricas tradicionales (Norabuena-Figueroa et al., 2025) hasta soluciones más sofisticadas basadas en Inteligencia Artificial y Procesamiento de Lenguaje Natural. Investigaciones recientes han desarrollado modelos de detección mediante Machine Learning y redes neuronales capaces de inferir estados mentales a partir de huellas digitales en redes sociales y comunicaciones (Hochstenbach et al., 2026; Oulahbib et al., 2026). Otras propuestas han apostado por asistentes conversacionales con mecanismos de fusión emocional para brindar soporte psicológico (Wang et al., 2023), e intervenciones gamificadas que, a través del storytelling, mejoran la adherencia terapéutica sin depender de incentivos materiales (Castro et al., 2023). En conjunto, estos desarrollos muestran que integrar algoritmos de detección con

soportes digitales adaptativos es una vía con potencial real para abordar la ansiedad en entornos universitarios.

Este capítulo se organiza en tres secciones. La primera, 2.2 Metodología de Búsqueda, describe las fases de planificación, conducción y documentación seguidas para llevar a cabo la revisión sistemática de la literatura. La segunda, 2.3 Análisis de Resultados, incluye la matriz de artículos seleccionados, el resumen de cada investigación con foco en sus aportes, problemas, instrumentos y resultados, y la discusión crítica articulada en torno a las preguntas de investigación formuladas. El capítulo cierra con las conclusiones del estado del arte, que consolidan el fundamento conceptual y empírico sobre el que se apoya la propuesta tecnológica de esta tesis.


3.2 Metodología de Búsqueda

3.2.1 Fases o Etapas de la Búsqueda

Para la elaboración del presente estado del arte, se emplea la metodología de revisión sistemática definida por Kitchenham y Charters (2007). Este proceso metodológico se estructura en tres fases fundamentales: la planificación de la revisión, la conducción de la misma y la documentación de la revisión.

Figura 7

Etapas de una búsqueda



3.2.2 Fase: Planificación de la Revisión

3.2.2.1 Preguntas de Investigación

Con el fin de cumplir con el objetivo de la revisión sistemática, se plantean las siguientes preguntas de investigación relevantes:

Tabla 21

Preguntas de investigación

#	Acrónimo	Pregunta de Investigación
1	P1	¿Qué factores y escalas caracterizan el tecnoestrés y la ansiedad digital en universitarios?
2	P2	¿Qué algoritmos de PLN y Machine Learning son más precisos para clasificar trastornos afectivos?
3	P3	¿Cómo influyen las plataformas web o móviles y la gamificación en la regulación emocional del usuario?
4	P4	¿Qué arquitecturas tecnológicas garantizan la seguridad y privacidad de los datos en salud digital?
5	P5	¿Cómo optimizan los modelos de ensamble y la telemetría multimodal la detección de ansiedad en tiempo real?

3.2.2.2 Palabras claves

En base a las preguntas de investigación se plantean las siguientes palabras claves:

Tabla 22

Palabras claves

#	Pregunta de Investigación	Palabras claves
1	P1	[ansiedad digital, tecnoestrés] + [estrés académico, estudiantes universitarios] + [escalas psicométricas, factores predictores]
2	P2	[procesamiento de lenguaje natural, machine learning] + [deep learning, clasificación de trastornos afectivos] + [análisis de sentimientos, transformers]
3	P3	[salud web, salud móvil, gamificación] + [juegos serios, regulación emocional] + [agentes conversacionales, experiencia de usuario]
4	P4	[ciberseguridad, privacidad de datos] + [salud digital, computación en la niebla] + [aprendizaje federado, gobernanza ética]
5	P5	[modelos de ensamble, telemetría multimodal] + [fusión de sensores, tiempo real] + [visión artificial, wearables]

3.2.2.3 Criterios de Selección y Exclusión

Se tendrá en cuenta los siguientes criterios para la búsqueda de artículos científicos:

Tabla 23

Criterios de selección

#	Criterios
1	Antigüedad de Artículos: Máximo 5 años de antigüedad (2022 - a la fecha)
2	Idioma: De preferencia en inglés o español
3	Tipo de Artículo: Artículo de aporte
4	Tipo de Revista: Indexada
5	Quartil: Q1 - Q4
6	Actas de conferencias internacionales arbitradas por pares (IEEE, LACCEI, etc.)

Tabla 24

Criterios de exclusión


#	Criterios de Exclusión
1	Tipo de Artículo: Editorial, Tesis, Libros, opiniones editoriales, notas de prensa, blogs informativos, etc.
2	Publicaciones con una antigüedad mayor al año 2022
3	No es de acceso libre
4	Sin pruebas estadísticas, numeración o validación

3.2.3 Fase: Conducción de la Revisión

A continuación, se presenta el proceso de revisión de la literatura:

Figura 8

Proceso de revisión de la literatura



Como resultado de la revisión sistemática llevada a cabo, se obtuvieron un total de 93 artículos, de los cuales se seleccionaron 40 investigaciones siguiendo los criterios establecidos de inclusión y exclusión.

Tabla 25

Artículos potencialmente elegibles y seleccionados

Base de Datos	N° de artículos elegibles	N° de artículos seleccionados
SCOPUS	2884	65
Web of Science	19	3
Pubmed	177	8
IEEE Xplore	343	17
TOTAL	3383	93


3.2.4 Fase: Documentación de la Revisión

A partir del cuerpo documental consolidado, se procedió a la elaboración de estadísticas descriptivas con el propósito de evaluar el nivel de calidad y la pertinencia de la información recolectada. Este análisis estadístico resulta fundamental para visibilizar patrones predominantes y tendencias que emergen en el área de estudio, lo que a su vez facilita el hallazgo de vacíos conceptuales y nichos de investigación que precisan de un mayor desarrollo. En este apartado, se integran diversas representaciones gráficas que sintetizan los hallazgos derivados de la revisión sistemática.

Se presentan a continuación algunos modelos ilustrativos:

Figura 9


Número de artículos por banco de datos



Scopus concentra la mayor parte de la evidencia científica seleccionada, con 65 artículos que equivalen al 69.9% del total, lo que refleja su amplia cobertura multidisciplinaria en áreas como machine learning, salud mental digital y tecnologías de la información aplicadas a la educación. IEEE Xplore ocupa el segundo lugar con 17 artículos (18.3%), base que resulta especialmente pertinente para este proyecto al indexar investigaciones sobre sistemas inteligentes, detección de señales fisiológicas y plataformas tecnológicas para el monitoreo de la ansiedad. PubMed aporta 8 artículos (8.6%) con evidencia clínica validada sobre intervenciones digitales en salud mental, y Web of Science contribuye con 3 (3.2%) de alto impacto en ciencias sociales y psicología. La combinación estratégica de estas cuatro bases asegura una cobertura comprehensiva del estado del arte en detección de ansiedad digital mediante IA.

Figura 10


Número de artículos clasificados año



La distribución temporal evidencia una tendencia de crecimiento sostenido en la producción científica sobre plataformas TI y machine learning para la detección de ansiedad digital. Con apenas 4 artículos en 2022, la publicación se disparó a 30 en 2023 (32.3%), el año de mayor producción, manteniéndose alta con 26 en 2024 (28.0%), 13 en 2025 (14.0%) y 20 en 2026 (21.5%), este último aún en curso al momento de la búsqueda. Este incremento notable a partir de 2023 coincide con la consolidación de los modelos de lenguaje de gran escala, la expansión de los wearables y el creciente reconocimiento de la ansiedad digital como problema de salud pública en estudiantes universitarios, lo que otorga plena vigencia y actualidad al presente proyecto de investigación.

Figura 11


Número de artículos clasificados por país del autor



El gráfico muestra que Perú y Estados Unidos lideran en paridad la producción científica incluida en esta revisión, con 17 artículos cada uno (18.3% respectivamente), lo que en conjunto representa el 36.6% del total del corpus. La posición de Perú como país colidero es altamente relevante para el proyecto, dado que confirma una base de investigación local activa sobre plataformas tecnológicas, machine learning y ansiedad en estudiantes universitarios de entornos similares al de Lima Metropolitana. Le siguen China (7), India (6), Australia y Reino Unido (5 cada uno), países con tradición consolidada en el desarrollo de soluciones de inteligencia artificial para salud mental digital. La diversidad geográfica del corpus garantiza que las propuestas tecnológicas y metodológicas identificadas puedan ser analizadas y adaptadas al contexto universitario limeño

Figura 12


Número de artículos clasificados por cuartil



El 58.1% de los artículos seleccionados pertenece a revistas Q1 (54 artículos) y el 15.1% a revistas Q2 (14 artículos), lo que significa que el 73.1% de la evidencia revisada proviene de publicaciones de alto impacto internacional. Las revistas Q3 y Q4 aportan el 9.7% restante, mientras que las ponencias de conferencias IEEE representan el 17.2%, reflejando la naturaleza tecnológica y emergente del campo de la detección de ansiedad digital mediante machine learning. Esta distribución respalda la solidez del fundamento científico del proyecto, ya que los cuartiles superiores exigen estándares elevados de rigor metodológico, revisión por pares y reproducibilidad, aspectos críticos para el diseño de una plataforma TI basada en ML híbrido orientada a estudiantes universitarios de Lima Metropolitana.

Figura 13


Número de artículos clasificados por tipo



Los artículos de tipo "Aporte" son los más numerosos con 54 publicaciones (58.1%), seguidos de los artículos "Original" con 27 (29.0%) y los de "Contribución" con 12 (12.9%). La predominancia de aportes indica que el campo de la detección de ansiedad digital con IA se encuentra en una fase de consolidación conceptual y síntesis, lo cual es favorable para fundamentar el diseño de la plataforma propuesta en este proyecto. Los artículos originales con evidencia empírica primaria confirman que también existe experimentación activa en el área, mientras que las contribuciones metodológicas amplían el repertorio de técnicas ML disponibles para la implementación de soluciones híbridas de detección de ansiedad en entornos universitarios.

Figura 14

Número de artículos clasificados por año y banco de datos



El análisis cruzado entre año y banco de datos revela que Scopus domina en todos los períodos, con su mayor concentración en 2023 (20 artículos) y 2024 (16), consolidándose como la fuente más constante de evidencia sobre plataformas ML para salud mental digital. IEEE Xplore muestra actividad significativa en 2023 y 2024 (6 artículos cada año), lo que refleja el impulso de las conferencias tecnológicas en el desarrollo de sistemas de detección de ansiedad mediante señales fisiológicas y wearables, directamente aplicables al presente proyecto. PubMed aporta evidencia clínica distribuida entre 2023 y 2026, y Web of Science concentra su contribución en 2023 y 2024. Esta distribución confirma que el pico de 2023 fue un fenómeno multidisciplinario global que integró al mismo tiempo avances tecnológicos, clínicos y educativos relevantes para la detección de ansiedad digital en universitarios.

3.3 Análisis de Resultados

3.3.1 Matriz de Artículos Seleccionados

Tabla 26

Relación de los artículos analizados por categoría

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
P1	1	The mediating role of academic stress, critical thinking and performance expectations in the influence of academic self-efficacy on AI dependence: Case study in college students	Acosta-Enriquez, B. G., Ballesteros, M. A. A., Guzman Valle, M. de los A., Morales Angaspilco, J. E., Aquino Lalupú, J. del R., Jaico, J. L. B., Germán Reyes, N. C., Alarcón García, R. E., & Castillo, W. E. J.	2025	Perú	Computers and Education Artificial Intelligence	Q1
	2	Academic stress and organizational climate in university students of a public university in Peru in the post-Covid-19 pandemic	López-Armes, E. L., & Javier-Ninahuaman, H. J.	2023	Perú	Aibi Revista De Investigación Administración E Ingenierías	Q4
	3	Coping with stress and self-efficacy as predictors of academic satisfaction in a sample of university students	Estrada-Araoz, E. G., Larico-Uchamaco, G. R., Roman-Paredes, N. O., & Ticona-Chayña, E.	2024	Perú	Salud, Ciencia y Tecnología	Q3

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	4	Contextual Study of Technostress in Higher Education: Psychometric Evidence for the TS4US Scale from Lima, Peru	Araya-Ugarte, G., Armesto-Céspedes, M., Contreras-Barraza, N., Vega-Muñoz, A., Salazar-Sepúlveda, G., & Lay, N.	2025	Perú	Sustainability Switzerland	Q2
	5	Technostress and Smartphone addiction mediated by Smartphone distraction in college students	Vallejos-Flores, M., Talledo-Sánchez, K., Carlos-Ventura, D., Caycho-Caja, A., Amesquita, J. S., & Huamanyauri, D. R.	2024	Perú	Revista Digital De Investigación En Docencia Universitaria	Q3
	6	Factors influencing higher education students' performance and satisfaction with virtual classes during the Covid-19 pandemic: the case of Peru	Reyes, R., & Libaque-Saenz, C. F.	2023	Perú	Issues in Information Systems	Q4
	7	Digital Teaching Practices and Student Academic Stress in the Era of Digitalization in Higher Education	Norabuena-Figueroa, R. P., Deroncele-Acosta, A., Rodríguez-Orellana, H. M., Norabuena-Figueroa, E. D., Flores-Chinte, M. C., Huamán-Romero, L. L., Tarazona-Miranda, V. H., & Mollo-Flores, M. E.	2025	Perú	Applied Sciences Switzerland	Q2

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
P2	8	Psychometric evidence of the academic stressors scale in Peruvian university students in the context of COVID-19	Serpa-Barrientos, A., Tito-Huamani, P. L., Campos, L. A. G., & Quijaite, J. J. S.	2022	Perú	Publicaciones de la Facultad de Educación y Humanidades Del Campus de Melilla	Q4
	9	A contextual hierarchical attention network for detecting mental health disorders using social media	Hochstenbach, R., Frasincar, F., & Klinkhamer, J.	2026	Países Bajos	Data and Knowledge Engineering	Q1
	10	Machine learning approaches to identifying neurodevelopmental disorders using social media data: a systematic review	Mohammad, S. R., Kadaei, F., & Mohkam, M.	2026	Irán	International Journal of Medical Informatics	Q1
	11	Deep-AP: An efficient multi-task architecture for Author Profiling and Depression Detection	Oulahbib, I., Benhaddi, M., & El Hadaj, S.	2026	Marruecos	Scientific African	Q1
	12	Utilizing large language models and natural language processing to classify ischemia status from cardiac stress tests in a large multicenter healthcare system	Cave, S., Peterson, K. S., Plomondon, M. E. y Waldo, S. W.	2026	Estados Unidos	BMC Research Notes	Q3

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	13	A Multimodal Dataset for Assessing Emotion, Stress, and Emotional Workload in Interpersonal Work Scenario	Lee, D., Park, E., Kim, G., Han, Y., & Lee, U.	2026	Corea del Sur	Scientific Data	Q1
	14	Deep learning-based intelligent assessment and early warning system for employee mental health status	Wang, Y., Wang, Z., Fan, S., Wang, X., Zhang, Y., & Zhang, Z.	2026	China	Discover Artificial Intelligence	Q1
	15	Machine learning methods for detecting depression in Arabic tweets: a comprehensive performance analysis with enhanced evaluation metrics	Alkasem, H., Alsalamah, A., Alhussan, L., Alzahrani, N., & Abalkhail, S.	2026	Arabia Saudita	Discover Artificial Intelligence	Q1
	16	A hybrid explainable machine learning and transformer-based framework for psychological stress detection in women's social media narratives	Ramya, V. J. y Manu, Y. M.	2026	India	Discover Artificial Intelligence	Q1
	17	Enhancing the conversational agent with an emotional support system for mental health digital therapeutics	Wang, Q., Peng, S., Zha, Z., Han, X., Deng, C., Hu, L., & Hu, P.	2023	China	Frontiers in Psychiatry	Q1
P3							

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	18	Increasing engagement with cognitive-behavioral therapy (CBT) using generative AI: a randomized controlled trial (RCT)	McFadyen, J., Habicht, J., Dina, L.-M., Harper, R., Hauser, T. U., & Rollwage, M.	2026	Reino Unido	Communications Medicine	Q1
	19	A Serious Game for Emotion Regulation in Adolescents: Player Experience and Pilot Feasibility Study	Mittmann, G., Barnard, A., Zehetmayer, S., Wimmer, S., Zehetner, V., Doerfler, S., Woodcock, K., & Schrank, B.	2024	Austria	International Journal of Game-Based Learning	Q2
	20	Digital Interventions for Emotion Regulation in Children and Early Adolescents: Systematic Review and Meta-analysis	Reynard, S., Dias, J., Mitic, M., Schrank, B., & Woodcock, K. A.	2022	Reino Unido	JMIR Serious Games	Q1
	21	Effect of the "Art Coloring" Online Coloring Game on Subjective Well-Being Increase and Anxiety Reduction During the COVID-19 Pandemic: Development and Evaluation	Xi, J.Z., Gao, Y.H., Lyu, N., She, Z., Wang, X.Y., Zhang, X.A., Yu, X.Y., Ji, W.D., Wei, M.S., Dai, W.H., & Qian, X.	2022	China	JMIR Serious Games	Q1
	22	AI-enhanced, digital psychosocial interventions for pediatric	Salahshoor, S., & Renbarger, K. M.	2026	Estados Unidos	Journal of Pediatric Nursing	Q1

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
P4		developmental disabilities: A scoping review					
	23	Co-Designed Mental Health Screening App (Here for You) for University Students: Pilot Feasibility Mixed Methods Study	Singh Sethi, M. I., Manickam, T., Chakraborty, T., & Bada Math, S.	2026	India	JMIR Formative Research	Q2
	24	Development of "LvL UP 1.0": a smartphone-based, conversational agent-delivered holistic lifestyle intervention for the prevention of non-communicable diseases and common mental disorders	Castro, O., Mair, J. L., Salamanca-Sanabria, A., Alattas, A., Keller, R., Zheng, S., Jabir, A., Lin, X., Frese, B. F., Lim, C. S., Santhanam, P., van Dam, R. M., Car, J., Lee, J., Tai, E. S., Fleisch, E., von Wangenheim, F., Tudor Car, L., Müller-Riemenschneider, F., & Kowatsch, T.	2023	Singapur	Frontiers in Digital Health	Q1
P4	25	EMLSCF-FCH: A Secure and Efficient Machine Learning-Based Framework for Fog Computing in Healthcare	Kannan, N., & Balasubramanian, K.	2026	India	International Journal of Computational Intelligence Systems	Q1

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	26	Artificial intelligence methods for enhancing cybersecurity in Oman: a comprehensive review	Alnaabi, A. A. H., & Al Mahruqi, A. A. H.	2026	Oman	Journal of Cloud Computing	Q1
	27	Trustfed a scalable privacy preserving federated AI framework for industrial IoT healthcare and finance	Murala, D. K., K., M., Vuyyuru, V. A., Rao, K. V. P., & Hitimana, E.	2026	India	Discover Internet of Things	Q1
	28	Adaptive AI-driven framework for digital mental health interventions in low-resource universities	Baena-Navarro, R., Carriazo-Regino, Y., Crawford-Vidal, R., Fernández-Arango, A., & Barreiro-Pinto, F.	2026	Colombia	Bulletin of Electrical Engineering and Informatics	Q3
	29	SocialBullyAlert: A Web Application for Cyberbullying Detection on Minors' Social Media	Nina-Gutiérrez, E. A., Pacheco-Alanya, J. E., & Morales-Arevalo, J. C.	2024	Perú	International Journal of Advanced Computer Science and Applications	Q3

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista		Cuartil
	30	"First, do no harm" in the digital era: examining the practicality of the European Health Data Space proposal and ethical implications of artificial intelligence - A systematic literature review	Mateus, M., Alho, I., Neves, A. L., Lopes, H., & Correia, M.	2026	Portugal	BMC Ethics	Medical	Q1
	31	Systematic Review on AI-Based Diagnosis and Appointment Management in Under-Digitalized Healthcare	Meneses Ayala, A. Y., Quispe Mamani, J. E., & Rada Mota, L. C.	2025	Perú	Proceedings of the LACCEI International Multi Conference		Conference paper
	32	Systematic review on the inclusion of technological tools in the Health Sector Supply Chain (CSSS)	Castillo-Arce, A., Patrick Sanchez-Zavalaga, H., Nuñez-Bardales, K., Obregon-Tinoco, H., & Bazan-Aguilar, A.	2025	Perú	Proceedings of the LACCEI International Multi Conference		Conference paper
P5	33	Mobile Application for Managing Anxiety using Machine Learning Model	Alexandra, A. M. M., Gabriel, G. D. C., & Elio, N. v.	2025	Perú	2025 Cognitive Models and Artificial Intelligence Conference	3rd	Conference paper

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	34	FocusED: An NLP-Driven Personalized and Affective-Aware Learning Framework for Neurodivergent Students	Gayathri, C., TV, Y. Krishnan., Kumar, S. S., Poovarasan, K., & Vel, M. S. H.	2026	India	2026 International Conference on Smart Electronic Devices (ICSEDIS)	Conference paper
	35	NeuroPhysio: Explainable EEG-Based AI for Affective and Cognitive Load Recognition in Digital Health-Integrated Learning Systems	Reddy, A. R., Veerasingam, S., & Begum, B. S.	2026	India	IEEE Transactions on Affective Computing	Q1
	36	Tampu: Mobile Application Using Wearable Technology for Real-Time Detection and Alert of Anxiety and Panic Attacks in University Students	Curi, I. C., Quispe, E. Y., & Lopez, N. B.	2025	Perú	Proceedings of the 2025 IEEE 5th International Conference (ICALTER)	Conference paper
	37	A Scalable System Architecture for Composition and Deployment of Machine Learning Models in Cognitive Behavioral Therapy	Schmidt, F., Kurzawski, M. G., Hammerfald, K., Jahren, H. H., Solbakken, O. A., & Vlassov, V.	2024	Suecia	IEEE International Conference on Digital Health (ICDH)	Conference paper

Pregunta de Investigación	#	Título de artículo	Autor	Año de publicación	País de Autor	Nombre de revista	Cuartil
	38	AI-enabled Vision Attentive System for Detection of Emotional Anxiety and Digital Fatigue among University Students	Gunawardhana, A. G. M. S., Madhubhashini, G. G. K. N., Herath, H. M. K. K. M. B., & Yasakethu, S. L. P.	2025	Sri Lanka	10th International Conference on Information Technology Research (ICITR)	Conference paper
	39	Automatic Detection of Twitter Users Who Express Chronic Stress Experiences via Supervised Machine Learning and Natural Language Processing	Yang, Y. C., Xie, A., Kim, S., Hair, J., Al-Garadi, M., & Sarker, A.	2023	Estados Unidos	CIN: Computers, Informatics, Nursing	Q2
	40	A school-setting pilot study of the e-learning version of the "Journey of the Brave": a universal anxiety-prevention program based on cognitive behavioral therapy	Ohashi, S., Urao, Y., Fujiwara, K., Koshiba, T., Ishikawa, S., & Shimizu, E.	2025	Japon	Child and Adolescent Psychiatry and Mental Health	Q1

3.3.2 Resumen de Artículos Seleccionados

La presente sección documenta el análisis sistemático de los cuarenta artículos primarios que superaron los filtros de elegibilidad establecidos en la metodología. Con el propósito de mantener una trazabilidad rigurosa frente a los objetivos del estudio, la literatura ha sido vertebrada en torno a las cinco preguntas de investigación planteadas. Cada manuscrito se somete a un proceso de disección donde se aísla su contribución fundamental, la dimensión sociotécnica o clínica del problema, el herramental analítico empleado y sus resultados empíricos definitivos. Este ordenamiento categorico obedece a una necesidad procedimental estricta: mapear las convergencias algorítmicas, desnudar las carencias metodológicas en la evaluación de la salud mental y evidenciar la brecha científica que justifica inequívocamente el diseño arquitectónico de nuestra plataforma basada en Machine Learning híbrido.

3.3.2.1 P1: ¿Qué factores y escalas caracterizan el tecnoestrés y la ansiedad digital en universitarios?

La literatura revisada deja ver un panorama diverso de modelos estructurales, estudios estadísticos y propuestas psicométricas que intentan capturar, desde distintos ángulos, el peso que el estrés tecnológico ejerce sobre la vida universitaria. Los entornos institucionales varían, las dimensiones medidas no siempre coinciden y los niveles de afectación psicológica reportados son heterogéneos, pero el patrón de fondo es reconocible. En el contexto peruano, los trabajos de López-Arnes y Javier-Ninahuaman (2023) y Reyes y Libaque-Saenz (2023) construyen su evidencia sobre ecuaciones estructurales para mostrar cómo las exigencias del entorno virtual y el clima organizacional terminan condicionando el rendimiento del estudiante. Los datos son contundentes: el primer estudio reporta que el 81% de los

universitarios experimenta estrés moderado, mientras el segundo documenta el efecto perjudicial directo que el tecnoestrés imprime sobre el desempeño académico.

A partir de ahí, una segunda línea de trabajos abandona el diagnóstico general y se concentra en algo más técnico construyendo y validando instrumentos psicométricos capaces de medir con precisión el desgaste en entornos virtuales. Serpa-Barrientos et al. (2022) adaptan transculturalmente la Escala de Estresores Académicos (ECEA) en una muestra de 866 universitarios de instituciones públicas y privadas, llegando a una estructura oblicua de siete factores. Norabuena-Figueroa et al. (2025) amplían ese horizonte trabajando con una base de 6605 estudiantes de la Universidad Nacional Mayor de San Marcos para validar las herramientas TPSVE y SASSEV. Lo que este último estudio aporta con claridad es que el diseño de las evaluaciones virtuales y la sobrecarga de trabajo estudiantil no son variables menores: actúan como estresores severos que deterioran la interacción docente-alumno.

El foco se afina aún más cuando la investigación se sitúa en Lima. Araya-Ugarte et al. (2025) validan transculturalmente la escala TS4US en una universidad privada de la capital y encuentran que el 28% de su muestra registra altos niveles de tecnoestrés y un 5% niveles muy altos, con la sobrecarga informativa como principal detonante. En paralelo, Vallejos-Flores et al. (2024) trabajan con 550 universitarios de Lima Metropolitana y, a través de un modelo de ecuaciones estructurales con las escalas C-SDS y SABAS, muestran cuantitativamente que la relación entre el tecnoestrés y la adicción al smartphone no es directa: la distracción cognitiva la media por completo.

Las investigaciones más recientes desplazan la mirada hacia herramientas emergentes y recursos personales, lo que abre una perspectiva crítica sobre los nuevos predictores de ansiedad. Acosta-Enriquez et al. (2025) aplican la escala ASADAS a 676 universitarios y, mediante un modelo PLS-SEM que explica el 58.9% de la varianza, determinan que el estrés

académico actúa como mediador significativo entre la autoeficacia y la dependencia compulsiva a la inteligencia artificial. Este hallazgo dialoga con el de Estrada-Araoz et al. (2024), quienes en Puerto Maldonado aplican un modelo de regresión lineal múltiple y concluyen que la autoeficacia general y las estrategias de afrontamiento predicen de manera robusta el 27.3% de la satisfacción académica frente a las presiones del entorno.

Tomado en conjunto, este cuerpo de evidencia permite afirmar que el tecnoestrés y la ansiedad digital en universitarios peruanos son fenómenos multicausales: la sobrecarga informativa, la distracción por smartphones, las demandas de la virtualidad y la dependencia a herramientas automatizadas se entrelazan y se potencian mutuamente, y su medición descansa hoy en escalas validadas como TS4US, SASSEV y ASADAS. Sin embargo, hay un vacío que estos estudios no logran resolver: todos operan de manera reactiva y retrospectiva, recurriendo a cuestionarios transversales de autoinforme que, por definición, llegan tarde. Ninguno propone una arquitectura de software capaz de anticiparse en tiempo real. Frente a esa limitación, la plataforma TI basada en Machine Learning híbrido propuesta para Lima Metropolitana toma precisamente esos factores psicométricos validados como variables de entrada y los convierte en insumos de un sistema de detección continua, con el objetivo de intervenir antes de que el colapso emocional estudiantil se produzca.

Tabla 27

Resumen: Pregunta 1

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
Acosta-Enriquez et al. (2025).	Modelo de ecuaciones estructurales (PLS-SEM) y escala de evaluación adaptada y validada (ASAIIDAS) para medir la autoeficacia académica y dependencia a la IA.	Predictoras: Autoeficacia, estrés académico, pensamiento crítico y expectativas de rendimiento. Objetivo: Dependencia a la IA.	Análisis Factorial Exploratorio (AFE) y Confirmatorio (AFC), evaluando validez y fiabilidad con SmartPLS y Alfa de Cronbach.	El modelo explica el 58.9% de la varianza. El estrés académico media significativamente la relación, con un fuerte efecto directo de la autoeficacia.
López-Armes y Javier-Ninahuaman (2023)	Modelo de interacción de variables evaluado por la metodología de ecuaciones estructurales (SEM) fundamentado en el análisis factorial exploratorio.	Predictoras/dimensiones: Potencial humano, diseño organizacional, cultura, estresores, síntomas y estrategias de afrontamiento. Objetivo: Estrés académico general y clima organizacional.	Validación en software R integrando análisis de normalidad, correlación de Spearman, cargas factoriales y bondad de ajuste del modelo SEM.	El 81% de los estudiantes presentó niveles de estrés moderado. Existe una relación inversa, débil pero significativa, entre el estrés académico y el clima organizacional.
Estrada-Araoz et al. (2024)	Propuesta y validación de un modelo estadístico predictivo para comprender cómo ciertas variables psicológicas explican la satisfacción académica.	Predictoras: Afrontamiento al estrés y autoeficacia. Objetivo: Satisfacción académica.	Modelo de regresión lineal múltiple y análisis de correlación de Pearson evaluando bondad y coeficientes en SPSS.	El modelo explica el 27.3% de la varianza total de la satisfacción. La autoeficacia y el afrontamiento al estrés son fuertes predictores.
Araya-Ugarte et al. (2025)	Validación psicométrica, ajuste y adaptación transcultural de la escala TS4US para medir el tecnoestrés (modelo a 13	Predictoras (latentes): Recursos de Necesidades-Suministros (NSR) y Entorno Sociotécnico (STE). Objetivo: Medida de tecnoestrés.	Análisis Factorial Confirmatorio (AFC) a través del software FACTOR, ajustando umbrales y bondad de ajuste.	Excelente consistencia interna. El 28% padece altos niveles de tecnoestrés y un 5% niveles muy altos, sin asociaciones significativas con variables sociodemográficas.

Cita Bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas y Resultados
	ítems y 2 factores).			
Vallejos-Flores et al. (2024)	Modelo de ecuaciones estructurales que evalúa el efecto mediador de la distracción entre el tecnoestrés y la adicción a los teléfonos inteligentes.	Predictora: Tecnoestrés. Mediadora: Distracción. Objetivo: Adicción al smartphone.	Análisis Factorial Confirmatorio y modelamiento de ecuaciones estructurales en el software R (coeficientes alfa y omega).	El tecnoestrés tiene un efecto indirecto significativo sobre la adicción, mediado completamente por la distracción, perdiendo impacto directo.
Reyes y Libaque-Saenz (2023).	Modelo integral de investigación basado en ecuaciones estructurales (PLS-SEM) para identificar factores tecnológicos y humanos.	Predictoras: Tecnoestrés, calidad del instructor, calidad del sistema (disponibilidad, diseño web, facilidad de uso). Objetivo: Desempeño y satisfacción general.	Modelado utilizando SmartPLS evaluando validez y caminos estructurales con técnica de bootstrapping de 5000 submuestras.	Explica el 55.9% de la varianza en el desempeño y el 53.8% en la satisfacción. El tecnoestrés impacta perjudicialmente, mientras el soporte docente influye positivamente.
Norabuena-Figueroa et al. (2025)	Diseño y validación factorial robusta de escalas psicométricas complementarias (TPSVE y SASSEV) probadas mediante ecuaciones estructurales.	Predictoras: Dimensiones del desempeño docente. Objetivo: Estrés académico estudiantil.	Análisis Factorial Exploratorio y Confirmatorio a través de SPSS, R y AMOS.	Ajuste ideal innegable. La buena práctica docente no engendra estrés, pero sí sufre los impactos del estrés (ej. sobrecarga estudiantil frena la interacción).
Serpa-Barrientos et al. (2022).	Adaptación transcultural y medición de las evidencias psicométricas de la Escala de Estresores Académicos (ECEA) en modalidad virtual.	Predictoras (subyacentes): Exámenes, creencias sobre rendimiento o sobrecarga. Objetivo: Estrés académico multidimensional.	Análisis de estructura exploratorio (software FACTOR) y revisión confirmatoria para contrastar cuatro modelos jerárquicos (R Studio).	La configuración oblicua de 7 factores rinde el ajuste más representativo estadísticamente ($\chi^2/df= 0.121$; CFI= 0.999; TLI= 0.999; RMSEA= 0.020).

3.3.2.2 P2: ¿Qué algoritmos de PLN y Machine Learning son más precisos para clasificar trastornos afectivos?

La ciencia internacional ha seguido un camino relativamente claro en esto: partir de técnicas estadísticas convencionales e ir escalando, progresivamente, hacia taxonomías metodológicas cada vez más sofisticadas para inferir afecciones psicológicas a partir de datos digitales. Los primeros trabajos en esta dirección se mueven en un terreno más conocido. Rashti Mohammad et al. (2026) y Alkasem et al. (2026) atacan el problema de la detección diagnóstica con clasificadores de Machine Learning clásico y revisiones sistemáticas de la huella digital en plataformas como Twitter o Reddit, recurriendo a descriptores léxicos para mapear la conducta del usuario. Los resultados son más que competitivos: algoritmos como las Máquinas de Vectores de Soporte (SVM) y los modelos de ensamble tradicionales alcanzan puntuaciones F1 que van de 0.48 a 0.95 en la clasificación de patrones de depresión o desajustes del desarrollo.

Donde la cosa se complica es en la siguiente etapa. Los investigadores empezaron a diseñar arquitecturas profundas y modelos de aprendizaje multitarea, buscando reducir la carga computacional y capturar mejor las dependencias secuenciales a largo plazo en los textos. Hochstenbach et al. (2026) presentan Context-HAN, una arquitectura basada en redes de atención jerárquica que combina embeddings contextuales de BERT con autoatención multicabezal para procesar historiales lingüísticos informales en foros de discusión, y llega a un F1-score de hasta 0.69. En paralelo, Oulahbib et al. (2026) apuntan a un problema diferente pero igualmente relevante: la eficiencia. Su modelo Deep-AP usa un backbone de BERT-large para hacer perfilado demográfico del autor e inferencia binaria de estados depresivos de forma simultánea, consiguiendo un F1 de 0.881 para la depresión y recortando en un 66% el tiempo de inferencia frente a arquitecturas independientes. Nada despreciable.

La expansión del alcance semántico llega con la incorporación de textos especializados y señales en tiempo real. Cave et al. (2026) aplican variantes como ClinicalBERT sobre registros médicos no estructurados y demuestran la alta capacidad de abstracción de los Modelos de Lenguaje de Gran Escala (LLMs), obteniendo una métrica F1 de 0.927 en la clasificación automatizada de estados críticos. Wang et al. (2026) llevan esa misma lógica al entorno corporativo: proponen un sistema de alerta temprana que combina una red neuronal recurrente BiLSTM con un mecanismo de atención para analizar flujos de texto de chats laborales y predecir el riesgo de desgaste mental. El sistema alcanza una precisión del 89.3% y, lo que quizás es más valioso, logra emitir alertas preventivas con una ventana de adelanto de 5.6 días.

Los desarrollos más recientes apuestan por la fusión de fuentes heterogéneas y los ensambles híbridos. Lee et al. (2026) introducen el dataset multimodal EmoWork y, mediante validación cruzada, demuestran que combinar el procesamiento lingüístico de audios y textos con biosensores en clasificadores como Random Forest eleva el AUC a 0.783 para la detección de estrés. Ramya y Manu (2026) van un paso más allá: construyen un framework explicable basado en fusión tardía y generalización apilada que usa una Regresión Logística como meta-learner para orquestar las fronteras de decisión de algoritmos léxicos clásicos (Random Forest) y semánticos profundos (BERT), alcanzando un rendimiento del 99% de precisión global.

Recapitulando, lo que muestra esta revisión es que las técnicas de PLN más efectivas combinan la comprensión semántica profunda de variantes BERT o Transformers con clasificadores robustos organizados en redes de ensamble o arquitecturas concurrentes BiLSTM. Pero hay un problema que los datos no ocultan: los modelos de mayor rendimiento muestran un riesgo serio de sobreajuste cuando se entrenan sobre datasets pequeños

sobremuestreados artificialmente, arrastran sesgos culturales propios de la lengua y los contextos en que fueron entrenados, y exigen una latencia computacional que dificulta su despliegue real en infraestructuras universitarias estándar. Precisamente ahí se justifica la propuesta de esta plataforma TI basada en Machine Learning híbrido con técnicas de Voting: integrar el procesamiento semántico calibrado al argot estudiantil de Lima Metropolitana con un ensamble de Voting de baja carga computacional, haciendo posible un monitoreo continuo, preciso y eficiente en condiciones reales de uso.

Tabla 28

Resumen: Pregunta 2

Cita bibliográfica en APA7	Aporte	Variables	Modelo	Métricas y Resultados
Hochstenbach et al., 2026	Modelo Context-HAN que incorpora información contextual para perfilar trastornos mentales en textos de Reddit.	Textos, embeddings (GloVe/BERT), frecuencias de stopwords y léxicos (LIWC/NRC).	Context-HAN (Embeddings de BERT + Autoatención multicabezal jerárquica).	Context-HAN superó al modelo base logrando un F1 de 0.56, 0.69 y 0.55 para autolesiones, anorexia y depresión respectivamente. Su AUC llegó hasta 0.93.
Rashti Mohammad et al., 2026	Revisión sistemática de enfoques ML para identificar trastornos del neurodesarrollo usando huellas digitales de redes sociales.	Textos, comportamientos y videos extraídos de plataformas como Twitter, Reddit y YouTube.	Diversos algoritmos revisados, destacando SVM, Random Forest, CNN y Redes Neuronales.	Los modelos lograron métricas F1 entre 0.48 y 0.89 para autismo, y hasta 0.86 para TDAH. La precisión varió del 71% al 96.9% según la modalidad.
Oulahbib et al., 2026	Deep-AP, arquitectura multitarea unificada para inferir edad o género a nivel autor y depresión a nivel publicación.	Tokens de texto limpios de foros de Reddit y embeddings de nombre de usuario.	Deep-AP y Deep-AP-uname (Backbone BERT-large con cabezales MLP compartidos).	Usando BERT-large, logró un F1 de 0.914 (género), 0.717 (edad) y 0.881 (depresión). Redujo el tiempo de inferencia en 66% y la memoria en 40%.

Cita bibliográfica en APA7	Aporte	Variables	Modelo	Métricas y Resultados
Cave et al., 2026	Sistema de NLP para extraer e identificar estados de isquemia desde informes médicos no estructurados del VHA.	Informes de pruebas de estrés cardíaco (impresiones médicas de texto libre).	ClinicalBERT, DistilBERT, y un sistema de NLP basado en reglas (medspaCy).	ClinicalBERT: F1 de 92.7% (Precisión 86.4%, Recall 100%).Reglas: F1 de 92.5% (Precisión 88.1%, Recall 97.4%).
Lee et al., 2026	Dataset multimodal EmoWork para evaluar estrés y carga emocional en entornos laborales simulados de centros de llamadas.	Fisiológicas (ECG, BVP, EDA), y conductuales (prosodia en audio y movimiento en video).	Random Forest, SVM, XGBoost, kNN, Árboles de Decisión (para validar el dataset).	Random Forest logró un AUC de 0.946 para distinguir el entorno laboral agresivo, un AUC de 0.783 para estrés y 0.739 para supresión emocional.
Wang et al., 2026	Sistema inteligente de alerta temprana para la salud mental de empleados, capaz de monitoreo dinámico y en tiempo real.	Texto de chats laborales, fisiológicas (sensores y wearables) y comportamiento.	BiLSTM con mecanismo de atención integrado.	Accuracy 89.3%, F1 macro 91.3%, AUC 94.5% y un MAE de 90.1%. Proporcionó un tiempo de ventaja de alerta temprana de 5.6 días.
Alkasem et al., 2026	Dataset ArabMindGuard (AMG) y una rigurosa evaluación de métodos ML sobre dialectos árabes para detección de depresión temprana.	Patrones textuales extraídos mediante N-gramas y vectores TF-IDF de tuits.	9 clasificadores evaluados: Regresión Logística, Random Forest, SVM, Voting, KNN, etc.	Los mejores modelos fueron SVM y métodos de ensamble, logrando un F1 entre 0.82 y 0.95 (hasta 0.949 con el dataset multidiomático de Nassar).
Ramya & Manu, 2026	Marco híbrido y explicable combinando procesamiento léxico y semántico para medir estrés en narrativas digitales femeninas.	Vectores TF-IDF dispersos y embeddings contextuales profundos de Reddit y X.	Ensamble generalizado apilado (Regresión Logística como meta-learner sobre Random Forest y BERT).	El modelo híbrido superó las corrientes individuales con una precisión del 99%, un F1 de 0.99 y un ROC-AUC perfecto de 1.00.

3.3.2.3 P3: ¿Cómo influyen las plataformas web o móviles y la gamificación en la regulación emocional del usuario?

Las revisiones sistemáticas y los meta-análisis disponibles trazan un mapa bastante claro de hacia dónde se dirige la investigación sobre intervenciones digitales e inteligencia artificial aplicadas a la regulación psicofisiológica. Reynard et al. (2022) parten de 39 estudios independientes y calculan, mediante la *g* de Hedges, que los juegos serios digitales logran reducir de forma estadísticamente significativa la experiencia emocional negativa, con resultados especialmente notorios cuando se añaden arquitecturas de retroalimentación neuronal mediante neurofeedback EEG. Salahshoor y Renbarger (2026), por su parte, completan ese panorama con una scoping review bajo directrices PRISMA-SCR que organiza los soportes psicosociales en tres pilares: agentes conversacionales basados en Procesamiento de Lenguaje Natural (PLN), sistemas de retroalimentación adaptativa, y módulos de reconocimiento de emociones por visión artificial y voz. Lo que ambos estudios comparten es la constatación de tasas de abandono elevadas en plataformas tradicionales, atribuibles tanto a la incomodidad de los sensores físicos como a desajustes de vocabulario en el procesamiento lingüístico. La conclusión es la misma: hay que diseñar interfaces más intuitivas y personalizadas.

Frente a ese problema de retención, la gamificación y los estímulos terapéuticos no intrusivos integrados en entornos lúdicos han mostrado resultados concretos. Mittmann et al. (2024) desarrollan el juego serio *School Can Be a Nightmare* mediante co-diseño interdisciplinario y constatan mejoras estadísticamente significativas en la regulación emocional personal (pER) tras las sesiones de juego, con una puntuación de usabilidad de 3.69 sobre 5 en la escala GUESS-GA-18. En una dirección similar, pero a mayor escala, Xi et al. (2022) insertan un paquete terapéutico de cromoterapia dentro de la aplicación

comercial Art Coloring y demuestran empíricamente que los usuarios expuestos a estímulos visuales de la categoría "asombro" (awe) mejoran de forma conjunta y robusta tanto el bienestar subjetivo como la reducción de la ansiedad. Ahora bien, ninguno de los dos estudios es completamente optimista: Mittmann et al. (2024) advierten que la exposición prolongada en solitario genera fatiga cognitiva, y Xi et al. (2022) constatan que estímulos mal calibrados pueden provocar efectos adversos. Ambas advertencias apuntan en la misma dirección: las micro-intervenciones deben ser breves y adaptativas.

En el terreno de las plataformas de salud móvil (mHealth) dirigidas a universitarios, el diseño participativo y los marcos preventivos holísticos han ganado terreno con respaldo empírico. Singh Sethi et al. (2026) validan la aplicación Here for You, concebida bajo un marco colaborativo cuatripartito que integra la escala DASS-21 con supervisión clínica continua; los resultados hablan por sí solos: una aceptabilidad técnica promedio de 4.4 sobre 5 en la escala UMARS y una validez concurrente muy sólida frente a estándares médicos de oro. Castro et al. (2023) presentan una apuesta diferente con LvL UP 1.0, un ecosistema móvil estructurado bajo la estrategia de optimización multifase (MOST) que aborda la salud física y mental de forma integrada, prescindiendo de incentivos financieros convencionales y sustituyéndolos por narrativas animadas e interactivas y adaptaciones culturales profundas pensadas para superar las barreras de adherencia de la población objetivo.

El escalón tecnológico más alto lo ocupan los asistentes conversacionales avanzados y los modelos generativos, que han empezado a ofrecer soporte psicológico dinámico en tiempo real con garantías de seguridad clínica. Wang et al. (2023) introducen el agente STEF, que incorpora un mecanismo de fusión emocional y un codificador de tendencia de estrategia capaces de analizar el historial del diálogo a lo largo de múltiples turnos; el sistema supera a los modelos del estado del arte en diversidad lingüística (D-2 de 23.00) y vence a la

arquitectura estática BlenderBot-Joint con un 60.7% de victorias humanas en capacidad de consuelo. McFadyen et al. (2026) aportan otro dato difícil de ignorar: en un ensayo controlado aleatorizado (RCT) con 540 participantes, el uso de IA generativa en la aplicación Limbic Care multiplica por 2.4 la frecuencia de participación y por 3.8 la duración de uso frente a los materiales de control convencionales; además, presentan el diseño de una "capa cognitiva" que actúa como filtro de seguridad algorítmica para garantizar respuestas terapéuticas clínicamente apropiadas y libres de alucinaciones.

Lo que deja ver esta evidencia, en su conjunto, es que las intervenciones móviles que combinan gamificación, narrativas inmersivas, co-diseño clínico y asistentes conversacionales empáticos mejoran sustancialmente la adherencia y mitigan la sintomatología ansiosa y depresiva. Pero hay un límite claro que los sistemas evaluados no logran superar: operan en su mayoría de forma reactiva ante el autoinforme del usuario, se apoyan en reglas heurísticas estáticas o resultan costosos de desarrollar y mantener por su rigidez arquitectónica. Ese vacío es exactamente el que justifica el diseño de la plataforma TI basada en Machine Learning híbrido propuesta para universitarios de Lima Metropolitana. La propuesta toma lo que ha funcionado, las interfaces móviles lúdicas y la psicoeducación digital estructurada (iCBT), e incorpora un ensamble de Voting de baja latencia que procesa de forma adaptativa las variables del tecnoestrés, automatizando el soporte emocional de manera proactiva, segura y ajustada a la realidad lingüística local.

Tabla 29

Resumen: Pregunta 3

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
Wang et al. (2023)	Creación del agente STEF, un chatbot de soporte emocional basado en IA que integra un mecanismo de fusión emocional y un codificador de tendencia de estrategia para evaluar múltiples turnos de diálogo.	Emoción del paciente, intención semántica, estrategia de apoyo, estados mentales históricos y actuales.	Redes neuronales basadas en el modelo generativo <i>Blenderbot-small</i> y el generador de sentido común <i>COMET</i> .	Automáticas: Perplejidad (PPL), Distinct-2, BLEU, ROUGE-L, Precisión (ACC). Humanas: Fluidez, identificación del problema, consuelo, sugerencias.	STEF demostró superioridad frente a modelos de la competencia, obteniendo el mejor puntaje en diversidad (D-2 de 23.00) y superando a BlenderBot-Joint en capacidad de consuelo (60.7% de victorias).
McFadyen et al. (2026)	Desarrollo de "Limbic Care", una app de IA generativa para Terapia Cognitivo-Conductual (TCC) que utiliza una "capa cognitiva" como filtro de seguridad algorítmica para evitar alucinaciones.	Interacción del usuario, nivel de ansiedad, nivel de depresión, seguridad clínica, deterioro funcional y calidad del sueño.	IA Generativa (LLMs) combinada con Aprendizaje Automático (ML) tradicional.	Frecuencia y duración de uso, GAD-7 (Ansiedad), PHQ-9 (Depresión), informes de eventos adversos (Seguridad).	La app con IA logró 2.4 veces más apertura y 3.8 veces más tiempo de uso que el grupo de control. Redujo significativamente la ansiedad y depresión, probando ser 100% segura.
Mittmann et al. (2024)	Creación del juego serio "School Can Be a Nightmare", diseñado para enseñar psicoeducación y entrenar la regulación emocional interpersonal en adolescentes mediante un entorno lúdico.	Regulación emocional personal (pER) e interpersonal (iER), gratificación, y usabilidad de la interfaz.	Aventura interactiva <i>RPG Maker MV</i> diseñada mediante codiseño participativo o interdisciplinario.	Usabilidad/Satisfacción (GUESS-GA-18), Regulación Emocional Personal e Interpersonal (escala EROS pretest-postest).	Aumentó de forma significativa la regulación emocional personal (pER) y tuvo alta satisfacción de los usuarios. Sin embargo, la regulación interpersonal (iER) decreció por fatiga cognitiva tras 3h de juego.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
Reynard et al. (2022)	Meta-análisis que consolida 39 estudios de intervenciones digitales para la regulación emocional en jóvenes, identificando la superioridad del neurofeedback.	Experiencia emocional negativa, habilidades de regulación emocional, tasas de abandono (dropout).	Meta-análisis (estadística de modelos de efectos aleatorios) bajo directrices PRISMA.	g de Hedges para medir tamaños de efecto (eficacia), índice I^2 (heterogeneidad) y tasas de abandono.	Los juegos digitales con arquitecturas de biometría EEG redujeron significativamente la ansiedad (g de Hedges = -0.19), aunque las tasas de abandono en la población clínica fueron altas.
Xi et al. (2022)	Inyección de un módulo gamificado de cromoterapia (asombro, azul, rosa, naturaleza) en una app móvil de coloreo masiva con 1.5 millones de descargas.	Bienestar subjetivo (SWB), estado de ansiedad, y eficacia subjetiva percibida (SE).	Intervención experimental naturalista sobre un juego comercial.	Escala "Face Scale" (SWB de 1 a 7), autoinforme Likert para ansiedad y evaluación de eficacia subjetiva.	Las imágenes de "asombro" incrementaron sustancialmente el bienestar subjetivo y redujeron la ansiedad. Paradójicamente, las imágenes de color rosa disminuyeron el bienestar de los jugadores.
Salahshoor & Renbarger (2026)	Clasificación arquitectónica de los sistemas de IA para soporte psicosocial pediátrico en tres pilares: Procesamiento de Lenguaje Natural, Visión por Computadora y Neurofeedback.	Tipología algorítmica IA, vocabulario/regulación emocional, desafíos técnicos y calidad de vida.	Revisión exploratoria estructurada (<i>Scoping Review</i> bajo directrices PRISMA-ScR).	Extracción cualitativa y temática de eficacia frente a errores técnicos y sesgos algorítmicos de los sistemas evaluados.	Los agentes conversacionales y neurofeedback mejoraron la interacción y calma pediátrica, pero la viabilidad falló por desajustes en el diccionario del bot y la incomodidad de sensores físicos.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
Sethi et al. (2026)	Desarrollo de la app "Here for You" co-diseñada con estudiantes indios, implementando la escala clínica DASS-21 con medidas de seguridad robustas (human-in-the-loop y privacidad AES-256).	Gravedad de síntomas (depresión, ansiedad, estrés), usabilidad del sistema e interacción con botones de seguridad.	Aplicación móvil (<i>Flutter</i> / <i>Firebase</i>) concebida por diseño participativo o cuatripartito y métodos mixtos.	Coeficiente de correlación de Pearson (r) frente al estándar de oro médico, usabilidad (UMARS) y porcentaje de uso.	Alta precisión diagnóstica ($r > 0.81$), excelente nivel de usabilidad técnica (4.4 de 5) y altísimo uso de la protección de privacidad (90% utilizó el botón de "salida rápida").
Castro et al. (2023)	Desarrollo del ecosistema móvil "LvL UP 1.0", una intervención holística preventiva guiada por IA para tratar cuerpo y mente mediante dinámicas de gamificación sin recompensas monetarias.	Engagement continuo, actividad física (Move More), dieta (Eat Well) y bienestar mental (Stress Less).	Estrategia de Optimización Multifase (MOST) adaptada al motor de software <i>Mobile Coach</i> .	Viabilidad técnica (engagement), adopción, efectividad clínica preliminar y satisfacción del usuario (fase de evaluación).	Se construyó con éxito el prototipo con adaptaciones culturales locales (Singapur). El sistema logró integrar técnicas motivacionales (como <i>storytelling</i>) para abarcar poblaciones socioeconómicamente vulnerables.

3.3.2.4 P4: ¿Qué arquitecturas tecnológicas garantizan la seguridad y privacidad de los datos en salud digital?

Buena parte de la literatura reciente sobre digitalización en salud converge en un punto: antes de desplegar cualquier sistema inteligente, hay que resolver las preguntas de gobernanza, ética e infraestructura de seguridad. Mateus et al. (2026) lo abordan desde el lado regulatorio, evaluando con la herramienta JBI la viabilidad del Espacio Europeo de Datos Sanitarios (EHDS) y la Ley de IA de la UE, y dejando claro que la clasificación por niveles de riesgo y la transparencia algorítmica no son opcionales si se quiere dismantelar el fenómeno de la

"caja negra" en el diagnóstico digital. Meneses Ayala et al. (2025) y Castillo-Arce et al. (2025) completan ese cuadro desde otro ángulo: mediante mapeos bibliométricos y cualitativos estructurados bajo la metodología PRISMA y la herramienta PICOC, sistematizan las brechas más críticas de los entornos sub-digitalizados y argumentan con solidez que la convergencia de herramientas distribuidas aporta la trazabilidad, la inmutabilidad y la transparencia que los flujos tradicionales de información médica simplemente no tienen.

El siguiente problema es técnico y muy concreto: el ancho de banda se satura y la latencia de la nube central penaliza los sistemas que necesitan respuesta rápida. Para resolverlo, varios equipos han desarrollado marcos de computación perimetral (*fog/edge computing*) pensados para dispositivos de bajo consumo. Kannan y Balasubramanian (2026) presentan la arquitectura EMLSCF-FCH, que procesa los datos localmente mediante una Regresión Lineal Mejorada (ELR) gobernada por el Algoritmo de Optimización del Efecto Loto (LEA), encapsula los datos biomédicos ruidosos en contratos inteligentes distribuidos y consigue reducir el tiempo de diagnóstico a 95 milisegundos con una robustez de seguridad simulada del 98.34%. Baena-Navarro et al. (2026) trabajan en una dirección similar pero dirigida específicamente al ecosistema universitario con limitaciones tecnológicas severas: su marco AMRIA-U combina modelos de Filtrado Colaborativo Neuronal (NCF) y Redes Amplias y Profundas para ejecutar el diagnóstico de padecimientos emocionales directamente en el smartphone del estudiante, de forma completamente offline, aligerando la carga sobre la RAM y eliminando la dependencia de conexión continua a internet.

La privacidad de los registros médicos durante el entrenamiento de modelos de IA es otro frente que la literatura ha abordado con creciente sofisticación, principalmente a través del aprendizaje federado y las técnicas de anonimización matemática. Murala et al. (2026)

desarrollan TrustFed, una plataforma orientada a microservicios que descompone el Aprendizaje Federado (FL) e incorpora una capa de ruido basada en Privacidad Diferencial Gaussiana combinada con codificación de conocimiento seguro de punto fijo. Cuando se escala a 50 nodos heterogéneos, TrustFed mitiga de forma efectiva los ataques de inferencia y envenenamiento del modelo, mantiene una precisión del 92.5% y reduce la sobrecarga de red frente a algoritmos clásicos como FedAvg o FedProx. Baena-Navarro et al. (2026) convergen con este enfoque desde otro ángulo: integran Redes Generativas Antagónicas (GAN) para generar historiales sintéticos seguros y recurren al Aprendizaje Federado como mecanismo de protección que permite compartir únicamente el conocimiento abstracto entre servidores institucionales, sin exponer la identidad primaria de los usuarios.

Cerrando el recorrido, los trabajos más recientes evalúan cómo todo esto funciona —o deja de funcionar— cuando se lleva a la práctica. Alnaabi y Al Mahruqi (2026) formulan el marco nacional OCAIF sobre las teorías de adopción TOE y DOI, y demuestran mediante regresión ($R^2=0.78$) que la efectividad de la ciberseguridad no depende solo de la tecnología sino también de factores normativos, organizacionales y del grado en que las herramientas —incluido el procesamiento de lenguaje natural local— han sido nacionalizadas. Nina-Gutiérrez et al. (2024) bajan aún más al terreno concreto con SocialBullyAlert, una aplicación centinela multiplataforma que conecta peticiones asíncronas a través de una API REST en Spring Boot, bases de datos PostgreSQL y un frontend en Angular/Firebase optimizado con las heurísticas de usabilidad de Nielsen; los resultados del test UEQ superan 1.5 en todas las dimensiones evaluadas.

Lo que muestra esta revisión, en suma, es que las arquitecturas más eficientes para garantizar seguridad y privacidad en salud digital se articulan sobre microservicios modulares descentralizados, computación en la niebla y aprendizaje federado con privacidad

diferencial. Pero hay un límite recurrente que los estudios no logran esquivar del todo: las soluciones con mayor blindaje suelen depender de servicios cognitivos de terceros que generan *vendor lock-in* y comprometen la soberanía de los datos, operan en entornos puramente teóricos, o introducen una sobrecarga criptográfica tan alta que deteriora los tiempos de respuesta en dispositivos periféricos estándar. Ese vacío es el que le da sustento a la propuesta de esta plataforma TI basada en Machine Learning híbrido con técnicas de Voting para universitarios de Lima Metropolitana. El proyecto adopta desde su código base una postura de "Ética por Diseño": un ensamble ligero auto-hospedado en local que garantiza la inmutabilidad de la información confidencial sobre ansiedad digital, procesa el lenguaje local sin depender de APIs externas y mantiene la latencia predictiva dentro de rangos operativos reales sin penalizar el hardware disponible.

Tabla 30

Resumen: Pregunta 4

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
N. Kannan y K. Balasubramanian (2026)	Desarrollo de la arquitectura EMLSCF-FCH, un sistema de aprendizaje automático seguro y eficiente para computación en la niebla orientado a la salud, que integra predicción clínica (ELR+LEA) con seguridad basada en Blockchain.	Costo computacional, un sobrecarga de comunicación, robustez de seguridad, precisión de predicción y monitoreo tiempo real.	Regresión Lineal Mejorada (ELR) de optimizada con Algoritmo de Optimización en el Efecto Loto (LEA) + Blockchain y criptografía.	Automáticas: Costo de computación (ms y %), sobrecarga de comunicación (%), robustez de seguridad (%), precisión de predicción (%), monitoreo tiempo real (%).	EMLSCF-FCH superó a modelos clásicos: diagnóstico en 95 ms (vs. 150 ms), eficiencia de comunicación 96.58%, precisión de predicción 99.05%, robustez de seguridad en 98.34%.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
Almoatasem A. H. Alnaabi y Ali A. H. Al Mahruqi (2026)	Propuesta del Marco de Ciberseguridad con IA de Omán (OCAIF), hoja de ruta de seis pilares adaptada al contexto omaní y del Golfo para integrar IA en la ciberseguridad nacional.	Adopción de IA, efectividad en ciberseguridad, barreras de implementación (talento, infraestructura, regulación, silos de datos).	Métodos mixtos: IA generativa, ML no supervisado (k-means clustering), PNL en árabe, Aprendizaje Federado + marco TOE y Teoría DOI.	Cuantitativas: Media, Desviación Estándar, T-Test, ANOVA, R^2 , valor p, coeficiente Beta, frecuencias (n). Cualitativas: Alfa de Cronbach (>0.70), comprobación de miembros (90%).	Correlación alta entre adopción de IA y efectividad ($R^2=0.78$). Brecha de implementación: conciencia alta (Media=4.22) vs. beneficios reales limitados (Media=3.85). Principales barreras: escasez de talento (87%), silos de datos (80%), infraestructura heredada (73%).
Dileep Murala et al. (2026)	Desarrollo de TrustFed, marco de IA federada con preservación de privacidad para IIoT, que combina Privacidad Diferencial con codificación de punto fijo en arquitectura Edge-Cloud modular.	Privacidad (ϵ , δ), rendimiento predictivo (accuracy, loss, F1), sobrecarga de comunicación, escalabilidad (hasta 50 nodos).	Aprendizaje Federado (FedAvg) + Privacidad Diferencial (ruido gaussiano) + redes convolucionales profundas (ResNet-50 y LCNN) en arquitectura de microservicio s.	Presupuesto de privacidad (ϵ), probabilidad de fallo (δ), escala de ruido (σ), Accuracy, Loss, Precisión, Recall, F1-Score, tiempo de entrenamiento (min), costo de comunicación (MB).	ResNet50 logró precisión de entrenamiento 99% y validación 94.7%. Con TrustFed ($\epsilon > 0.2$), precisión competitiva del 92-94%. A 50 nodos, superó a FedAvg y FedDP en ancho de banda y latencia.
Rubén Navarro et al. (2026)	Diseño del Marco Metodológico Adaptativo AMRIA-U, solución integral de IA ligera y offline para detección de salud mental en universidades con bajos recursos tecnológicos.	Tiempo de procesamiento, consumo de memoria, precisión predictiva (AUC), reducción sintomática (ansiedad), pérdida del modelo (MAE, entropía cruzada).	Filtrado Colaborativo Neuronal Adaptado (NCF) + Redes GAN adaptadas + Redes Amplias y Profundas + Aprendizaje Federado, diseñados para ejecución	Tiempo de procesamiento (segundos), consumo de memoria (MB), precisión predictiva (% y AUC), reducción sintomática (15-25% en ansiedad), métricas de pérdida (MAE, L1/L2).	Arquitecturas ligeras (NCF adaptado) demostraron tiempos de procesamiento mínimos y bajo consumo de memoria. Con GAN, pronósticos de estrés y soledad superiores al 80% sin acceso a la nube.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
			local y offline.		
Elizabeth Adriana Nina-Gutiérrez et al. (2024)	Desarrollo de SocialBullyAlert, aplicación web full-stack para detección de ciberacoso en redes sociales (TikTok, Instagram, Facebook) con Fine-Tuning en español peruano/chileno.	Interacción de menores en redes sociales, detección de contenido ofensivo, usabilidad (UX/UI), experiencia del usuario (padres).	LLM GPT-3.5 con Fine-Tuning para dialectos peruano/chileno + Google Cloud Vision API (OCR) + Web Scraping (Apify) + Backend API REST + Frontend Angular/Firebase.	Escala UEQ (User Experience Questionnaire): 6 dimensiones (Atractivo, Perspicuidad, Eficiencia, Fiabilidad, Estimulación, Novedad) en escala -3 a +3. Validación cualitativa de expertos.	Valores superiores a 1.5 en todas las escalas UEQ. La dimensión Atractivo obtuvo puntuación cercana a 2.0. Sistema considerado significativamente más usable que controles parentales existentes.
Margarida Mateus et al. (2026)	Revisión sistemática que evalúa la practicidad del Espacio Europeo de Datos Sanitarios (EHDS) y las implicaciones éticas de la IA en salud bajo el principio hipocrático de no maleficencia.	Transparencia algorítmica, sesgo en IA, privacidad de datos médicos, conformidad regulatoria (EU AI Act, EHDS), no maleficencia.	Revisión Sistemática de Literatura bajo directrices PRISMA, preregistrada en PROSPERO. Análisis cualitativo de 76 estudios con herramienta de evaluación crítica JBI.	Volumen de selección documental (653 → 76 estudios). Evaluación de riesgo de sesgo (JBI Checklist): Bajo riesgo >70%, Moderado 50-70%, Alto <50%.	El marco europeo (EU AI Act + EHDS) resulta efectivo para prevenir riesgos de IA no regulada. La transparencia exigida reduce drásticamente fallas de implementación frente a estudios previos menos regulados.
Adrian Yul Meneses Ayala et al. (2025)	Revisión Sistemática de Literatura (SLR) que categoriza seis tipos de sistemas inteligentes funcionales en entornos de salud con baja digitalización, con análisis bibliométrico mediante VOSviewer.	Barreras de digitalización (infraestructura, ética-legal, alfabetización digital), tipos de arquitecturas IA, precisión y eficiencia de algoritmos en entornos sub-digitalizados.	Revisión sistemática PRISMA con técnica PICOC. Análisis bibliométrico con VOSviewer. Categorización de 6 arquitecturas: IA explicable,	Volumen bibliométrico por año (pico en 2024), frecuencia de problemas citados (%), distribución de clústeres tecnológicos (6 tipos en 26 estudios finales).	La falta de infraestructura y sistemas predictivos son las principales brechas. Algoritmos ML ligeros generan impacto positivo en triaje. Valida enfoque de plataformas ligeras para contextos con recursos limitados.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
Alexis Castillo-Arce et al. (2025)	Taxonomía y mapeo bibliométrico del ecosistema tecnológico en la cadena de suministro de salud, clasificando herramientas en Hardware (RFID, Drones, 3D), Software (IA, Big Data, Cloud) y Mixtas (Blockchain, IoT).	Adopción tecnológica en la cadena de suministro de salud, barreras de implementación (resistencia al cambio, infraestructura, presupuesto, políticas).	IoT+IA, Modelos NLP conversacionales, entre otros. Metodología cualitativa de observación de l PRISMA con PICOC. Análisis bibliométrico de 63 artículos (Scopus y ScienceDirect, 2013-2023) con redes de co-ocurrencia.	Frecuencia absoluta de adopción por tecnología (Blockchain: 18 estudios, IA: 11). Cuantificación porcentual de impactos y barreras (ej. 50% considera clave; 80% señala riesgos en IoT).	Blockchain (18) e IA (11) dominan la literatura. La combinación IoT+Blockchain garantiza integridad de datos. La convergencia IA+Blockchain añade la capa de transparencia faltante en información médica.

3.3.2.5 P5: ¿Cómo optimizan los modelos de ensamble y la telemetría multimodal la detección de ansiedad en tiempo real?

Hay un consenso creciente en la literatura sobre esto, ya que al combinar sensores comerciales con algoritmos supervisados permite monitorear trastornos emocionales de forma preventiva con un nivel de precisión que hace unos años habría parecido optimista. Alexandra et al. (2025) ilustran bien este punto con "Kora", una aplicación móvil multiplataforma desarrollada en Flutter y Dart que fusiona variables biológicas dinámicas, como ritmo cardíaco, saturación de oxígeno y horas de sueño, junto con la escala psicométrica STAI. Usando el dataset LifeSnaps con una partición 80/20 y la librería TensorFlow, el modelo "Gradient Boosted Trees" (GBT) superó con claridad a Random Forest y SVM, alcanzando una exactitud del 80.76% y un F1 del 82.33%. La misma lógica de ejecución periférica aparece en Curi et al. (2025), que desarrollaron "Tampu", un sistema

acoplado a dispositivos Wear OS que procesa localmente frecuencia cardíaca, variabilidad del ritmo cardíaco (HRV) y SpO2 bajo un modelo Random Forest optimizado en TensorFlow Lite, validado con el cuestionario GAD-7. Los números son elocuentes: área bajo la curva ROC de 0.91, exactitud del 86.7% y sensibilidad del 87%, todo ello sin depender de servidores en la nube. La alerta llega directamente desde la muñeca del usuario.

La siguiente capa de complejidad aparece cuando los investigadores incorporan análisis conductual profundo y bioseñales electroencefalográficas. Gayathri et al. (2026) proponen "FocusED", un marco educativo que extrae trazas finas de interacción multimodal y despliega un procesador de lenguaje natural neurosimbólico orquestado con reglas difusas y aprendizaje por refuerzo. Los resultados son notables: exactitud predictiva del 96.51% en la personalización de contenidos y una reducción del estrés del 38.6% en el alumnado. Reddy et al. (2026), por su parte, desarrollaron "NeuroPhysio", orientado a clasificar tri-estados afectivos, como la ansiedad, confusión y frustración, a partir de ondas EEG capturadas a 2000 Hz en ventanas de apenas 3 y 5 segundos. Para compensar la escasez de datos primarios, implementaron una red condicional GAN (cGAN) que generó registros sintéticos en proporción 1:1, lo que permitió al clasificador XGBoost alcanzar una exactitud del 97.27%; la técnica SHAP se usó además para mapear el peso neurotopográfico frontal de cada electrodo y disparar automáticamente recomendaciones psicoterapéuticas de autorregulación.

Escalar estas soluciones biométricas a entornos más amplios exige infraestructuras distribuidas sólidas y pipelines de visión computacional no intrusivos. Schmidt et al. (2024) resuelven esa parte de la ecuación con una arquitectura de microservicios distribuidos basada en el framework Ray sobre Microsoft Azure, diseñada para orquestar terapia cognitivo-conductual por internet. El sistema combina, de forma paralela y asíncrona, modelos

fundacionales como Whisper y TinyLlama para la transcripción de video con ensambles de XGBoost y Random Forest que procesan vectores de contexto latente del paciente; el 100% de las pruebas funcionales de flujo de datos pasaron sin comprometer la integridad de la información transaccional. Gunawardhana et al. (2025) atacan el problema del hardware costoso por otro camino: un sistema de visión artificial que extrae biometría postural a través de una cámara web estándar, usando MediaPipe y estimaciones BlazePose para calcular distancias espaciales y cinco ángulos del torso superior. La fusión híbrida tardía entre una Red Neuronal Feed-Forward (FFNN) para el análisis facial y una Red Convolutiva Recurrente a Largo Plazo (LRCN) adaptada a la decadencia temporal de la postura produjo un 96.67% de exactitud en el diagnóstico compuesto de ansiedad y fatiga digital.

Las tendencias más recientes van más lejos todavía: las redes sociales empiezan a tratarse como sensores epidemiológicos pasivos, y los grandes ensayos comunitarios revelan matices que los estudios de laboratorio no capturan. Yang et al. (2022) construyeron un pipeline supervisado de PLN para detectar longitudinalmente usuarios que expresan estrés crónico en Twitter; sobre 152,000 publicaciones etiquetadas por cuatro expertos con un acuerdo Kappa de 0.83, demostraron que BERT aplasta a SVM y Random Forest con una exactitud del 83.6% y un F1 de 0.79, gracias a su mecanismo de atención semántica profunda. Ohashi et al. (2025) aportaron otro tipo de evidencia: validaron la versión digitalizada de e-learning del programa "Journey of the Brave" en 204 estudiantes usando Modelos Mixtos Lineales Generalizados (GLMM). La caída de 2.6 puntos en la escala de ansiedad de Spence fue estadísticamente significativa ($p=0.04$ $p=0.04$ $p=0.04$), pero el estudio reveló algo igual de importante: una asimetría de impacto por género pronunciada y variaciones inter-institucionales críticas, con la Escuela A registrando incluso un pico de ansiedad post-

intervención que escaló de 27.86 a 35.41 puntos, atribuible al tecnoestrés agudo generado por la falta de preparación tecnológica del entorno.

Todo esto, leído en conjunto, confirma que combinar ensambles híbridos con telemetría multimodal, fusión de texto, postura de video y bioseñales, maximiza la precisión diagnóstica y hace viables las alertas preventivas en tiempo real. Pero el estado del arte también muestra un límite persistente: las plataformas de alto rendimiento clínico tienden a degradarse cuando se generalizan entre sujetos diferentes, dependen de hardware especializado difícil de conseguir, o recurren a infraestructuras de videovigilancia en la nube que comprometen la privacidad y generan “vendor lock-in”. Ese es el vacío que la plataforma TI basada en Machine Learning híbrido con técnicas de Voting para universitarios de Lima Metropolitana viene a cubrir. La propuesta asimila las lecciones de la literatura e innova al estructurar un ensamble de Voting descentralizado de baja carga computacional que procesa localmente métricas conductuales y psicométricas calibradas al argot estudiantil local, garantizando un monitoreo preventivo proactivo, preciso y estrictamente respetuoso de la confidencialidad del alumno en condiciones reales de uso.

Tabla 31

Resumen: Pregunta 5

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
(Alexandra et al., 2025)	Aplicación móvil "Kora" para recomendación de relajación personalizada ante ansiedad pre/postoperatoria.	Edad, género, ritmo cardíaco, horas de sueño, saturación de oxígeno y categoría STAI.	Gradient Boosted Trees (GBT), Random Forest (RF) y Support Vector Machine (SVM).	Exactitud (Acc), Sensibilidad (Rc), Precisión (Pr), Puntuación F1 e instrumentos Likert de expertos.	GBT obtuvo el mejor desempeño con 80.76% de exactitud y 82.33% de F1-score. Validación favorable.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
(Gayathri et al., 2026)	Marco "FocusED" con PLN, modelado conductual y adaptación afectiva para alumnos neurodivergentes.	Trazas de interacción (navegación, relecturas, diario), estados emocionales y rasgos cognitivos latentes.	Procesamiento de Lenguaje Natural (PLN) neurosimbólico, reglas difusas y aprendizaje por refuerzo.	Exactitud, Precisión, Sensibilidad, tiempo en tarea, tasa de finalización, legibilidad y reducción de estrés.	Exactitud predictiva general de 96.51%. Elevó la finalización de lecciones al 91.6% y redujo el estrés (38.6%).
(Reddy et al., 2026)	Marco "NeuroPhysio" para clasificar tri-estados afectivos y niveles de carga cognitiva mediante datos EEG.	Ondas EEG, parámetros Hjorth, energía Wavelet, fractales y NASA-TLX.	XGBoost, SVM, RF (ML); CNN, LSTM, Conformer (DL); condicional GAN (cGAN) para datos sintéticos.	Exactitud (CA), Área bajo la curva ROC (AUC), F1-score, Coeficiente de Matthews (MCC) y Kappa.	XGBoost lideró en ML real (88% AS / 89.13% CL). Con cGAN, XGBoost llegó a 97.27% (AS) y CNN a 96.19% (CL).
(Curi et al., 2025)	Aplicación "Tampu" acoplada a Wear OS para detección y alerta local en tiempo real de crisis de ansiedad.	Frecuencia cardíaca, variabilidad del ritmo cardíaco (HRV), saturación de oxígeno (\$SpO_2\$) y GAD-7.	Clasificador Random Forest convertido y ejecutado localmente en el borde mediante TensorFlow Lite.	Exactitud, Sensibilidad, Especificidad, AUC, latencia, carga de CPU, consumo de batería y Escala SUS.	Logró un AUC de 0.91, exactitud de 86.7%, sensibilidad de 87% y especificidad de 93%. Puntuación SUS de 87/100.
(Schmidt et al., 2024)	Arquitectura en la nube distribuida para composición y despliegue asíncrono de modelos ML en iCBT.	Trazas de iCBT, transcripciones de audio, notas clínicas, vectores latentes de contexto, PHQ-9 y GAD-7.	Conjunto (ensemble) de microservicios paralelos (XGBoost, RF, Whisper, TinyLlama) vía Ray en Azure.	Pruebas unitarias de carga/inferencia a tensorial y pruebas integrales de flujo de datos (Data Flow).	Pipeline completado al 100%. Demostró la viabilidad de orquestar modelos paralelos sin corromper la data.
(Gunawardhana et al., 2025)	Sistema atento de visión artificial multimodal (no invasivo) para fatiga digital y ansiedad estudiantil.	Vectores espaciales faciales (FACS), landmarks posturales de torso superior y	Fusión híbrida tardía de Red Neuronal Feed-Forward (FFNN) y Red Convolutiva	Precisión emocional (FFNN), exactitud conjunta (fatiga/ansiedad) y latencia de	El clasificador facial FFNN obtuvo 95.6%. Al ensamblarse de forma híbrida con LRCN alcanzó 96.67% general.

Cita bibliográfica en APA 7	Aporte	Variables	Modelo	Métricas	Resultados
		perfiles demográficos.	Recurrente (LRCN).	inferencia temporal.	
(Yang et al., 2022)	Pipeline supervisado de PLN para detección autónoma y monitoreo longitudinal de estrés crónico en Twitter.	Publicaciones de texto con patrones de cronicidad, historiales retrospectivos (perfil) y concordancia Kappa.	Modelos estadísticos tradicionales (SVM, RF, Naïve Bayes) frente al Transformer contextual BERT.	Exactitud (Accuracy), Puntuación F1 (clase positiva), acuerdo inter-anotador Kappa e intervalos de confianza.	BERT superó significativamente a los esquemas tradicionales alcanzando un 83.6% de exactitud y 0.79 de F1.
(Ohashi et al., 2025)	Versión e-learning asíncrona y autodirigida del programa de TCC universal "Journey of the Brave".	Puntuaciones de ansiedad (SCAS), variables demográficas de género y varianza inter-institucional.	Procesamiento estadístico paramétrico mediante Modelos Mixtos Lineales Generalizados (GLMM).	Reducción de escala SCAS, test de asimilación cognitiva empotrado y tasa de finalización del software.	Caída significativa de 2.6 puntos de ansiedad global ($p=0.04$). Reveló alta asimetría de impacto según género y escuela.

3.3.3 Discusión

3.3.3.1 P1: ¿Qué factores y escalas caracterizan el tecnoestrés y la ansiedad digital en universitarios?

Al comparar los hallazgos de la literatura sobre la caracterización del tecnoestrés, resulta claro que los autores comparten un diagnóstico común sobre la severidad del fenómeno en el entorno universitario peruano, aunque difieren en las dimensiones conductuales y los detonantes específicos que identifican. Los estudios de base, como los de López-Arnes y Javier-Ninahuaman (2023) y Reyes y Libaque-Saenz (2023), coinciden en reportar niveles masivos de afectación y un impacto perjudicial directo sobre el desempeño estudiantil. Ahora bien, cuando se examinan las escalas psicométricas empleadas, las consecuencias medidas se diversifican notablemente. Vallejos-Flores et al. (2024) demuestran, mediante

las escalas C-SDS y SABAS, que la sobrecarga tecnológica se expresa a través de la distracción cognitiva y la adicción al smartphone; Acosta-Enriquez et al. (2025), en cambio, extienden la problemática hacia las tecnologías emergentes con la escala ASADAS y determinan que el estrés académico opera como mediador crítico en la dependencia compulsiva a la inteligencia artificial. Esta asimetría pone de manifiesto que instrumentos consolidados como la ECEA (Serpa-Barrientos et al., 2022) o la escala TS4US (Araya-Ugarte et al., 2025) capturan con solidez los estresores vinculados a la sobrecarga informativa y las evaluaciones virtuales, pero necesitan una actualización continua de sus parámetros para incorporar las nuevas dinámicas de hiperconectividad urbana.

Desde una perspectiva metodológica y de ingeniería de sistemas, la limitación más significativa del corpus analizado es otra: el carácter estrictamente reactivo, retrospectivo y transversal de las investigaciones. Norabuena-Figueroa et al. (2025) y Estrada-Araoz et al. (2024), entre otros, sustentan sus conclusiones en cuestionarios de autoinforme aplicados manualmente en un único momento del periodo académico, lo que expone los resultados a sesgos de subjetividad difíciles de controlar. Ninguno de los modelos de ecuaciones estructurales ni de las regresiones lineales múltiples presentados en la literatura dispone de capacidad computacional para realizar un seguimiento continuo o emitir alertas automatizadas en tiempo real. Ese vacío no es menor: las metodologías disponibles hasta hoy funcionan, en la práctica, como auditorías del colapso emocional estudiantil ya ocurrido, sin ninguna arquitectura de software capaz de anticipar el riesgo de forma proactiva.

Frente a esa brecha socio técnica, el diseño de una plataforma TI basada en Machine Learning híbrido con técnicas de Voting se justifica como un aporte original y superador.

La propuesta no descarta los factores predictivos que la literatura ha validado; los asimila y los convierte en vectores de entrada para alimentar un ensamble de clasificadores automatizados. De ese modo, la investigación tiende un puente directo entre la psicometría analítica retrospectiva y la ingeniería proactiva de baja latencia, dando lugar a una herramienta capaz de mitigar el tecnoestrés y proteger la salud digital de la comunidad universitaria en Lima Metropolitana de manera oportuna, segura y ajustada a la realidad local.

3.3.3.2 P2: ¿Qué algoritmos de PLN y Machine Learning son más precisos para clasificar trastornos afectivos?

Al comparar las aproximaciones metodológicas para clasificar trastornos afectivos, la trayectoria que traza la literatura es bastante nítida: se parte de descriptores léxicos tradicionales como TF-IDF y clasificadores clásicos respaldados por Rashti Mohammad et al. (2026) y Alkasem et al. (2026), y se llega al despliegue de redes profundas secuenciales y modelos semánticos basados en Transformers, como los propuestos por Hochstenbach et al. (2026) y Wang et al. (2026). Las arquitecturas derivadas de BERT alcanzan métricas F1 de hasta 0.927 en la abstracción de estados críticos (Cave et al., 2026), lo que las sitúa claramente por encima del análisis léxico superficial. Oulahbib et al. (2026) introducen un matiz importante en esa conversación al proponer modelos multitarea orientados a optimizar la infraestructura informática y reducir drásticamente el tiempo de inferencia del procesador. Y ahí está precisamente la tendencia que marca la vanguardia: no apostar por un único paradigma, sino orquestar meta-aprendices y sistemas de generalización apilada que unifiquen las fortalezas de los enfoques matemáticos tradicionales con los semánticos profundos, tal como plantean Lee et al. (2026) y Ramya y Manu (2026).

Desde el ángulo técnico y de ingeniería de sistemas, el corpus analizado arrastra tres limitaciones que se repiten: alta latencia computacional, riesgo de sobreajuste y sesgo lingüístico. Los modelos de mayor rendimiento predictivo evaluados por Hochstenbach et al. (2026) y Cave et al. (2026) exigen capacidades de hardware que los servidores universitarios convencionales simplemente no pueden sostener en condiciones operativas continuas. A eso se suma un problema de fondo que las revisiones de Rashti Mohammad et al. (2026) y Alkasem et al. (2026) dejan entrever: estos algoritmos fueron entrenados con datasets anglosajones genéricos y muestran una rigidez cultural que los vuelve analíticamente ineficaces frente al sarcasmo, los modismos y los neologismos con que los estudiantes de nuestra región expresan el burnout y la ansiedad digital. No es un detalle menor; es una brecha que invalida la aplicabilidad directa de estos modelos en Lima Metropolitana.

Esas dos limitaciones, la de infraestructura y la sociolingüística, son las que justifican la propuesta de una plataforma TI basada en Machine Learning híbrido con técnicas de Voting. Al combinar la robustez semántica de los Transformers con la ligereza computacional y la velocidad transaccional de un Voting Classifier, el proyecto aprovecha la precisión diagnóstica del estado del arte sin incurrir en los costos de procesamiento que la literatura crítica. La calibración adaptada al argot local de Lima Metropolitana resuelve el vacío sociolingüístico. El resultado es un puente metodológico que convierte los grandes modelos en herramientas predictivas proactivas, de baja latencia y viables para entornos reales de educación superior.

3.3.3.3 P3: ¿Cómo influyen las plataformas web o móviles y la gamificación en la regulación emocional del usuario?

Cuando se contrastan los hallazgos de la literatura sobre gamificación e interfaces web o móviles en salud digital, el consenso sobre su efectividad para mejorar la adherencia y reducir la sintomatología ansiosa es prácticamente unánime. Donde sí hay diferencias es en las mecánicas de interacción y los estímulos terapéuticos que cada propuesta utiliza.

McFadyen et al. (2026) lo demuestran de forma contundente en un ensayo controlado aleatorizado: incorporar agentes basados en IA generativa multiplica por 2.4 la frecuencia de uso y por 3.8 la duración de las sesiones frente a los cuadernos de control convencionales. Wang et al. (2023) refuerzan esa línea al mostrar que el modelado de diálogos interactivos de múltiples turnos a través del agente STEF eleva de forma significativa la capacidad de consuelo clínico frente a arquitecturas estáticas. Sin embargo, la persistencia del beneficio no está garantizada: depende del diseño de cada sesión. Xi et al. (2022) comprueban que los estímulos visuales no intrusivos basados en el "asombro" elevan el bienestar subjetivo a gran escala, pero Mittmann et al. (2024) advierten que las dinámicas lúdicas prolongadas e individuales que superan las tres horas continuas generan fatiga cognitiva y producen un deterioro paradójico en la regulación emocional interpersonal. Esa tensión entre estimulación y saturación valida la superioridad de combinar la interactividad con biometría o con enfoques motivacionales intrínsecos como el storytelling adaptado, dejando de lado los esquemas de recompensa material rígidos (Castro et al., 2023; Reynard et al., 2022).

Las brechas que el corpus deja al descubierto son serias. Salahshoor y Renbarger (2026) lo documentan en su revisión exploratoria: los agentes conversacionales de soporte psicosocial presentan fallos recurrentes de alineación semántica porque el vocabulario

predefinido del bot no se corresponde con la jerga real del usuario, lo que genera frustración y deserción. Intervenciones masivas como la analizada por Xi et al. (2022) muestran además una falta preocupante de predictibilidad adaptativa al operar con contenidos visuales estáticos y métricas de un solo ítem que simplifican en exceso la carga cognitiva; en algunos casos, estímulos mal calibrados llegan a provocar caídas en el bienestar en lugar de mejorarlo. En el plano metodológico, marcos de cribado exitosos como Here for You (Singh Sethi et al., 2026) circunscriben su validación a estudios piloto unicéntricos con muestras reducidas en entornos clínicos de alta alfabetización, sin llegar a evaluar probabilísticamente variables cruzadas en poblaciones más amplias y heterogéneas.

Esos vacíos son precisamente los que dan sustento al desarrollo de la plataforma TI basada en Machine Learning híbrido con técnicas de Voting. A diferencia de los sistemas puramente interactivos basados en reglas fijas o de los videojuegos de larga exposición que terminan saturando al usuario, la propuesta orchestra un pipeline de micro-intervenciones breves y dinámicas fundamentadas en la terapia cognitivo-conductual digital (iCBT). Las dimensiones psicométricas validadas de escalas como la DASS-21 son procesadas localmente de manera asíncrona mediante un clasificador de Voting calibrado al argot juvenil de Lima Metropolitana. Ese diseño desmantela la "caja negra" computacional y permite automatizar la entrega de recursos de soporte y recomendaciones lúdicas de forma proactiva y segura, cerrando la distancia entre el monitoreo de la ansiedad digital y la retención autónoma del estudiante en condiciones reales.

3.3.3.4 P4: ¿Qué arquitecturas tecnológicas garantizan la seguridad y privacidad de los datos en salud digital?

Al comparar las aproximaciones tecnológicas orientadas a la ciberseguridad y la privacidad en salud digital, hay un punto en el que los investigadores no discrepan: proteger los

perfiles sensibles del usuario y salvaguardar su identidad frente al estigma social es una necesidad irrenunciable. El desacuerdo surge cuando se trata de cómo hacerlo sin sacrificar el rendimiento. Un primer bloque de propuestas apuesta por los esquemas perimetrales de computación en la niebla: el marco EMLSCF-FCH de Kannan y Balasubramanian (2026) y el marco adaptativo AMRIA-U de Baena-Navarro et al. (2026) desplazan el procesamiento de datos y la inferencia clínica a la periferia mediante algoritmos ligeros y ejecuciones offline locales, reduciendo al mínimo la dependencia de la nube central. En el extremo opuesto, para entornos distribuidos que requieren entrenamiento colaborativo entre múltiples instituciones, aparecen arquitecturas como TrustFed de Murala et al. (2026), que combina Aprendizaje Federado con Privacidad Diferencial e inyecta ruido gaussiano controlado para compartir el conocimiento abstracto aprendido sin exponer jamás la información primaria de los pacientes. A esas dos grandes corrientes se suman soluciones complementarias: la tecnología Blockchain para blindar la transmisión de datos mediante inmutabilidad (Castillo-Arce et al., 2025) y la orquestación asíncrona de microservicios full-stack interconectados por APIs REST con bases de datos relacionales locales (Nina-Gutiérrez et al., 2024).

El análisis crítico de estos entornos de vanguardia deja ver severas brechas operativas. Kannan y Balasubramanian (2026) y Murala et al. (2026) lo reconocen ellos mismos, las soluciones que dependen de cifrado criptográfico intenso, inyección de ruido o contratos inteligentes descentralizados imponen una sobrecarga computacional que deteriora la granularidad analítica y agota los recursos de RAM en hardware comercial estándar. El problema no termina ahí. Cuando las aplicaciones web delegan el Procesamiento de Lenguaje Natural a APIs comerciales públicas, como ocurre con el diseño de SocialBullyAlert (Nina-Gutiérrez et al., 2024), se abre una vulnerabilidad de vendor lock-

in que compromete la soberanía informática al exportar datos psicológicos altamente confidenciales fuera del perímetro institucional. Y en el plano legal, las revisiones de los marcos europeos estudiadas por Mateus et al. (2026) y, de forma indirecta, por Meneses Ayala et al. (2025) revelan una desconexión profunda con las economías emergentes de América Latina: ante la falta de directrices algorítmicas punitivas aplicables a la región, la responsabilidad de una "Ética por Diseño" recae íntegramente sobre el arquitecto del sistema.

Ese conjunto de tensiones es el que le da sentido a la propuesta de la plataforma web basada en algoritmos de Voting. El proyecto recoge la necesidad de explicabilidad y transparencia que las revisiones sistemáticas de salud digital demandan (Mateus et al., 2026; Meneses Ayala et al., 2025), pero evita los dos escollos más costosos del estado del arte: la sobrecarga del esquema fog-blockchain de Kannan y Balasubramanian (2026) y el vendor lock-in que acarrea el diseño de Nina-Gutiérrez et al. (2024). La alternativa es un enfoque híbrido optimizado que auto-hospeda modelos de código abierto dentro del perímetro institucional. Al procesar localmente las variables de ansiedad digital y los modismos propios de Lima Metropolitana mediante un ensamble ligero de votación, el sistema protege la privacidad del universitario sin penalizar la latencia transaccional del servidor, cerrando la brecha de salud mental de forma proactiva, segura, escalable y éticamente sostenible.

3.3.2.5 P5: ¿Cómo optimizan los modelos de ensamble y la telemetría multimodal la detección de ansiedad en tiempo real?

Al comparar los enfoques tecnológicos para la detección de ansiedad en tiempo real, la literatura deja ver un acuerdo de fondo: la telemetría multimodal y los esquemas de ensamble superan con claridad a las evaluaciones estáticas tradicionales. Dentro de ese

consenso, las soluciones de ejecución periférica de Alexandra et al. (2025) y Curi et al. (2025) comparten una misma lógica: explotar bioseñales de wearables comerciales para alimentar algoritmos supervisados locales como Gradient Boosted Trees y Random Forest, alcanzando exactitudes superiores al 80% en dispositivos de bajo consumo. Pero la forma de capturar la angustia psicológica se diversifica notablemente cuando se miran otras modalidades. Reddy et al. (2026) apuestan por el rigor biomédico y procesan ondas EEG optimizadas mediante redes condicionales cGAN e Inteligencia Artificial Explicable (SHAP). Gunawardhana et al. (2025) van en dirección opuesta y prescinden del hardware costoso: proponen un sistema de visión artificial que extrae landmarks faciales y distancias posturales desde webcams convencionales, usando una fusión híbrida tardía entre redes FFNN y LRCN para decodificar la decadencia temporal de la postura. Lo que esa asimetría evidencia es que, aunque la literatura converge en la necesidad de capturar secuencias temporales continuas o rasgos cognitivos latentes en internet (Gayathri et al., 2026; Yang et al., 2022), los canales de ingesta varían de forma crítica entre el monitoreo fisiológico directo y la observación conductual pasiva.

El análisis de estos entornos de vanguardia saca a la luz brechas operativas y trade-offs que no son fáciles de ignorar. Los modelos de alto rendimiento basados en bioseñales, como los evaluados por Reddy et al. (2026), sufren un declive pronunciado en su capacidad de generalización cruzada inter-sujeto debido a las asimetrías neuronales entre individuos. Más preocupante aún: propuestas como la de Gunawardhana et al. (2025), basadas en visión ininterrumpida, introducen una amenaza real de panoptismo digital si la arquitectura transmite los vectores hacia servidores públicos en la nube, lo que vulnera directamente los Modelos de Aceptación Tecnológica (TAM) al activar el temor justificado de los usuarios a la violación de su privacidad. A eso se suma un vacío sociocultural que Ohashi et al.

(2025) documentan en entornos reales: las interfaces de e-Health generan impactos profundamente asimétricos según el género y pueden inducir picos severos de tecnoestrés agudo cuando el entorno institucional no está habituado a la tecnología. Ese factor de ruido contextual es algo que las superestructuras de microservicios en paralelo en la nube, como las de Schmidt et al. (2024), todavía no logran parametrizar de forma automatizada.

Frente a esas limitaciones de latencia, interpretabilidad y sesgo demográfico, la plataforma TI orientada a universitarios de Lima Metropolitana y basada en técnicas de Voting se justifica como una propuesta original y superadora. En lugar de asumir las restricciones de hardware del EEG (Reddy et al., 2026) o la resistencia ética que genera el monitoreo continuo por cámara web (Gunawardhana et al., 2025), la solución orquesta un ensamble de Voting descentralizado y de baja carga computacional que procesa localmente métricas conductuales, lingüísticas y factores psicométricos. Al integrar pesos paramétricos de calibración específicos en el algoritmo, la plataforma asimila y neutraliza de forma explícita las variaciones inter-institucionales y de género documentadas por Ohashi et al. (2025), convirtiendo los modelos masivos del estado del arte (Yang et al., 2022) en una herramienta predictiva proactiva, de baja latencia y estrictamente respetuosa de la confidencialidad de la salud mental en condiciones reales de uso.

3.3.4 Conclusiones

Respecto a la Pregunta de Investigación 1 (P1): La literatura científica internacional valida un conjunto multifactorial de dimensiones psicométricas medidas mediante herramientas como las escalas TS4US, SASSEV y ASADAS. Lo que el estado del arte también deja en evidencia es un vacío que no es menor: las investigaciones analizadas operan de forma reactiva, transversal y retrospectiva, apoyándose exclusivamente en cuestionarios manuales susceptibles a sesgos subjetivos y sin ningún mecanismo de

monitoreo predictivo automatizado. Esos factores e indicadores validados se convierten, por tanto, en los vectores de entrada que nutren la propuesta tecnológica aquí planteada, haciendo posible el salto desde la auditoría clínica tradicional hacia un sistema de detección proactivo adaptado a la comunidad universitaria de Lima Metropolitana.

Respecto a la Pregunta de Investigación 2 (P2): En lo que respecta a las técnicas de Procesamiento de Lenguaje Natural y los algoritmos de Machine Learning, las arquitecturas basadas en Transformers contextuales y los modelos de aprendizaje multitarea son los que alcanzan mayor precisión semántica para decodificar historiales lingüísticos y clasificar trastornos afectivos en internet. Sin embargo, esa superioridad tiene un precio: sobreajuste, alta latencia transaccional y rigidez analítica frente a la diversidad cultural, factores que limitan seriamente su portabilidad en infraestructuras de hardware académico convencional. Esa brecha técnica es la que justifica el desarrollo de un ensamble de votación que combine comprensión semántica profunda calibrada al argot estudiantil local con una carga computacional lo suficientemente baja para operar de forma continua en tiempo real.

Respecto a la Pregunta de Investigación 3 (P3): Las interfaces interactivas de salud web y móvil, el codiseño participativo con soporte clínico y los agentes conversacionales empáticos mejoran de forma significativa la adherencia del usuario y reducen la sintomatología ansiosa. Eso está bien documentado. Pero el estado del arte también expone sus límites: la rigidez arquitectónica de los entornos evaluados y el riesgo de generar fatiga cognitiva cuando las mecánicas lúdicas se prolongan en sesiones individuales extensas son problemas que no están resueltos. De ahí se desprende la necesidad de diseñar entornos modulares de micro-intervenciones breves y adaptativas que aprovechen el conocimiento

de los cuestionarios estandarizados para automatizar el soporte y la psicoeducación digital de forma dinámica y no intrusiva.

Respecto a la Pregunta de Investigación 4 (P4): Los modelos descentralizados basados en microservicios, la computación perimetral y el Aprendizaje Federado con Privacidad Diferencial son los marcos de ingeniería más robustos para proteger los registros confidenciales frente a accesos no autorizados y neutralizar el estigma social en salud. Aun así, la literatura científica deja ver dos vulnerabilidades recurrentes: la dependencia de vendor lock-in y una sobrecarga criptográfica excesiva en las soluciones perimetrales actuales que deteriora los tiempos de respuesta en hardware comercial restringido. Eso fundamenta la incorporación de un enfoque de "Compartición Segura e Inmutabilidad" en la plataforma, mediante el auto-hospedaje del backend y de los modelos distribuidos, para proteger la identidad del alumno sin comprometer la latencia transaccional en el entorno real.

Respecto a la Pregunta de Investigación 5 (P5): La fusión híbrida de múltiples fuentes de datos maximiza de forma consistente la exactitud predictiva y reduce el ruido analítico en ventanas temporales cortas. Ahí hay consenso. Donde aparecen las grietas es en la baja generalización cruzada inter-sujeto, en el riesgo ético que implica la videovigilancia en la nube y en las asimetrías de impacto generadas por sesgos institucionales y de género que los entornos de vanguardia aún no logran resolver. Ese escenario es el que valida el diseño de un ensamble de Voting descentralizado capaz de parametrizar e integrar variables de contexto demográfico para neutralizar las variaciones del entorno real, garantizando un monitoreo predictivo continuo, preciso y eficiente.

Conclusión General del Capítulo del Estado del Arte

La revisión analítica y sistemática de los 40 artículos indexados permitió construir una taxonomía científica e ingenieril que unifica, de forma coherente, los fundamentos psicométricos, el procesamiento de lenguaje avanzado y la arquitectura de software distribuida para abordar la ansiedad digital en la educación superior. Lo que el mapeo metodológico dejó en claro es que las soluciones tecnológicas actuales no cuentan con un enfoque predictivo integrado que logre conciliar al mismo tiempo la ligereza computacional, la calibración sociolingüística regional y la protección ética de la privacidad del estudiante. Ese es el vacío que este capítulo identifica y sustenta teóricamente, y es también el que valida la formulación de la plataforma TI basada en Machine Learning híbrido con técnicas de Voting como una alternativa pertinente, escalable y metodológicamente sólida para mitigar el tecnoestrés en los estudiantes universitarios de Lima Metropolitana.

Conclusiones

- El presente trabajo de investigación cumplió con el objetivo general planteado, al sentar las bases conceptuales, metodológicas y de diseño para la implementación de una plataforma web basada en Machine Learning híbrido orientada a la detección de la ansiedad digital en estudiantes universitarios de Lima Metropolitana. A partir del análisis del problema, la revisión del marco teórico y el estudio del estado del arte, se demostró la viabilidad técnica y la pertinencia social de integrar reglas de conocimiento experto con algoritmos de aprendizaje automático, específicamente Random Forest, para ofrecer un mecanismo de detección temprana, escalable y culturalmente adaptado al contexto universitario peruano, contribuyendo así a reducir la brecha existente entre la necesidad de atención en salud mental y el acceso oportuno a ella.
- Se concluye que el análisis de los factores técnicos, psicológicos y contextuales, sustentado en la revisión de la literatura científica y en el estudio de caso desarrollado en el Capítulo 1, permitió identificar las dimensiones psicométricas (ansiedad digital, tecnoestrés, autoeficacia académica) y los indicadores conductuales asociados al uso de tecnologías digitales. Dichos factores constituyen las variables de entrada del modelo predictivo y validan la pertinencia de un enfoque híbrido frente a los métodos de evaluación manual tradicionales.
- Se concluye que el diseño de las arquitecturas lógica, física e integrada de la plataforma web (Sección 1.4), junto con el proceso de benchmarking tecnológico realizado en la Sección 1.6, permitió definir una solución basada en la nube que integra módulos de Procesamiento de Lenguaje Natural y computación afectiva. Esta arquitectura garantiza la correcta captura, transformación y análisis de los datos textuales y conductuales de los estudiantes de manera segura y escalable.

- Se concluye que el proceso de benchmarking del algoritmo de Machine Learning y de las métricas de evaluación clínica (Tablas 17 y 18) permitió seleccionar Random Forest como el modelo más adecuado en función de su precisión diagnóstica, interpretabilidad y eficiencia computacional. Con ello se estableció el criterio metodológico y los indicadores de desempeño ($F1\text{-Score} \geq 85\%$) que guiarán la validación del modelo con datos reales de estudiantes universitarios en la etapa de implementación del proyecto.
- se concluye que la definición del backlog de la Épica 7 — Continuidad y MLOps, junto con la gestión del proyecto descrita en la Sección 1.5 (alcance, cronograma, costos, calidad y riesgos), estableció los lineamientos necesarios para elaborar un plan de continuidad operativa. Dicho plan garantizará la disponibilidad, escalabilidad y sostenibilidad de la plataforma a largo plazo, mediante mecanismos de reentrenamiento automatizado del modelo y procedimientos de mantenimiento y recuperación ante fallos.

Referencias Bibliográficas

- A., Alrawad, M., Al Mulhem, A., Alkhdour, T., Awad, A. B., & Al-Marooof, R. S. (2022). Examining the Impact of Artificial Intelligence and Social and Computer Anxiety in E-Learning Settings: Students' Perceptions at the University Level. *Electronics*, 11(22), 3662. <https://doi.org/10.3390/electronics11223662>
- Acosta-Enriquez, B. G., Ballesteros, M. A. A., Guzman Valle, M. de los A., Morales Angaspilco, J. E., Aquino Lalupú, J. del R., Jaico, J. L. B., Germán Reyes, N. C., Alarcón García, R. E., & Castillo, W. E. J. (2025). The mediating role of academic stress, critical thinking and performance expectations in the influence of academic self-efficacy on AI dependence: Case study in college students. *Computers and Education Artificial Intelligence*, 8, Article 100381. <https://doi.org/10.1016/j.caeai.2025.100381>
- Alexandra, A. M. M., Gabriel, G. D. C., & Elio, N. v. (2025). Mobile Application for Managing Anxiety using Machine Learning Model. *2025 3rd Cognitive Models and Artificial Intelligence Conference, AICCONF 2025 - Proceedings*. <https://doi.org/10.1109/AICCONF64766.2025.11064189>
- Alkasem, H., Alsalamah, A., Alhussan, L., Alzahrani, N., & Aba-alkhail, S. (2026). Machine learning methods for detecting depression in Arabic tweets: a comprehensive performance analysis with enhanced evaluation metrics. *Discover Artificial Intelligence*, 6(1), Article 120. <https://doi.org/10.1007/s44163-026-00842-y>
- Alnaabi, A. A. H., & Al Mahruqi, A. A. H. (2026). Artificial intelligence methods for enhancing cybersecurity in Oman: a comprehensive review. *Journal of Cloud Computing*, 15(1), Article 48. <https://doi.org/10.1186/s13677-026-00860-2>
- Ampuero-Tello, N. L., Zegarra-López, A. C., Padilla-López, D. A., & Venturo-Pimentel, D. S. (2022). Academic self-efficacy as a protective factor for the mental health of university

- students during the COVID-19 pandemic. *Interacciones*, 8, e289.
<https://doi.org/10.24016/2022.V8.289>
- Anicama, J., Calderón, R., Javier-Aliaga, D., Caballero, G., Talla, K., Pizarro, R., Calizaya-Milla, Y. E., & Saintila, J. (2025). Self-efficacy and stress as predictors of anxiety in Peruvian and Mexican university students: a cross-sectional study. *Frontiers in Education*, 10. <https://doi.org/10.3389/feduc.2025.1423406>
- Araya-Ugarte, G., Armesto-Céspedes, M., Contreras-Barraza, N., Vega-Muñoz, A., Salazar-Sepúlveda, G., & Lay, N. (2025). Contextual Study of Technostress in Higher Education: Psychometric Evidence for the TS4US Scale from Lima, Peru. *Sustainability Switzerland*, 17(15), Article 6974. <https://doi.org/10.3390/su17156974>
- Asana. (2024). ¿Qué es Scrum? Metodología, principios y beneficios. <https://asana.com/es/resources/what-is-scrum>
- Baena-Navarro, R., Carriazo-Regino, Y., Crawford-Vidal, R., Fernández-Arango, A., & Barreiro-Pinto, F. (2025). Adaptive AI-driven framework for digital mental health interventions in low-resource universities. *Bulletin of Electrical Engineering and Informatics*, 14(6), 4534–4547. <https://doi.org/10.11591/eei.v14i6.10143>
- Baigorria, R. (2024). Serverless a Gran Escala: cómo diseñé un flujo de procesamiento de datos totalmente automatizado en AWS. AWS Builder Center. <https://builder.aws.com/content/33iGIV0a5GGK4E6ZIoZFy9e0tCR>
- Baldassarri Santalucía, S. (2016). Computación afectiva: tecnología y emociones para mejorar la experiencia del usuario. *Bit & Byte*, 2(3), 14-15.
<http://sedici.unlp.edu.ar/handle/10915/53441>

- Castillo-Arce, A., Patrick Sanchez-Zavalaga, H., Nuñez-Bardales, K., Obregon-Tinoco, H., & Bazan-Aguilar, A. (2025). Systematic review on the inclusion of technological tools in the Health Sector Supply Chain (CSSS) | Revisión sistemática sobre la inclusión de herramientas tecnológicas en la cadena de suministro del sector salud (CSSS). *Proceedings of the Laccei International Multi Conference for Engineering Education and Technology*, (2025), Article (2025). <https://doi.org/10.18687/LACCEI2025.1.1.1596>
- Castro, O., Mair, J. L., Salamanca-Sanabria, A., Alattas, A., Keller, R., Zheng, S., Jabir, A., Lin, X., Frese, B. F., Lim, C. S., Santhanam, P., van Dam, R. M., Car, J., Lee, J., Tai, E. S., Fleisch, E., von Wangenheim, F., Tudor Car, L., Müller-Riemenschneider, F., & Kowatsch, T. (2023). Development of “LvL UP 1.0”: A smartphone-based, conversational agent-delivered holistic lifestyle intervention for the prevention of non-communicable diseases and common mental disorders. *Frontiers in Digital Health*, 5, Artículo 1039171. <https://doi.org/10.3389/fdgth.2023.1039171>
- Cave, S., Peterson, K. S., Plomondon, M. E. y Waldo, S. W. (2026). Utilizing large language models and natural language processing to classify ischemia status from cardiac stress tests in a large multicenter healthcare system. *BMC Research Notes*, 19, Artículo 10 . <https://doi.org/10.1186/s13104-025-07586-5>
- Chanchí-Golondrino, G. E., et al. (2022). Aplicación de la computación afectiva en el análisis de la percepción de los asistentes a una feria de emprendimiento del SENA. *Revista Científica*, 44(2), 215-227. <https://www.redalyc.org/journal/5043/504371984005/html>
- Choudhary, L., & Sybol, S. S. (2026). Impact of AI on students mental health and well-being. En *Human-Centered Learning Design in the AI Era* (pp. 205–233). IGI Global Scientific Publishing. <https://doi.org/10.4018/979-8-3373-5786-7.ch008>

- Chumbimuni-Aguirre, F., & Pequeña Constantino, J. (2023). Bienestar psicológico y autoeficacia académica en estudiantes de un centro preuniversitario de Lima. *Persona*, 25(2), 107-121. [https://doi.org/10.26439/persona2022.n25\(2\).5709](https://doi.org/10.26439/persona2022.n25(2).5709)
- Congreso de la República del Perú. (2011). Ley N° 29733: Ley de Protección de Datos Personales. <https://www.leyes.congreso.gob.pe/documentos/leyes/29733.pdf>
- Congreso de la República del Perú. (2013). Ley N° 30096: Ley de Delitos Informáticos. <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/239569-30096>
- Congreso de la República del Perú. (2023). Ley N° 31814: Ley que promueve el uso de la inteligencia artificial en favor del desarrollo económico y social del país. <https://www.gob.pe/institucion/congreso-de-la-republica/normas-legales/4565760-31814>
- Cudris-Torres, L., Gutiérrez, J. M., & López-Castellar, M. A. (2026). Innovation in digital interventions for the mental health of university students in Latin America: Challenges, advances, and perspectives from recent evidence. *Gaceta Medica de Caracas*, 134(1), 314–319. <https://doi.org/10.47307/GMC.2026.134.1.26>
- Curi, I. C., Quispe, E. Y., & Lopez, N. B. (2025). Tampu: Mobile Application Using Wearable Technology for Real-Time Detection and Alert of Anxiety and Panic Attacks in University Students. *Proceedings of the 2025 IEEE 5th International Conference on Advanced Learning Technologies on Education and Research, ICALTER 2025*. <https://doi.org/10.1109/ICALTER69698.2025.11355147>
- Defensoría del Pueblo. (2019). Manual de Protección de Datos Personales. <https://www.defensoria.gob.pe/wp-content/uploads/2019/11/Manual-de-Protección-de-Datos-Personales.pdf>

- Digital Exp. (2024). *Desarrollo Firebase para aplicaciones escalables*.
<https://digitalexp.co/technologies/firebase>
- Dominguez-Lara, S., & Fernández-Arata, M. (2019). Autoeficacia académica en estudiantes de Psicología de una universidad de Lima. *Revista Electrónica de Investigación Educativa*, 21, e32. <https://doi.org/10.24320/redie.2019.21.e32.2014>
- E2E Networks. (16 de octubre de 2023). *NLP 101: NLP architecture explained*.
<https://www.e2enetworks.com/blog/nlp-101-nlp-architecture-explained>
- Eidman, L. (2024). Tecnoestrés en estudiantes universitarios argentinos en pandemia COVID-19. *Academo*, 11(1). <https://doi.org/10.30545/academo.2024.ene-abr.1>
- Estrada-Araoz, E. G., & Cruz-Laricano, E. O. (2025). A Look at the Mental Health of University Students in Times of Uncertainty and Challenges | Una mirada a la salud mental de los estudiantes universitarios en tiempos de incertidumbre y desafíos. *Revista Del Hospital Psiquiatrico De La Habana*, 22, Article 22. Disponible en:
<https://revhph.sld.cu/index.php/hph/article/view/760>
- Estrada-Araoz, E. G., Larico-Uchamaco, G. R., Roman-Paredes, N. O., & Ticona-Chayña, E. (2024). Coping with stress and self-efficacy as predictors of academic satisfaction in a sample of university students | Afrontamiento al estrés y autoeficacia como predictores de la satisfacción académica en una muestra de estudiantes universitarios. *Salud, Ciencia y Tecnología*, 4, Article 840. <https://doi.org/10.56294/saludcyt2024840>
- Gayathri, C., TV, Y. Krishnan., Kumar, S. S., Poovarasan, K., & Vel, M. S. H. (2026). FocusED: An NLP-Driven Personalized and Affective-Aware Learning Framework for Neurodivergent Students. *2026 International Conference on Smart Electronic Devices and Intelligent Systems (ICSEDIS)*, 1599–1606.
<https://doi.org/10.1109/ICSEDIS68157.2026.11518527>

Gkintoni, E., Vassilopoulos, S. P., & Nikolaou, G. (2025). Next-Generation Cognitive-Behavioral Therapy for Depression: Integrating Digital Tools, Teletherapy, and Personalization for Enhanced Mental Health Outcomes. *Medicina*, 61(3), 431. <https://doi.org/10.3390/medicina61030431>

Gunawardhana, A. G. M. S., Madhubhashini, G. G. K. N., Herath, H. M. K. K. M. B., & Yasakethu, S. L. P. (2025). AI-enabled Vision Attentive System for Detection of Emotional Anxiety and Digital Fatigue among University Students. *Proceedings of ICITR 2025 - 10th International Conference on Information Technology Research: Advancing Global Connectivity Through Emerging Information Technology Solutions*. <https://doi.org/10.1109/ICITR69413.2025.11353823>

Hochstenbach, R., Frasincar, F., & Klinkhamer, J. (2026). A contextual hierarchical attention network for detecting mental health disorders using social media. *Data and Knowledge Engineering*, 163, Article 102560. <https://doi.org/10.1016/j.datak.2026.102560>

Isaiah, U. S., Naibo, A. T., Ugondo, M. T., Ogwuche, S., Iziengbuwa, S. J., Abiama, E. E., & Ineme, M. E. (2026). The role of AI companions in supporting adaptive emotion regulation among university students with social anxiety. *Discover Mental Health*, 6, 53. <https://doi.org/10.1007/s44192-026-00387-7>

Ishfaq, U., Khan, H. U., & Shabbir, D. (2024). Exploring the role of sentiment analysis with network and temporal features for finding influential users in social media platforms. *Social Network Analysis and Mining*, 14, Artículo 241. <https://doi.org/10.1007/s13278-024-01396-6>

ITDO. (2023). ¿Qué es la computación afectiva y qué aplicaciones tiene en el desarrollo de software? <https://www.itdo.com/blog/que-es-la-computacion-afectiva-y-que-aplicaciones-tiene-en-el-desarrollo-de-software>

- Jiménez Boraita, R., Arriscado Alsina, D., González García, H., Castro López, R., María Gallardo Pérez, J., Salas Sánchez, J., Álvarez Kurogi, L., & Tierno Cordón, J. (2026). Estrés, ansiedad y depresión en estudiantes universitarios en línea: relación con hábitos de vida, estrategias de afrontamiento y comportamiento académico. *American Journal of Distance Education*, 1–23. <https://doi.org/10.1080/08923647.2026.2629651>
- Jurispol. (2026). Modifican la Ley N° 30096 – “Ley de delitos informáticos”, incorporando el delito de adquisición, posesión y tráfico ilícito de datos informáticos [DL 1700]. <https://jurispol.pe/modifican-la-ley-n-30096-ley-de-delitos-informaticos-incorporando-el-delito-de-adquisicion-posesion-y-trafico-ilicito-de-datos-informaticos-dl-1700>
- Kannan, N., & Balasubramanian, K. (2026). EMLSCF-FCH: A Secure and Efficient Machine Learning-Based Framework for Fog Computing in Healthcare. *International Journal of Computational Intelligence Systems*, 19(1). <https://doi.org/10.1007/s44196-025-01100-2>
- Lee, D., Park, E., Kim, G., Han, Y., & Lee, U. (2026). A Multimodal Dataset for Assessing Emotion, Stress, and Emotional Workload in Interpersonal Work Scenario. *Scientific Data*, 13(1), Article 214. <https://doi.org/10.1038/s41597-025-06531-2>
- León-Garrido, A., et al. (2025). Evaluación del uso y aceptación de apps móviles en educación superior mediante el modelo TAM. *RIED-Revista Iberoamericana de Educación a Distancia*, 28(1), 107–126. <https://doi.org/10.5944/ried.28.1.40988>
- Lin, H., & Chen, Q. (2024). Artificial intelligence (AI)-integrated educational applications and college students’ creativity and academic emotions: students and teachers’ perceptions and attitudes. *BMC Psychology*, 12, 487. <https://doi.org/10.1186/s40359-024-01979-0>

- López del Castillo, F. L. (2024). Inteligencia artificial generativa: determinismo tecnológico o artefacto construido socialmente. *Palabra Clave*, 27(1), e2719. <https://doi.org/10.5294/pacla.2024.27.1.9>
- López-Armes, E. L., & Javier-Ninahuaman, H. J. (2023). Academic stress and organizational climate in university students of a public university in Peru in the post-Covid-19 pandemic | Estrés académico y clima organizacional en estudiantes universitarios de una universidad pública en Perú en pospandemia Covid.... *Aibi Revista De Investigacion Administracion E Ingenierias*, 11(3), 94–104. <https://doi.org/10.15649/2346030X.3386>
- Mateus, M., Alho, I., Neves, A. L., Lopes, H., & Correia, M. (2026). “First, do no harm” in the digital era: examining the practicality of the European Health Data Space proposal and ethical implications of artificial intelligence: A systematic literature review. *BMC Medical Ethics*, 27(1), Article 35. <https://doi.org/10.1186/s12910-025-01372-5>
- McFadyen, J., Habicht, J., Dina, L.-M., Harper, R., Hauser, T. U., & Rollwage, M. (2026). Increasing engagement with cognitive-behavioral therapy (CBT) using generative AI: A randomized controlled trial (RCT). *Communications Medicine*, 6, Artículo 129. <https://doi.org/10.1038/s43856-025-01321-8>
- Meegle. (2024). Serverless Architecture for Healthcare: A Complete Guide. https://www.meegle.com/en_us/topics/serverless-architecture/serverless-architecture-for-healthcare
- Meneses Ayala, A. Y., Quispe Mamani, J. E., & Rada Mota, L. C. (2025). Systematic Review on AI-Based Diagnosis and Appointment Management in Under-Digitalized Healthcare. *Proceedings of the Laccei International Multi Conference for Engineering*

<https://doi.org/10.18687/leird2025.1.1.1052>

- Mittmann, G., Barnard, A., Zehetmayer, S., Wimmer, S., Zehetner, V., Doerfler, S., Woodcock, K., & Schrank, B. (2024). A Serious Game for Emotion Regulation in Adolescents: Player Experience and Pilot Feasibility Study. *International Journal of Game Based Learning*, 14(1), 1–17. <https://doi.org/10.4018/IJGBL.358940>
- Mohammad, S. R., Kadaei, F., & Mohkam, M. (2026). Machine learning approaches to identifying neurodevelopmental disorders using social media data: a systematic review. *International Journal of Medical Informatics*, 213, Article 106378. <https://doi.org/10.1016/j.ijmedinf.2026.106378>
- Morales-García, W. C., Sairitupa-Sanchez, L. Z., Flores-Paredes, A., Pascual-Mariño, J., & Morales-García, M. (2025). Influence of Self-Efficacy in the Use of Artificial Intelligence (AI) and Anxiety Toward AI Use on AI Dependence Among Peruvian University Students. *Data and Metadata*, 4. <https://doi.org/10.56294/dm2025210>
- More, T. (2020). Bienestar psicológico y autoeficacia en universitarios migrantes en Lima Metropolitana. Repositorio Académico UPC. <http://hdl.handle.net/10757/652108>
- Murala, D. K., K., M., Vuyyuru, V. A., Rao, K. V. P., & Hitimana, E. (2026). Trustfed a scalable privacy preserving federated AI framework for industrial IoT healthcare and finance. *Discover Internet of Things*. <https://doi.org/10.1007/s43926-025-00276-5>
- Nina-Gutiérrez, E. A., Pacheco-Alanya, J. E., & Morales-Arevalo, J. C. (2024). SocialBullyAlert: A Web Application for Cyberbullying Detection on Minors' Social Media. *International Journal of Advanced Computer Science and Applications*, 15(7), 769–778. <https://doi.org/10.14569/IJACSA.2024.0150776>

- Norabuena-Figueroa, R. P., Deroncele-Acosta, A., Rodríguez-Orellana, H. M., Norabuena-Figueroa, E. D., Flores-Chinte, M. C., Huamán-Romero, L. L., Tarazona-Miranda, V. H., & Mollo-Flores, M. E. (2025). Digital Teaching Practices and Student Academic Stress in the Era of Digitalization in Higher Education. *Applied Sciences Switzerland*, 15(3), Article 1487. <https://doi.org/10.3390/app15031487>
- Ohashi, S., Urao, Y., Fujiwara, K., Koshiba, T., Ishikawa, S., & Shimizu, E. (2025). A school-setting pilot study of the e-learning version of the "Journey of the Brave": a universal anxiety-prevention program based on cognitive behavioral therapy. *Child and Adolescent Psychiatry and Mental Health*, 19(1), 96. <https://doi.org/10.1186/s13034-025-00956-8>
- Onyeka, O. C., et al. (2024). Internet-delivered cognitive behavioral therapy for anxiety: A review of effectiveness. *Journal of Anxiety Disorders*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11493317>
- Oulahbib, I., Benhaddi, M., & El Hadaj, S. (2026). Deep-AP: An efficient multi-task architecture for Author Profiling and Depression Detection. *Scientific African*, 32, Article e03303. <https://doi.org/10.1016/j.sciaf.2026.e03303>
- PHD Assistance. (2024). Sentiment Analysis and Machine Learning for Understanding PhD Scholars' Mental Health. <https://www.phdassistance.com/academy/critical-review/sentiment-analysis-phd-scholars-mental-health>
- Presidencia del Consejo de Ministros. (2025). Decreto Supremo N° 115-2025-PCM: Reglamento de la Ley N° 31814. <https://www.gob.pe/institucion/pcm/normas-legales/7133522-115-2025-pcm>

- Puente-Torre, P., Delgado-Benito, V., Rodríguez-Cano, S., & García-Delgado, M. Á. (2025). The Impact of Technology on Anxiety Management in University Students. *Behavioral Sciences*, 15(3), 310. <https://doi.org/10.3390/bs15030310>
- Quiroz Martinez, M. R. (2025). Inteligencia Artificial Generativa (IA Gen) en la Transformación Digital de la Educación Superior una Revisión Sistemática de Literatura. *Ciencia Latina Revista Científica Multidisciplinar*, 9(2), 6339-6378. <https://ciencialatina.org/index.php/cienciala/article/view/17370>
- Ramya, V. J. y Manu, Y. M. (2026). A hybrid explainable machine learning and transformerbased framework for psychological stress detection in women's social media narratives. *Discover Artificial Intelligence*, 6, Artículo 300. <https://doi.org/10.1007/s44163-026-01055-z>
- Reddy, A. R., Veerasingam, S., & Begum, B. S. (2026). NeuroPhysio: Explainable EEG-Based AI for Affective and Cognitive Load Recognition in Digital Health-Integrated Learning Systems. *IEEE Transactions on Affective Computing*. <https://doi.org/10.1109/TAFFC.2026.3664306>
- Reyes, R., & Libaque-Saenz, C. F. (2023). Factors influencing higher education students' performance and satisfaction with virtual classes during the Covid-19 pandemic: the case of Peru. *Issues in Information Systems*, 24(4), 176–190. https://doi.org/10.48009/4_iis_2023_114
- Reynard, S., Dias, J., Mitic, M., Schrank, B., & Woodcock, K. A. (2022). Digital Interventions for Emotion Regulation in Children and Early Adolescents: Systematic Review and Meta-analysis. *JMIR Serious Games*, 10(3), Artículo e31456. <https://doi.org/10.2196/31456>

- Salahshoor, S., & Renbarger, K. M. (2026). AI-enhanced, digital psychosocial interventions for pediatric developmental disabilities: A scoping review. *Journal of Pediatric Nursing*, 86, 199–206. <https://doi.org/10.1016/j.pedn.2025.11.016>
- Schmidt, F., Kurzawski, M. G., Hammerfald, K., Jahren, H. H., Solbakken, O. A., & Vlassov, V. (2024). A Scalable System Architecture for Composition and Deployment of Machine Learning Models in Cognitive Behavioral Therapy. *Proceedings - 2024 IEEE International Conference on Digital Health, ICDH 2024*, 79–86. <https://doi.org/10.1109/ICDH62654.2024.00024>
- Schorr, A. (2023). The Technology Acceptance Model (TAM) and its Importance for Digitalization Research: A Review. *International Symposium on Technikpsychologie (TecPsy) 2023*, 55–65. <https://doi.org/10.2478/9788366675896-005>
- Schutte, N. S., & Li, H. (2025). The role of self-efficacy and curiosity in student use of artificial intelligence (AI). *International Journal of Educational Technology in Higher Education*, 22(1). <https://doi.org/10.1186/s41239-025-00574-6>
- Schwaber, K., & Sutherland, J. (2020). La Guía de Scrum: Las Reglas del Juego. Scrum.org. <https://scrumguides.org/docs/scrumguide/v1/Scrum-Guide-ES.pdf>
- Serpa-Barrientos, A., Tito-Huamaní, P. L., Campos, L. A. G., & Quijaite, J. J. S. (2022). Psychometric evidence of the academic stressors scale in Peruvian university students in the context of COVID-19 | 在 COVID-19 的背景下秘鲁大学生学业压力量表的心理测量学证据. *Publicaciones De La Facultad De Educacion Y Humanidades Del Campus De Melilla*, 52(1), 277–299. <https://doi.org/10.30827/publicaciones.v52i1.22091>

- Shahzad, M. F., Xu, S., Lim, W. M., Yang, X., & Khan, Q. R. (2024). Artificial intelligence and social media on academic performance and mental well-being: Student perceptions of positive impact in the age of smart learning. *Heliyon*, 10(8). <https://doi.org/10.1016/j.heliyon.2024.e29523>
- Singh Sethi, M. I., Manickam, T., Chakraborty, T., & Bada Math, S. (2026). Co-Designed Mental Health Screening App (Here for You) for University Students: Pilot Feasibility Mixed Methods Study. *JMIR Formative Research*, 10, Artículo e75616. <https://doi.org/10.2196/75616>
- Solano Castro, V. V., & Núñez Lira, L. (2025). Tecnoestrés en estudiantes de educación superior en Lima, Perú. *Revista Venezolana de Gerencia*, 30(110). https://ve.scielo.org/scielo.php?script=sci_arttext&pid=S2739-00632025000202018
- Suxe-Ramírez, M. A., Miranda-Saldaña, R. J., & Castro-García, J. H. (2025). Impact of online video games on academic performance and mental health in college students: a systematic review | Impacto de los videojuegos online en el rendimiento académico y la salud mental en estudiantes universitarios: una revisión sistemática. Proceedings of the Laccei International Multi Conference for Engineering Education and Technology, (2025), Article (2025). <https://doi.org/10.18687/LACCEI2025.1.1.2089>
- Tantalean-Terrones, L. J., Aguirre-Morales, M. T., Cirilo-Acero, I. B., Mayanga-Aliaga, M. H., Carbajal-Ríos, M. A., & Livia-Segovia, J. H. (2025). Mental Health Continuum–Short Form scale: Validation in una muestra de estudiantes universitarios peruanos. *Revista de Psicopatología y Psicología Clínica*, 30(3), 257–266. <https://doi.org/10.5944/rppc.42092>

- Tudose, M.-A. (2025). Digital anxiety: the psychological toll of constant technological change in the workplace. *International Conference of Management and Industrial Engineering*, 12. <https://doi.org/10.56177/12icmie2025.117>
- Vallejos-Flores, M., Talledo-Sánchez, K., Carlos-Ventura, D., Caycho-Caja, A., Amesquita, J. S., & Huamanyauri, D. R. (2024). Technostress and Smartphone addiction mediated by Smartphone distraction in college students | Tecnoestrés y Adicción al teléfono inteligente mediado por la distracción por teléfono inteligente en universitarios. *Revista Digital De Investigacion En Docencia Universitaria*, 18(2), Article e1957. <https://doi.org/10.19083/ridu.2024.1957>
- Villanueva, R. (2023). Análisis dogmático de los delitos contra los sistemas y datos informáticos en el Perú. *Revista Lucerna*. <https://revistasinvestigacion.unmsm.edu.pe/index.php/Lucerna/article/download/28141/22209/121539>
- Wan, Q., Pan, Y., & Zakeri, S. (2025). Analyzing Depression in College Students Using NLP and Transformer Models: Implications for Career and Educational Counseling. *Brain and behavior*, 15(9), e70828. <https://doi.org/10.1002/brb3.70828>
- Wang, Q., Peng, S., Zha, Z., Han, X., Deng, C., Hu, L., & Hu, P. (2023). Enhancing the conversational agent with an emotional support system for mental health digital therapeutics. *Frontiers in Psychiatry*, 14, Artículo 1148534. <https://doi.org/10.3389/fpsy.2023.1148534>
- Wang, Y., Wang, Z., Fan, S., Wang, X., Zhang, Y., & Zhang, Z. (2026). Deep learning-based intelligent assessment and early warning system for employee mental health status. *Discover Artificial Intelligence*, 6(1), Article 42. <https://doi.org/10.1007/s44163-025-00720-z>

- World Health Organization. (2024). Ethics and governance of artificial intelligence for health: Guidance on large multi-modal models. Geneva: WHO.
<https://iris.who.int/server/api/core/bitstreams/e9e62c65-6045-481e-bd04-20e206bc5039/content>
- Xi, J.Z., Gao, Y.H., Lyu, N., She, Z., Wang, X.Y., Zhang, X.A., Yu, X.Y., Ji, W.D., Wei, M.S., Dai, W.H., & Qian, X. (2022). Effect of the “Art Coloring” Online Coloring Game on Subjective Well-Being Increase and Anxiety Reduction During the COVID-19 Pandemic: Development and Evaluation. *JMIR Serious Games*, 10(3), Artículo e37026.
<https://doi.org/10.2196/37026>
- Yang, Y. C., Xie, A., Kim, S., Hair, J., Al-Garadi, M., & Sarker, A. (2023). Automatic Detection of Twitter Users Who Express Chronic Stress Experiences via Supervised Machine Learning and Natural Language Processing. *CIN - Computers Informatics Nursing*, 41(9), 717–724. <https://doi.org/10.1097/CIN.0000000000000985>

Anexo(s)

- A. Anexo 01: Pila de Producto (Product Backlog)
- B. Anexo 02: Cronograma del Proyecto
- C. Anexo 03: Acta de Constitución del Proyecto (Project Charter)
- D. Anexo 04: Informe de Benchmarking

PRODUCT BACKLOG — PLATAFORMA WEB ML HÍBRIDO PARA DETECCIÓN DE ANSIEDAD DIGITAL

Nuñez Alvarez, Sebastian Andre | Salazar Gutiérrez, Darwin Karl

ID	COMO ...	QUIERO ...	PARA ...	PRIORIDA	SPRINT	ESTADO
US-01	Estudiante universitario	registrarme en la plataforma con mi correo institucional y completar un perfil inicial	que el sistema pueda personalizar mi evaluación de ansiedad digital según mi contexto académico	Alta	4	No se ha iniciado
US-02	Estudiante universitario	iniciar sesión de forma anónima y segura con autenticación JWT	proteger mi privacidad y sentirme seguro al compartir datos psicológicos sensibles	Alta	4	No se ha iniciado
US-03	Estudiante universitario	ver una pantalla de bienvenida con explicación del propósito de la plataforma y política de privacidad	dar mi consentimiento informado antes de comenzar cualquier evaluación de ansiedad digital	Alta	4	No se ha iniciado
US-04	Estudiante universitario	completar un cuestionario psicométrico validado (escala TS4US / ASADAS) sobre mis hábitos digitales	que el motor de ML pueda recopilar las variables necesarias para clasificar mi nivel de ansiedad digital	Alta	5	No se ha iniciado
US-05	Estudiante universitario	responder preguntas sobre el tiempo de uso de mis dispositivos, redes sociales y carga académica virtual	que el sistema capture indicadores conductuales y tecnológicos como variables de entrada del modelo predictivo	Alta	5	No se ha iniciado
US-06	Estudiante universitario	guardar mi progreso y retomar el cuestionario si salgo de la plataforma sin completarlo	no perder mis respuestas y completar la evaluación en varios momentos según mi disponibilidad	Media	5	No se ha iniciado
US-07	Estudiante universitario	escribir libremente cómo me siento respecto al uso de tecnología en mis estudios en un campo de texto abierto	que el módulo de Procesamiento de Lenguaje Natural identifique indicadores emocionales como desesperanza o agotamiento en mi discurso	Alta	6	No se ha iniciado
US-08	Sistema (PLN)	preprocesar y vectorizar el texto ingresado por el estudiante usando técnicas de análisis de sentimientos	transformar el texto no estructurado en representaciones numéricas que el modelo Random Forest pueda procesar	Alta	6	No se ha iniciado
US-09	Sistema (PLN)	detectar automáticamente el idioma del texto ingresado y aplicar el preprocesamiento lingüístico correspondiente al argot universitario limeño	garantizar la precisión del análisis semántico en el contexto sociocultural de Lima Metropolitana	Media	6	No se ha iniciado
US-10	Sistema (ML Híbrido)	combinar las respuestas del cuestionario psicométrico con los vectores del análisis de texto en un único vector de características	alimentar el modelo Random Forest con datos multimodales que mejoren la precisión diagnóstica del nivel de ansiedad	Alta	7	No se ha iniciado
US-11	Sistema (ML Híbrido)	aplicar el modelo Random Forest entrenado para clasificar el nivel de ansiedad digital del estudiante en las categorías: Bajo, Moderado o Alto	emitir un diagnóstico predictivo explicable que el personal de Bienestar Universitario pueda interpretar y validar clínicamente	Alta	7	No se ha iniciado
US-12	Sistema (ML Híbrido)	aplicar reglas de conocimiento experto definidas por el psicólogo consultor como capa de validación sobre la salida del modelo	garantizar que el motor híbrido no emita clasificaciones que contradigan criterios clínicos fundamentales de salud mental	Alta	7	No se ha iniciado
US-13	Sistema (ML Híbrido)	generar un reporte de Importancia de Características (Feature Importance) que identifique los factores digitales con mayor influencia en el nivel de ansiedad	que el psicólogo consultor y el equipo de Bienestar puedan auditar y comprender las razones detrás de cada clasificación	Alta	7	No se ha iniciado
US-14	Estudiante universitario	recibir un informe personalizado con mi nivel de ansiedad detectado, los factores que más influyeron y recomendaciones de hábitos digitales saludables	tomar conciencia de mi situación emocional y contar con orientación concreta para reducir mi tecnoestrés	Alta	9	No se ha iniciado
US-15	Área de Bienestar Universitario	filtrar los resultados del dashboard por carrera, ciclo académico y rango de fechas	identificar patrones de ansiedad digital por cohorte y tomar decisiones estratégicas basadas en evidencia	Media	9	No se ha iniciado
US-16	Área de Bienestar Universitario	exportar reportes de los niveles de ansiedad en formato PDF o Excel para presentarlos en reuniones institucionales	documentar el impacto del sistema y sustentar la continuidad del proyecto ante las autoridades de la institución	Media	9	No se ha iniciado
US-17	Estudiante universitario	que todos mis datos de evaluación sean almacenados cifrados en reposo y en tránsito mediante protocolos seguros en AWS	garantizar que mi información de salud mental sea protegida conforme a la Ley N° 29733 de Protección de Datos Personales del Perú	Alta	5	No se ha iniciado
US-18	Estudiante universitario	poder solicitar la eliminación de mis datos personales y evaluaciones previas desde la plataforma	ejercer mis derechos ARCO (Acceso, Rectificación, Cancelación y Oposición) sobre mi información psicológica sensible	Media	8	No se ha iniciado
US-19	Equipo de Desarrollo	configurar un pipeline automatizado de reentrenamiento del modelo Random Forest cuando se acumule un nuevo lote de datos de estudiantes	mantener la precisión diagnóstica del sistema (F1-Score ≥ 85%) a medida que los patrones de ansiedad digital evolucionan en el tiempo	Alta	11	No se ha iniciado
US-20	Portafolio Manager	contar con un documento de Plan de Continuidad Operativa que describa los procedimientos de mantenimiento, escalabilidad y recuperación ante fallos del sistema	asegurar la disponibilidad, sostenibilidad y gobernanza del sistema de detección de ansiedad digital a largo plazo	Alta	11	No se ha iniciado

ESTADO	PRIORIDAD
No se ha iniciado	Alta
En curso	Media
Completado	Baja
Atrasado	
En espera	

CÓDIGO EDT	ACTIVIDADES	TAL		
		30/03 al 05/04	06/04 al 12/04	13/04 al 19/04
		1	2	3
1	INICIO			
1.1	Acta de Constitución del Proyecto			
1.1.1	Elaboración del Documento			
1.1.2	Entrega del Documento			
1.1.3	Aprobación del Documento			
2	PLANIFICACIÓN			
2.1	Product Backlog			
2.1.1	Definición de Historias de Usuario			
2.1.2	Definición de Criterios de Aceptación			
2.1.3	Priorización de Historias de Usuario			
2.1.4	Entrega del Documento			
2.1.5	Aprobación del Documento			
2.2	Plan de Gestión del Proyecto			
2.2.1	Definición de Gestión del Alcance (EDT)			
2.2.2	Definición de Gestión de Tiempo (Cronograma)			
2.2.3	Definición de Gestión de Recursos (Matriz Org.)			
2.2.4	Definición de Gestión de Riesgos			
2.2.5	Definición de Gestión de Costos (Presupuesto)			
2.2.6	Definición de Gestión de Calidad			
2.2.7	Entrega del Documento			
2.2.8	Aprobación del Documento			
3	EJECUCIÓN			
3.1	Sprint 0 — Plan 11, Problema, Product Backlog (H1: 30/03–26/04/2026)			
3.1.1	Sprint Planning			
3.1.2	Daily Scrum			
3.1.3	Identificación y descripción del problema			
3.1.4	Análisis del problema (Ishikawa, caso estudio)			
3.1.5	Formulación del problema y objetivos			
3.1.6	Grooming			
3.1.7	Sprint Review — H1 aprobado			
3.1.8	Sprint Retrospective			
3.2	Sprint 1 — Marco Teórico y Estado del Arte (H2: 27/04–09/05/2026)			
3.2.1	Sprint Planning			
3.2.2	Daily Scrum			
3.2.3	Marco Teórico — Definiciones y estándares			
3.2.4	Estado del Arte — Búsqueda sistemática (PRISMA)			
3.2.5	Análisis de resultados y discusión			

3.2.6	Grooming			
3.2.7	Sprint Review — H2 aprobado			
3.2.8	Sprint Retrospective			
3.2.9	H3: Trabajo de Investigación Parcial — Entrega			
3.2.10	H4: Sustentación Parcial — Taller de Desempeño Profesional			
3.3	Sprint 2 — Acta de Constitución del Proyecto (H5: 16/05–27/06/2026)			
3.3.1	Sprint Planning			
3.3.2	Daily Scrum			
3.3.3	Elaboración del Acta de Constitución v1.0			
3.3.4	Identificación de stakeholders y riesgos			
3.3.5	Benchmarking tecnológico			
3.3.6	Propuesta de solución y diseño de arquitectura			
3.3.7	Grooming			
3.3.8	Sprint Review — H5 Acta aprobada			
3.3.9	Sprint Retrospective			
3.4	Sprint 3 — Trabajo de Investigación Final (H6: 28/06–05/07/2026)			
3.4.1	Sprint Planning			
3.4.2	Correcciones post-sustentación parcial			
3.4.3	Integración TI Final (caps. 1–3 completos)			
3.4.4	Actualización referencias bibliográficas APA 7			
3.4.5	Sprint Review — H6 TI Final completado			
3.4.6	Sprint Retrospective			
3.4.7	H7: Sustentación Final — Taller de Desempeño Profesional			
3.5	Sprint 4 — Plan de Trabajo y User Stories (H8: 03/08–30/08/2026)			
3.5.1	Sprint Planning			
3.5.2	Daily Scrum			
3.5.3	Definición de arquitectura del sistema			
3.5.4	Definición y creación de BD (PostgreSQL)			
3.5.5	Configuración ambientes dev y pruebas (AWS)			
3.5.6	Grooming			
3.5.7	Sprint Review — H8 Plan de Trabajo aprobado			
3.5.8	Sprint Retrospective			
3.5.9	H10: Validación con Comité de Proyectos — User Stories (OE1-I1)			
3.6	Sprint 5 — Arquitectura y Evaluación Psicométrica (H9: 31/08–04/10/2026)			
3.6.1	Sprint Planning			
3.6.2	Daily Scrum			
3.6.3	US-01: Registro con correo institucional y perfil inicial			
3.6.3.1	Análisis y Diseño			
3.6.3.2	Implementación			
3.6.3.3	Pruebas Internas			
3.6.4	US-02: Inicio de sesión anónimo y seguro (JWT)			
3.6.4.1	Análisis y Diseño			
3.6.4.2	Implementación			
3.6.4.3	Pruebas Internas			
3.6.5	US-04/05: Cuestionario psicométrico TS4US/ASAIDAS y hábitos digitales			
3.6.5.1	Análisis y Diseño			

3.6.5.2	Implementación			
3.6.5.3	Pruebas Internas			
3.6.6	US-17: Cifrado de datos en reposo y tránsito (AWS / Ley 29733)			
3.6.6.1	Análisis y Diseño			
3.6.6.2	Implementación			
3.6.6.3	Pruebas Internas			
3.6.7	Integración de HU del Sprint			
3.6.8	Pruebas de Integración			
3.6.9	Grooming			
3.6.10	Sprint Review — Certificación QA Arq. (OE2-I1) / IT-SERVICE (OE2-I2)			
3.6.11	Sprint Retrospective			
3.7	Sprint 6 — Módulo PLN (H11: 05/10–01/11/2026)			
3.7.1	Sprint Planning			
3.7.2	Daily Scrum			
3.7.3	US-07: Campo de texto libre y análisis de sentimientos			
3.7.3.1	Análisis y Diseño			
3.7.3.2	Implementación			
3.7.3.3	Pruebas Internas			
3.7.4	US-08: Preprocesamiento y vectorización PLN			
3.7.4.1	Análisis y Diseño			
3.7.4.2	Implementación			
3.7.4.3	Pruebas Internas			
3.7.5	US-09: Detección de idioma y argot universitario limeño			
3.7.5.1	Análisis y Diseño			
3.7.5.2	Implementación			
3.7.5.3	Pruebas Internas			
3.7.6	Integración de HU del Sprint			
3.7.7	Pruebas de Integración			
3.7.8	Grooming			
3.7.9	Sprint Review — H11 Módulo PLN certificado (OE1-I2)			
3.7.10	Sprint Retrospective			
3.8	Sprint 7 — Motor ML Híbrido (H12: 02/11–15/11/2026)			
3.8.1	Sprint Planning			
3.8.2	Daily Scrum			
3.8.3	US-10: Fusión multimodal — vector psicométrico + PLN			
3.8.3.1	Análisis y Diseño			
3.8.3.2	Implementación			
3.8.3.3	Pruebas Internas			
3.8.4	US-11: Clasificación Random Forest (Bajo / Moderado / Alto)			
3.8.4.1	Análisis y Diseño			
3.8.4.2	Implementación			
3.8.4.3	Pruebas Internas			
3.8.5	US-12/13: Reglas expertas clínicas + Feature Importance			
3.8.5.1	Análisis y Diseño			
3.8.5.2	Implementación			
3.8.5.3	Pruebas Internas			

3.8.6	Integración de HU del Sprint			
3.8.7	Pruebas de Integración			
3.8.8	Grooming			
3.8.9	Sprint Review — H12 ML Híbrido integrado			
3.8.10	Sprint Retrospective			
3.8.11	H13: Sustentación Parcial — Taller de Proyectos I (OE1+OE2)			
3.8.12	H14: Sustentación Final — Taller de Proyectos I			
3.9	Sprint 8 — Validación Clínica del Modelo (H15: 18/01–14/02/2027)			
3.9.1	Sprint Planning			
3.9.2	Daily Scrum			
3.9.3	Pruebas con datos reales de estudiantes			
3.9.4	Cálculo de métricas F1-Score $\geq 85\%$ (K-Fold)			
3.9.5	Ajuste de hiperparámetros Random Forest			
3.9.6	Validación clínica con psicólogo consultor			
3.9.7	Grooming			
3.9.8	Sprint Review — H15: Certificación QA modelo (OE3-I1)			
3.9.9	Sprint Retrospective			
3.10	Sprint 9 — Dashboard y Retroalimentación (H16: 15/02–14/03/2027)			
3.10.1	Sprint Planning			
3.10.2	Daily Scrum			
3.10.3	US-14: Informe personalizado de ansiedad para el estudiante			
3.10.3.1	Análisis y Diseño			
3.10.3.2	Implementación			
3.10.3.3	Pruebas Internas			
3.10.4	US-15/16: Dashboard de Bienestar Universitario + filtros + exportación			
3.10.4.1	Análisis y Diseño			
3.10.4.2	Implementación			
3.10.4.3	Pruebas Internas			
3.10.5	Integración de HU del Sprint			
3.10.6	Pruebas de Integración			
3.10.7	Grooming			
3.10.8	Sprint Review — H16: Dashboard aprobado por UX			
3.10.9	Sprint Retrospective			
3.11	Sprint 10 — Validación con Bienestar Universitario (H17: 15/03–11/04/2027)			
3.11.1	Sprint Planning			
3.11.2	Daily Scrum			
3.11.3	US-18/19: Derechos ARCO y pipeline reentrenamiento			
3.11.3.1	Análisis y Diseño			
3.11.3.2	Implementación			
3.11.3.3	Pruebas Internas			
3.11.4	Informe validación clínica con Bienestar (OE3-I2)			
3.11.5	Actas cliente/usuario protocolos sostenibilidad (OE4-I2)			
3.11.6	Grooming			
3.11.7	Sprint Review — H17: Validación Bienestar completada			

3.11.8	Sprint Retrospective			
3.12	Sprint 11 — Plan de Continuidad Operativa (H18: 12/04–25/05/2027)			
3.12.1	Sprint Planning			
3.12.2	Daily Scrum			
3.12.3	US-20: Plan de Continuidad Operativa			
3.12.3.1	Análisis y Diseño			
3.12.3.2	Elaboración del documento			
3.12.3.3	Revisión Portafolio Manager (OE4-I1)			
3.12.4	Pipeline MLOps — reentrenamiento automático (SageMaker)			
3.12.5	Pruebas de disponibilidad y recuperación ante fallos			
3.12.6	Grooming			
3.12.7	Sprint Review — H18: Plan Continuidad aprobado			
3.12.8	Sprint Retrospective			
3.12.9	H19: Sustentación Parcial — Taller de Proyectos II (OE3+OE4)			
3.13	Sprint 12 — Memoria Final y Documentación (H20: 23/06–10/07/2027)			
3.13.1	Sprint Planning			
3.13.2	Daily Scrum			
3.13.3	Ajustes de Capítulo 1 — Definición del Problema			
3.13.4	Ajustes de Capítulo 2 — Marco Teórico			
3.13.5	Elaboración Cap. 3 — Outcomes ABET			
3.13.6	Elaboración Cap. 4 — Competencias Generales			
3.13.7	Elaboración Cap. 5 — Gestión del Proyecto			
3.13.8	Elaboración de Conclusiones y Recomendaciones			
3.13.9	Actualización de Referencias Bibliográficas APA 7			
3.13.10	Entrega del Documento — H20			
3.13.11	Aprobación del Documento			
3.13.12	H21: Sustentación Final — Taller de Proyectos II			
3.14	Artículo Científico (Short Paper)			
3.14.1	Definición de Conferencia			
3.14.2	Revisión de Plantilla de Conferencia			
3.14.3	Revisión de Artículos Científicos			
3.14.4	Redacción del Artículo			
3.14.5	Entrega del Artículo			
3.14.6	Aprobación del Artículo (Coautor)			
3.15	Memoria Final del Proyecto TP1			
3.15.1	Ajustes de Capítulo 1			
3.15.2	Ajustes de Capítulo 2			
3.15.3	Elaboración Cap. 3 — Outcomes ABET			
3.15.4	Elaboración Cap. 4 — Competencias			
3.15.5	Elaboración Cap. 5 — Gestión Proyecto			
3.15.6	Conclusiones y Recomendaciones			
3.15.7	Entrega y Aprobación del Documento			
4	SEGUIMIENTO Y CONTROL			
4.1	Actas de Reunión			


4.1.1	Reunión con Asesor Especializado (quincenal)			
4.1.2	Reunión con Coautor (mensual)			
4.2	Planner			
4.2.1	Actualización de Actividades (semanal)			
4.3	Presentaciones del Proyecto			
4.3.1	H4: Sustentación Parcial — Taller Desempeño Prof. (Metodológico)			
4.3.2	H7: Sustentación Final — Taller Desempeño Prof.			
4.3.3	H10: Validación Comité de Proyectos — TP1 (07/09/2026)			
4.3.4	H13: Sustentación Parcial — Taller de Proyectos I (16/11/2026)			
4.3.5	H14: Sustentación Final — Taller de Proyectos I (07/12/2026)			
4.3.6	H19: Sustentación Parcial — Taller de Proyectos II (26/05/2027)			
4.3.7	H21: Sustentación Final — Taller de Proyectos II (11/07/2027)			
5	CIERRE			
5.1	Acta de Cierre			
5.1.1	Elaboración del Acta de Cierre			
5.1.2	Entrega del Acta de Cierre			
5.2	Estructura de Carpetas SharePoint			
5.2.1	Definición de Estructura			
5.2.2	Carga de Documentos y Fuentes			
5.2.3	Validación de Documentos			


LEYENDA:


 Taller Desempeñ


ANEXO 1. PLAN DE DESEMPEÑO PROFESIONAL (SI639) — Mar 2026 – Jul 2026

[illegible]












NOGRAMA GENERAL DEL PROYECTO — PLATAFORMA WEB ML HÍBRIDO PARA DETE
Nuñez Alvarez, Sebastian Andre | Salazar Gutiérrez, Darwin Ka


TALLER DE PROYECTOS I (SI644) — Ago 2026 – Dic 2026


[illegible]















arl

[illegible]













[illegible]


[illegible]












[illegible]

[illegible]

[illegible]



[illegible]



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS
FACULTAD DE INGENIERÍA
PROGRAMA ACADÉMICO DE INGENIERÍA DE SISTEMAS DE INFORMACIÓN

Plataforma web basada en Machine Learning híbrido para la detección de la ansiedad digital en
estudiantes universitarios de Lima Metropolitana

ACTA DE CONSTITUCIÓN DEL PROYECTO

AUTOR(ES)

Núñez Alvarez, Sebastian Andre (0009-0001-1448-2552)

Salazar Gutiérrez, Darwin Karl (0009-0004-8184-2273)

ASESOR(ES)

Santisteban Pazos, José Luis (0000-0003-4526-642X)

Lima, 28 de junio del 2026

Historial de Revisiones

Versión	Fecha	Autor	Descripción
1.0	28/06/2026	Sebastian Nuñez Darwin Salazar	Primera versión del informe del acta de constitución del proyecto

INDICE

ACTA DE CONSTITUCIÓN DEL PROYECTO	4
1. RESUMEN EJECUTIVO	4
2. MARCO TEÓRICO.....	5
3. POSICIONAMIENTO.....	7
3.1. Planteamiento del Problema.....	7
3.2. Objetivos.....	7
3.2.1. Objetivo General.....	7
3.2.2. Objetivos Específicos.....	7
3.3. Indicadores de Éxito	8
3.4. Alcance del Proyecto	8
3.5. Suposiciones y Restricciones	9
4. ORGANIZACIÓN DEL PROYECTO	10
4.1. Equipo del Proyecto.....	10
4.2. Stakeholders y Usuarios.....	11
4.3. Recursos requeridos	12
4.4. Fases e Hitos del Proyecto	13
4.5. Enfoques del Trabajo	14
5. GLOSARIO	15
6. SIGLARIO	16
7. BIBLIOGRAFÍA	17
8. APROBACIÓN.....	18
9. ANEXOS	18

ACTA DE CONSTITUCIÓN DEL PROYECTO

1. RESUMEN EJECUTIVO

El proyecto que desenvolvemos tiene como objetivo crear e implementar una plataforma web de Machine Learning híbrido, estructurada en arquitecturas cloud, sosteniendo la proactividad, el acceso, y la intimidad en la detección de la ansiedad digital en los estudiantes universitarios de Lima Metropolitana. La propuesta enfatiza el estudio de las causas que originan la ineficiencia estructural a la hora de detectar el malestar emocional de los estudiantes universitarios, como por ejemplo la falta de arquitecturas digitales con capacidades predictivas, la escasa autoeficacia digital del/ de la usuario/a, el método de intervención fraccionado y reactivo de las instituciones, o el estigma que acompaña la búsqueda de ayuda psicológica de manera presencial. Dicha ineficacia provoca que más del 80% de los estudiantes con trastornos emocionales que no reciben atención, lo que influye en el rendimiento escolar y el bienestar general de los estudiantes. La investigación en modelos de Machine Learning híbridos, técnicas de Procesamiento de Lenguaje Natural (PLN), computación afectiva y marcos de intervención como la Terapia Cognitivo-Conductual Digital (iCBT), son un elemento relevante para la definición de un objetivo central que contribuya a orientar la propuesta hacia una posible solución tecnológica innovadora y ética al mismo tiempo. La plataforma de la presente propuesta buscará potenciar la detección de la ansiedad digital mediante predicciones procesadas en tiempo real y confiables, sobre la base de la autoeficacia académica del/ de la estudiante.

2. MARCO TEÓRICO

- **Ansiedad Digital y Tecnoestrés**

El tecnoestrés se define como un estado psicológico negativo consecuencia de la incapacidad de adaptarse a las nuevas tecnologías (Solano Castro y Núñez Lira, 2025). Este fenómeno se expresa en dimensiones como la tecno-fatiga, la tecno-ansiedad o el sentimiento de ineficacia informática. Por su parte, la ansiedad digital se entiende como el miedo a no estar al día tecnológicamente o a perder el control del uso de dispositivos y plataformas, lo que da lugar a una tensión permanente, es difícil desconectar y en la situación más extrema deviene en un burnout académico (Tudose, 2025). En el ámbito universitario peruano, el tecnoestrés emerge como un estado crónico que merma el bienestar emocional de los estudiantes, así como su rendimiento en un contexto de presión constante que se produce por la transformación digital (Morales-García et al., 2025).

- **Machine Learning Híbrido para Detección Afectiva**

El Machine Learning puede definirse como una de las áreas de estudio que se encuadran dentro del marco de la inteligencia artificial, cuyo objetivo es desarrollar modelos basados en algoritmos que le permitan a su vez extraer patrones de un conjunto de datos, pero sin tener que ser programados explícitamente para cada tarea (Organización Mundial de la Salud, 2024). La arquitectura híbrida es la evolución de los modelos monolíticos que integra diferentes técnicas del aprendizaje automático para tratar de paliar las carencias individuales de cada enfoque y alcanzar una mayor robustez diagnóstica (Mateus et al., 2026). En el ámbito de la salud digital esa arquitectura híbrida permite manejar e interpretar a la vez variables clínicas, conductuales y textuales, lo que resulta particularmente adecuado para problemáticas complejas como sería la detección de estados emocionales en el contexto universitario (Meneses Ayala et al., 2025).

- **Procesamiento de Lenguaje Natural (PLN)**

El Procesamiento de Lenguaje Natural es el campo de la inteligencia artificial cuya finalidad es permitir que las máquinas comprendan, analicen e incluso generen lenguaje humano de manera coherente (Ishfaq et al., 2025). El Procesamiento del Lenguaje Natural se encuentra en el punto de intersección entre la lingüística computacional y el aprendizaje profundo y su papel consiste, principalmente, en transformar texto no estructurado en representaciones numéricas que los algoritmos de ML son capaces de gestionar. En el ámbito de la salud mental, el PLN permite extraer indicadores de emociones como un sentir de desesperanza, falta de asistencia o aislamiento del discurso del alumno, para transformarlos en datos estructurados para la detección automatizada de estados de ansiedad (Wan et al., 2025).

- **Computación Afectiva**

La computación afectiva implica una disciplina que investiga el diseño y la implementación de sistemas que sean capaces de reconocer, interpretar y responder a la expresión de las emociones humanas (Baldassarri Santalucía, 2016). Su idea principal es

que las emociones son un factor decisivo tanto en la toma de decisiones como en la interacción persona-computadora, y que, por ende, incorporar las emociones dentro de los sistemas digitales permitiría que la respuesta del sistema sea más pertinente y de mejor calidad. El funcionamiento de los sistemas de computación afectiva implica el uso de señales afectivas que son captadas a través de diferentes canales, pero que se van a procesar para poder formalizar el comportamiento del sistema según la emoción del usuario. De esta forma, la respuesta que recibirá el usuario será adecuada y ajustada a las circunstancias (Chanchí-Golondrino et al., 2022).

- **Metodologías Ágiles (Scrum) y Arquitecturas Cloud**

La autoeficacia académica aludida por Anicama et al. (2025) se refiere a la duda que presenta el alumno frente a su creencia de confianza en su propia capacidad para organizar y llevar a cabo con éxito las acciones necesarias para conseguir el objetivo exigido en el aprendizaje. En el contexto de la transformación digital universitaria, la autoeficacia académica juega un papel de variable protectora hacia el tecnoestrés, dado que los alumnos con alta autoeficacia son capaces de afrontar los estresores tecnológicos, emplean estratégicamente las herramientas digitales y su estabilidad emocional se mantiene ante situaciones de alta exigencia académica. En cambio, una escasa autoeficacia digital predice una mayor frustración, un rechazo tecnológico y una mayor vulnerabilidad a caer en la ansiedad digital (Schutte y Li, 2025).

3. POSICIONAMIENTO

3.1. Planteamiento del Problema

Problema	Causas
<i>Deficiencia estructural en la detección proactiva de la ansiedad digital en estudiantes universitarios de Lima Metropolitana.</i>	• <i>Ausencia de arquitecturas digitales integradas con capacidad de monitoreo en tiempo real.</i> • <i>Plataformas institucionales reactivas y estáticas sin algoritmos predictivos.</i> • <i>Baja autoeficacia digital y sobreuso de dispositivos como predictores de vulnerabilidad psicológica.</i> • <i>Metodología de intervención fragmentada, episódica y tardía.</i> • <i>Estigma social que impide la búsqueda de ayuda psicológica presencial.</i> • <i>Más del 80% de estudiantes con trastornos emocionales sin tratamiento oportuno.</i>

3.2. Objetivos

3.2.1. Objetivo General

OG: Implementar una plataforma web basada en Machine Learning híbrido que permita detectar la ansiedad digital en estudiantes universitarios de Lima Metropolitana

3.2.2. Objetivos Específicos

OE1: Analizar los factores técnicos, psicológicos y contextuales que condicionan la aparición de ansiedad digital en estudiantes universitarios de Lima Metropolitana para definir las variables del modelo predictivo.

OE2: Diseñar la arquitectura de la plataforma web basada en Machine Learning híbrido, integrando módulos de PLN y computación afectiva para el procesamiento de datos textuales y conductuales en la nube.

OE3: Validar el modelo de Machine Learning híbrido mediante métricas de evaluación clínica y pruebas con datos reales de estudiantes universitarios de Lima Metropolitana, garantizando su precisión y pertinencia diagnóstica.

OE4: Elaborar un plan de continuidad operativa de la plataforma web que asegure la disponibilidad, escalabilidad y sostenibilidad del sistema de detección de ansiedad digital a largo plazo.

3.3. Indicadores de Éxito

Objetivo Específico	Indicador de Éxito
OE1-I1	Aprobación del acta de reunión con el cliente detallando las variables psicológicas, conductuales y tecnológicas identificadas como predictoras de la ansiedad digital en el entorno universitario.
OE1-I2	Aprobación del acta de reunión con el usuario validando el flujo actual de detección y atención de la ansiedad en el Departamento de Bienestar Universitario.
OE2-I1	Aprobación de la certificación de la arquitectura física y lógica del sistema de Machine Learning híbrido otorgada por el área de QA.
OE2-I2	Aprobación de la certificación del proceso de ingesta, preprocesamiento y gestión de datos en la nube otorgada por IT-SERVICE.
OE3-I1	Aprobación de la certificación del modelo de detección y las Historias de Usuario asociadas, con métricas de precisión superiores al 85%, otorgada por el área de QA.
OE3-I2	Aprobación del informe de validación clínica del modelo por parte del equipo de Bienestar Universitario, confirmando la pertinencia diagnóstica de los niveles de ansiedad detectados frente a casos reales.
OE4-I1	Aprobación del documento de Plan de Continuidad Operativa por parte del Portafolio Manager, detallando los procedimientos de mantenimiento, escalabilidad y recuperación ante fallos del sistema.
OE4-I2	Aprobación del acta de reunión con el cliente validando los protocolos de sostenibilidad y actualización continua del modelo de detección, asegurando su vigencia ante la evolución de los patrones de ansiedad digital.

3.4. Alcance del Proyecto

El proyecto contendrá lo siguiente:

- Documentación del Acta de Constitución del Proyecto.
- Plan de Trabajo.
- Documentación de la Gestión del Proyecto.
- Actas de reuniones con el Product Owner, Coautor y Portafolio Manager.
- Documentación de la implementación de la plataforma de detección de ansiedad digital.
- Documentación de la Arquitectura Física y Lógica del sistema basado en ML híbrido.
- Documentación del proceso de ingesta, limpieza y modelado de datos textuales y conductuales.
- Desarrollo del módulo de PLN y computación afectiva integrado en la plataforma web.
- Desarrollo del dashboard de visualización de niveles de ansiedad y retroalimentación para Bienestar Universitario.

Las exclusiones del proyecto son las siguientes:


- El proyecto no reemplaza la atención psicológica clínica presencial; es una herramienta de soporte y detección temprana.
- El sistema no se ejecutará de manera local; su funcionamiento será exclusivamente en la nube.
- El proyecto no contempla instituciones educativas fuera de Lima Metropolitana.

3.5. Suposiciones y Restricciones


Suposiciones	Descripción
<i>Acceso a participantes</i>	<i>Se cuenta con acceso a estudiantes universitarios de Lima Metropolitana dispuestos a interactuar con la plataforma y proveer datos de forma voluntaria y anónima.</i>
<i>Acceso a la nube</i>	<i>El equipo dispone de cuentas o servicios de nube (AWS/Firebase/Serverless) donde se alojará la plataforma y los modelos de ML.</i>
<i>Soporte institucional</i>	<i>Las IES colaboradoras cuentan con personal de Bienestar Universitario para validar el flujo de atención e interpretar los resultados de la plataforma.</i>
<i>Marco legal vigente</i>	<i>El manejo de datos de salud mental se realizará en conformidad con la Ley N° 29733 de Protección de Datos Personales del Perú y los estándares éticos de la OMS para IA en salud.</i>

Restricciones	Descripción
<i>Privacidad de datos</i>	<i>El sistema no podrá recopilar datos de salud mental identificables sin consentimiento informado explícito del usuario.</i>
<i>Ejecución del sistema</i>	<i>El sistema se ejecuta exclusivamente en la nube; no contempla instalación local.</i>

4. ORGANIZACIÓN DEL PROYECTO



4.1. Equipo del Proyecto



Rol	Miembro	Responsabilidades
Project Manager	Núñez Álvarez, Sebastian Andre	- Planifica, dirige y verifica el cumplimiento de los objetivos del proyecto. - Relación directa con el cliente y los stakeholders.
Scrum Master	Salazar Gutiérrez, Darwin Karl	- Gestiona y asegura que el proceso Scrum se lleva a cabo correctamente. - Diseña, entrena y valida los modelos de ML híbrido y los pipelines de datos.

4.2. Stakeholders y Usuarios

Stakeholders	Necesidades	Entregables
Comité de Proyectos	Revisar y validar los hitos establecidos del proyecto de detección de ansiedad digital.	Acta de Constitución del Proyecto Memoria del Proyecto Documento de Investigación
Cliente (IES Lima Metropolitana)	Delimitar el alcance, validar avances y asegurar que la solución detecte la ansiedad digital con precisión clínicamente relevante.	Propuesta de implementación de la plataforma de detección de ansiedad digital.
Portafolio Manager	Supervisar el avance del proyecto y retroalimentar sobre la orientación técnica y estratégica.	Acta de Constitución del Proyecto, Cronograma de Trabajo.

Usuarios	Necesidades	Entregables
Estudiantes universitarios	Acceder a una plataforma anónima y accesible que les permita identificar su nivel de ansiedad digital y recibir retroalimentación de soporte.	Plataforma web interactiva, módulo de retroalimentación personalizada.
Área de Bienestar Universitario	Visualizar indicadores de ansiedad digital de los estudiantes para mejorar la planificación de intervenciones psicopedagógicas.	Dashboard de detección de ansiedad, documentación de uso.

4.3. Recursos requeridos

Humano:

- Un recurso de IT-SERVICES
- Dos Ing. Sistemas de Información
- Un psicólogo consultor (validación clínica del modelo)

Hardware:

- 2 laptops con los siguientes requisitos mínimos:
- CPU: Core i7 - 10ma generación o superior
- RAM: 16 GB
- Disco Sólido SSD: 512 GB
- 1 Router con acceso a Internet de alta velocidad

Software:

- Entorno de desarrollo Python para Machine Learning (scikit-learn, TensorFlow, HuggingFace)
- Servicios cloud (AWS / Firebase)
- Herramientas de gestión ágil (Jira / Trello)

4.4. Fases e Hitos del Proyecto

#	Hito del proyecto	Fecha Estimada	Entregables incluidos	Prioridad
1	Sprint 0: Plan de Trabajo de Investigación	30/03/2026	Plan de TI / Identificación del problema /	Alta
2	Sprint 1: Desarrollo del Marco Teórico y Estado del Arte	27/04/2026	Capítulo 1 - Descripción e importancia del problema / Capítulo 2 - Marco Teórico	Alta
3	Trabajo de Investigación Parcial	10/05/2026	Capítulos 1, 2 del TI	Alta
4	Sustentación Parcial — Taller de Desempeño Profesional	15/05/2026	Exposición ante el docente del avance parcial del TI / Correcciones post-sustentación parcial	Alta
5	Sprint 2: Acta de Constitución del Proyecto	28/06/2026	Acta de Constitución v1.0 / Identificación de stakeholders / Alcance, riesgos e hitos definidos	Alta
6	Sprint 3: Trabajo de Investigación Final	05/07/2026	TI completo con todos los capítulos	Alta
7	Sustentación Final — Taller de Desempeño Profesional	06/07/2026	Exposición final ante el docente del trabajo final de TI	Alta
8	Sprint 4: Planificación del Proyecto	03/08/2026	Plan de Trabajo / Cronograma Scrum / User Stories priorizadas / Arquitectura preliminar del sistema	Alta
9	Sprint 5: Diseño de Arquitectura y Pipeline de Datos	31/08/2026	Arquitectura Física y Lógica del sistema / Diseño del pipeline de datos / Certificación QA de arquitectura (OE2-I1)	Alta
10	Hito: Validación con Comité de Proyectos	07/09/2026	Acta de Constitución v1.0 / Plan de Trabajo aprobado / User Stories validadas con el cliente (OE1-I1)	Alta
11	Sprint 6: Desarrollo del Módulo de PLN y Datos	05/10/2026	Módulo de PLN implementado / Ingesta y preprocesamiento de datos / Certificación IT-SERVICE (OE2-I2) / Acta con usuario (OE1-I2)	Alta
12	Sprint 7: Integración del Modelo ML Híbrido	02/11/2026	Modelo ML híbrido integrado con PLN y computación afectiva / Pruebas unitarias / Documentación técnica v1.0	Alta
13	Sustentación Parcial — Taller de Proyectos I	16/11/2026	OE1 y OE2 completados con sus indicadores aprobados / Avance del sistema demostrable	Alta

14	Sustentación Final — Taller de Proyectos I	07/12/2026	Sistema con módulos de PLN y ML híbrido funcionando / Documentación técnica completa	Alta
15	Sprint 8: Validación Clínica del Modelo	18/01/2027	Pruebas con datos reales / Métricas de precisión $\geq 85\%$ / Certificación QA del modelo (OE3-I1)	Alta
16	Sprint 9: Dashboard y Módulo de Retroalimentación	15/02/2027	Dashboard de visualización de ansiedad / Módulo de retroalimentación para Bienestar Universitario / Aprobación UX	Alta
17	Sprint 10: Validación con Bienestar Universitario	15/03/2027	Informe de validación clínica aprobado (OE3-I2) / Actas con cliente y usuario (OE4-I2)	Alta
18	Sprint 11: Plan de Continuidad Operativa	12/04/2027	Documento de Plan de Continuidad Operativa aprobado por Portafolio Manager (OE4-I1) / Protocolos de mantenimiento y escalabilidad	Alta
19	Sustentación Parcial — Taller de Proyectos II	26/05/2027	OE3 y OE4 completados / Plataforma integrada y validada / Todos los indicadores de éxito aprobados	Alta
20	Sprint 12: Cierre, Pruebas Finales y Memoria	23/06/2027	Memoria final del proyecto / Correcciones post-sustentación parcial / Documentación completa del sistema	Alta
21	Sustentación Final — Taller de Proyectos II	11/07/2027	Plataforma web desplegada / Memoria final aprobada / Exposición ante el Comité y Portafolio Manager	Alta

4.5. Enfoques del Trabajo

Para la elaboración de este trabajo se va a utilizar la Metodología Ágil Scrum, un conjunto de buenas prácticas para aplicar el trabajo en equipo de forma colaborativa, y obtener el mejor resultado posible de un proyecto. Así, estas prácticas se apoyan entre sí. A su vez, la selección de este conjunto de buenas prácticas tiene su origen en un estudio de la forma de trabajar de equipos de muy buena productividad.

Scrum establece entregas parciales y regulares del producto final, priorizadas por el beneficio que producen al receptor del proyecto. Por esta razón, Scrum es muy útil para proyectos en entornos complejos, donde se quiere obtener el resultado lo antes posible, donde los requerimientos cambian o son poco fijados, y donde prima la innovación, la competitividad, la flexibilidad y la productividad. Puesto que el desarrollo de un modelo de ML para la detección de ansiedad implica iteraciones continuas de entrenamiento y validación, Scrum es la respuesta más adecuada.

4.6. Riesgos y Mitigación

#	Riesgo	Probabilidad	Impacto	Estrategia de mitigación
1	Sesgos o insuficiencia en los datos de entrenamiento del modelo de ML.	50%	Alta	Aplicar técnicas de aumento de datos, validar con expertos clínicos y solicitar datasets complementarios de entornos universitarios similares.
2	Dificultades técnicas en la implementación del modelo híbrido o la infraestructura cloud.	50%	Medio	Consultar con el equipo de TI; realizar pruebas progresivas; capacitarse en las herramientas de ML y cloud necesarias.
3	Baja participación de estudiantes por desconfianza en el manejo de sus datos de salud mental.	40%	Alto	Garantizar anonimato total, comunicar claramente la política de privacidad y cumplimiento de la Ley N° 29733, y diseñar la plataforma con enfoque de confianza.
4	Baja precisión del modelo en las primeras iteraciones de detección.	30%	Medio	Ajustar hiperparámetros, incluir nuevas variables relevantes, mejorar el preprocesamiento de datos y validar con el equipo de Bienestar Universitario.
5	Incumplimiento de acuerdos establecidos con el cliente o áreas usuarias.	40%	Alto	Agendar sesiones de revisión periódicas; llevar actas y minutas para asegurar claridad en los compromisos.

5. GLOSARIO

Término	Descripción
Ansiedad Digital	Estado psicológico de malestar caracterizado por el miedo a no estar tecnológicamente actualizado, la hiperconectividad compulsiva o la incapacidad de desconectarse del entorno digital, que puede derivar en burnout académico.
Machine Learning Híbrido	Arquitectura que combina múltiples técnicas de aprendizaje automático (NLP, modelos predictivos estadísticos, técnicas de ensamble) para mejorar la robustez y precisión diagnóstica frente a un único método.
PLN (Procesamiento de Lenguaje Natural)	Campo de la IA que permite a las máquinas interpretar, analizar y generar lenguaje humano para la identificación de indicadores emocionales y de salud mental.
Computación Afectiva	Diseño de sistemas capaces de reconocer, procesar y responder a las emociones humanas, dotando a las máquinas de capacidad de 'empatía artificial'.
Autoeficacia Académica	Creencia del estudiante en sus propias capacidades para organizar y ejecutar con éxito las acciones necesarias para lograr sus metas académicas; actúa como factor protector frente al tecnoestrés.

6. SIGLARIO

Sigla	Descripción
ML	Machine Learning
IA	Inteligencia Artificial
PLN	Procesamiento de Lenguaje Natural
NLP	Natural Language Processing
OG	Objetivo General
OE	Objetivo Específico
IES	Institución de Educación Superior
iCBT	Internet-based Cognitive Behavioral Therapy
TAM	Technology Acceptance Model
AWS	Amazon Web Services
QA	Quality Assurance
UX	User Experience
CPU	Central Processing Unit
RAM	Random Access Memory
API	Application Programming Interface

7. BIBLIOGRAFÍA

- Anicama, J., Calderón, R., Javier-Aliaga, D., Caballero, G., Talla, K., Pizarro, R., Calizaya-Milla, Y. E., & Saintila, J. (2025). Self-efficacy and stress as predictors of anxiety in Peruvian and Mexican university students: a cross-sectional study. *Frontiers in Education*, 10. <https://doi.org/10.3389/educ.2025.1423406>
- Baldassarri Santalucía, S. (2016). Computación afectiva: tecnología y emociones para mejorar la experiencia del usuario. *Bit & Byte*, 2(3), 14–15. <http://sedici.unlp.edu.ar/handle/10915/53441>
- Chanchí-Golondrino, G. E., Ospina-Alarcón, M., & Sarria-López, L. (2022). Aplicación de la computación afectiva en el análisis de la percepción de los asistentes a una feria de emprendimiento del SENA. *Revista Científica*, 44(2), 215–227. <https://doi.org/10.14483/23448350.18288>
- Choudhary, L., & Sybol, S. S. (2026). Impact of AI on students' mental health and well-being. *Journal of Learning and Educational Technology*, 3(1). <https://doi.org/10.1007/s44217-026-00189-x>
- Ishfaq, U., Khan, H. U., & Iqbal, S. (2025). Sentiment analysis and mental health detection using natural language processing: A systematic review. *Computers in Human Behavior Reports*, 17, 100562. <https://doi.org/10.1016/j.chbr.2025.100562>
- Mateus, J. C., Atarama-Rojas, T., & Palomino-Flores, P. (2026). Hybrid machine learning frameworks for affective computing in educational contexts. *Computers & Education: Artificial Intelligence*, 8, 100395. <https://doi.org/10.1016/j.caeai.2026.100395>
- Meneses Ayala, C., García Flores, R., & Torres Sánchez, M. (2025). Machine learning for early diagnosis in digital health environments: A scoping review. *Digital Health*, 11. <https://doi.org/10.1177/20552076251320147>
- Morales-García, W. C., Ruiz-Mamani, P. G., Sairitupa-Santisteban, L. Z., & Morales-García, S. B. (2025). Anxiety toward artificial intelligence and digital dependence in Peruvian university students. *Computers in Human Behavior*, 154, 108156. <https://doi.org/10.1016/j.chb.2025.108156>
- Organización Mundial de la Salud. (2024). *Ethics and governance of artificial intelligence for health: Guidance on large multi-modal models*. WHO. <https://www.who.int/publications/i/item/9789240092228>
- Schutte, N. S., & Li, Y. (2025). Academic self-efficacy and curiosity as predictors of healthy AI adoption among university students. *Computers & Education*, 211, 105167. <https://doi.org/10.1016/j.compedu.2025.105167>
- Solano Castro, L., & Núñez Lira, L. A. (2025). Tecnoestrés y sus dimensiones en estudiantes universitarios de Lima Metropolitana. *Propósitos y Representaciones*, 13(1), e1872. <https://doi.org/10.20511/pyr2025.v13n1.1872>

- Tudose, C. (2025). Digital anxiety, technostress and academic burnout in higher education students. *International Journal of Environmental Research and Public Health*, 22(3), 412. <https://doi.org/10.3390/ijerph22030412>
- Wan, Q., Li, X., Zhang, Y., & Chen, H. (2025). Deep learning models for mental health detection from social media: A systematic review. *Artificial Intelligence in Medicine*, 151, 102867. <https://doi.org/10.1016/j.artmed.2025.102867>

8. APROBACIÓN

Nombre	Cargo	Firma	Fecha
Núñez Alvarez, Sebastian Andre	Project Manager		28/06/2026
Salazar Gutiérrez, Darwin Karl	Scrum Master		28/06/2026

9. ANEXOS



UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS
FACULTAD DE INGENIERÍA
PROGRAMA ACADÉMICO DE INGENIERÍA DE SISTEMAS DE
INFORMACIÓN

Plataforma TI basada en Machine Learning híbrido para la detección de la
ansiedad digital en estudiantes universitarios de Lima Metropolitana

Para optar el grado de bachiller en Ingeniería de Sistemas de Información

BENCHMARKING

AUTOR(ES)

Núñez Alvarez, Sebastian Andre (0009-0001-1448-2552)

Salazar Gutiérrez, Darwin Karl (0009-0004-8184-2273)

ASESOR(ES)

Santisteban Pazos, José Luis (0000-0003-4526-642X)

Lima, [28 de junio de 2026]

ÍNDICE

1. INTRODUCCIÓN.....	3
2. OBJETIVO DEL BENCHMARKING.....	4
3. BENCHMARKING DE FRAMEWORKS DE BACKEND.....	6
3.1. Criterios y Parámetros de Medición.....	8
3.2. Comparación de Propuestas.....	9
3.3. Análisis de Alternativas.....	11
3.4. Selección de Alternativa.....	14
4. BENCHMARKING DE FRAMEWORKS DE FRONTEND.....	15
4.1. Criterios y Parámetros de Medición.....	15
4.2. Comparación de Propuestas.....	17
4.3. Análisis de Alternativas.....	18
4.4. Selección de Alternativas.....	21
5. BENCHMARKING DE BASE DE DATOS.....	22
5.1. Criterios y Parámetros de Medición.....	22
5.2. Comparación de Propuestas.....	24
5.3. Análisis de Alternativas.....	25
5.4. Selección de Alternativa.....	29
6. BENCHMARKING DE LENGUAJES DE PROGRAMACIÓN.....	30
6.1. Criterios y Parámetros de Medición.....	30
6.2. Comparación de Propuestas.....	33
6.3. Análisis de Alternativas.....	34
6.4. Selección de Alternativa.....	37
7. BENCHMARKING DE ALGORITMOS DE MACHINE LEARNING.....	38
7.1. Criterios y Parámetros de Medición.....	38
7.2. Comparación de Propuestas.....	40
7.3. Análisis de Alternativas.....	42
7.4. Selección de Alternativa.....	45
8. BENCHMARKING DE MÉTRICAS DE EVALUACIÓN (MACHINE LEARNING).....	46
8.1. Criterios y Parámetros de Medición.....	46
8.2. Comparación de Propuestas.....	48
8.3. Análisis de Alternativas.....	50
8.4. Selección de Alternativa.....	52
9. BENCHMARKING DE INFRAESTRUCTURA CLOUD.....	53
9.1. Criterios y Parámetros de Medición.....	53
9.2. Comparación de Propuestas.....	56
9.3. Análisis de Alternativas.....	57
9.4. Selección de Alternativa.....	61
10. CONCLUSIONES.....	62
11. REFERENCIAS BIBLIOGRÁFICAS.....	63

1. INTRODUCCIÓN

El acelerado proceso de sensorización digital del entorno académico viene acompañado de la emergencia de fenómenos psicológicos y conductuales inadecuados; la existencia de la ansiedad digital y el tecnoestrés. En particular, para el caso de los estudiantes de educación superior de Lima Metropolitana, la hiperconectividad y la carga académica virtual, así como el uso descontrolado de la tecnología en el entorno universitario están determinando adversamente el bienestar en la salud mental y las notas finales. Si bien se cuenta con un número creciente de recursos en el contexto de la salud digital (mHealth) y aplicaciones para el cribado, el estado del arte pone de manifiesto que muchas de estas propuestas son bio-psico-socialmente poco efectivas: o bien son calificaciones sin intervenciones sostenidas, o bien comparten un diseño estructural de alta vulnerabilidad para la privacidad de los datos clínicos -como api públicas o arquitecturas monolíticas-, o bien utilizan modelos de inferencia supervisada en inteligencia artificial no explicables (cajas negras, black boxes).

Para abordar esta problemática interdisciplinaria, el presente proyecto propone construir una Plataforma TI híbrida de Machine Learning para la detección de la ansiedad digital en estudiantes universitarios de Lima Metropolitana . Para asegurar que el diseño de esta solución sea técnica, funcional y éticamente superior a las alternativas existentes, es imperativo someter las tecnologías actuales a un proceso de evaluación riguroso.

En este contexto, el presente documento de *benchmarking* se establece como un pilar metodológico fundamental para la toma de decisiones tecnológicas del proyecto. Su objetivo es llevar a cabo un análisis comparativo de las principales plataformas, arquitecturas de software, marcos de trabajo (frameworks) y modelos algorítmicos extraídos a partir de la literatura científica más actual. A través de la comparación de variables críticas tales como la exactitud diagnóstica, el tiempo de implementación, la escalabilidad, la complejidad técnica y un cumplimiento de los estándares de seguridad, como la norma ISO 27001, se podrán identificar las brechas tecnológicas del mercado actual.

En última instancia, estos resultados derivados del análisis comparativo servirán de soporte empírico/técnico para justificar la adopción de una arquitectura de microservicios y el modelo de Machine Learning híbrido, garantizando así la construcción de una plataforma segura, escalable

y culturalmente adaptada a las necesidades del entorno universitario local.

2. OBJETIVO DEL BENCHMARKING

El objetivo del benchmarking aquí presente, se centra en el hecho de analizar, comparar y seleccionar, de manera sistemática y fundamentada, las alternativas tecnológicas más adecuadas para el diseño, realización y puesta en marcha de la "Plataforma TI basada en Machine Learning híbrido para la detección de la ansiedad digital en estudiantes universitarios de Lima Metropolitana". En este proceso de evaluación se busca asegurar los componentes de software, los lenguajes, los algoritmos de aprendizaje automático, las métricas de validación estadística y la infraestructura en la nube más adecuadas para la puesta en marcha de la plataforma con la voluntad de superar las deficiencias clínicas y técnicas que resulten a partir del estado del arte, garantizando la construcción de una solución que antepone la privacidad de los datos sensibles, la interpretabilidad de las predicciones y garantice la construcción de una solución escalable, de alta disponibilidad y con diseño de seguridad por defecto (*security by design*), capaz de gestionar flujos asíncronos de datos psicométricos con latencia mínima y respetando todo el tiempo las normativas de protección de la información sensible en materia de salud mental.

Para poder alcanzar este propósito y dar una organización a una evaluación integral que cubriera todas las láminas de la ingeniería del proyecto, goza el benchmarking de una evaluación comparativa que se estructura en siete objetivos específicos de evaluación, los cuales darán pie a las siguientes secciones.

1. **Determinar el núcleo arquitectónico del servidor (Backend):** Evaluar los principales entornos de ejecución para seleccionar una tecnología que ofrezca un manejo nativo de microservicios, aislamiento de procesos y una capa de seguridad corporativa capaz de mitigar riesgos críticos de inyección y vulnerabilidades estructurales en la lógica de negocio.
2. **Optimizar la experiencia del usuario final (Frontend Web):** Analizar entornos de desarrollo en el cliente web con el fin de seleccionar un *framework* orientado a componentes que reduzca el tiempo de carga de la aplicación y la fricción interactiva, previniendo que la latencia del sistema se convierta en un factor tecnológico desencadenante de estrés o ansiedad en el estudiante.

3. **Garantizar la soberanía y persistencia de datos clínicos (Base de Datos):** Evaluar motores de almacenamiento de datos para identificar una solución híbrida que concilie el estricto cumplimiento de las propiedades ACID (Consistencia, Integridad, Aislamiento y Durabilidad) con la flexibilidad computacional requerida para indexar estructuras de datos JSON y vectores procedentes del análisis analítico.
4. **Asegurar la viabilidad y agilidad del modelado analítico (Lenguaje de Programación):** Estudiar los ecosistemas de programación de mayor madurez para seleccionar el lenguaje que centralice las herramientas matemáticas, de manipulación matricial de datos y de prototipado rápido para estructurar el cerebro predictivo del sistema.
5. **Consolidar la transparencia y precisión del diagnóstico (Algoritmo de Machine Learning):** Analizar modelos de aprendizaje supervisado aplicados a la clasificación clínica, priorizando soluciones que ofrezcan un balance óptimo entre la capacidad de generalizar relaciones multivariantes complejas en cuestionarios de salud y el principio de explicabilidad (importancia de características), permitiendo que el personal psicológico audite y valide las razones detrás de cada nivel de riesgo emitido.
6. **Blindar el rendimiento predictivo ante el desbalance de datos (Métrica de Evaluación):** Evaluar indicadores estadísticos de rendimiento para seleccionar la métrica de validación que oriente el entrenamiento del algoritmo, asegurando una penalización rigurosa de los falsos negativos sin saturar el sistema con alertas erróneas que agoten los recursos de los centros de orientación universitaria.
7. **Sustentar la resiliencia y el cumplimiento normativo local (Infraestructura Cloud):** Comparar los principales proveedores de servicios en la nube para definir un entorno de despliegue que responda de forma elástica a las demandas de concurrencia masiva (típicas de los periodos de exámenes parciales y finales) y que cumpla estrictamente con la Ley N.º 29733 (Ley de Protección de Datos Personales en el Perú) mediante servicios gestionados de cifrado avanzado de datos en reposo y en tránsito.

La consecución de estos objetivos permitirá justificar técnicamente cada decisión arquitectónica de la propuesta final, alineando las capacidades del software con las necesidades psicológicas y de privacidad del usuario universitario local.

3. BENCHMARKING DE FRAMEWORKS DE BACKEND

En esta sección se evalúan seis soluciones tecnológicas orientadas al soporte de salud mental y el bienestar digital. El propósito es contrastar la arquitectura y funcionalidad de diversas plataformas, identificando sus aportes y limitaciones frente a los requerimientos del presente proyecto. Las propuestas seleccionadas han sido elegidas por su relevancia en el estado del arte y su aplicabilidad en entornos educativos o de salud, proporcionando una base empírica para la arquitectura de nuestra plataforma.

A continuación, se presentan las propuestas que serán parte de la evaluación:

Tabla 1
Propuestas seleccionadas para el Benchmarking de Backend

Propuesta	Descripción	Fuente (cita en APA 7)
Here for You	Aplicación móvil de cribado de salud mental co-diseñada con estudiantes, enfocada en la validación clínica mediante escalas como la DASS-21, con medidas de seguridad de nivel bancario.	Sethi et al. (2026)
SocialBullyAlert	Aplicación web Full-Stack (Angular/PostgreSQL) diseñada para detectar ciberacoso y comportamientos de riesgo mediante procesamiento de lenguaje natural en redes sociales.	Nina-Gutiérrez et al. (2024)

Limbic Care	Intervención basada en Terapia Cognitivo-Conductual (TCC) que utiliza una "capa cognitiva" algorítmica para asegurar respuestas clínicas precisas mediante IA generativa.	McFadyen et al. (2026)
AMRIA-U	Framework adaptativo de salud mental diseñado específicamente para universidades con bajos recursos, optimizado para ejecutarse localmente sin depender de la nube.	Baena-Navarro et al. (2025)
Tampu	Sistema integrado de aplicación móvil y wearable (reloj inteligente) para la detección proactiva de ataques de ansiedad mediante biometría en tiempo real.	Curi et al. (2025)
DEPLOYR	Arquitectura escalable de orquestación en la nube (Microsoft Azure) para el despliegue concurrente de modelos predictivos en el marco de la terapia cognitivo-conductual.	Schmidt et al. (2024)

Esta selección, en la Tabla 1, abarca desde enfoques puramente clínicos (Here for You) hasta infraestructuras complejas de orquestación en la nube (DEPLOYR), cubriendo el espectro tecnológico necesario para evaluar nuestra arquitectura de microservicios.

3.1. Criterios y Parámetros de Medición

Para realizar una evaluación objetiva de los frameworks candidatos (**Spring Boot, Django, Laravel, Node.js**), se han definido cinco criterios técnicos que determinan la viabilidad de la plataforma frente a los requisitos de seguridad, escalabilidad y procesamiento de datos exigidos por un sistema de salud mental.

Tabla 2
Definición de criterios y parámetros de medición

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Rendimiento	Capacidad del backend para gestionar la concurrencia de estudiantes y la latencia del modelo ML.	Escala	[1–5]	1 = Latencia alta; 5 = Alta concurrencia y respuesta inmediata.	(Schmidt et al., 2024)
2	Seguridad	Aplicación de cifrado extremo a extremo y cumplimiento de normativas de datos clínicos.	Escala	[1–5]	1 = Vulnerable; 5 = Cumplimiento total ISO 27001/GDPR.	(Sethi et al., 2026)

C1: Rendimiento	-	1	1	1	1	0	4	30%
C2: Seguridad	0	-	1	1	1	0	3	20%
C3: Escalabilidad	0	0	-	1	1	1	3	20%
C4: Integración IA	0	0	0	-	1	1	2	15%
C5: Privacidad	0	0	0	0	-	1	1	5%
C6: Complejidad	1	1	0	0	0	-	2	10%
TOTAL							15	100%

Nota. Los valores se basan en la comparativa de importancia relativa para un entorno universitario local donde la seguridad y la escalabilidad son críticas. El valor 1 indica que el criterio de la fila es más importante que el de la columna.

Tabla 4
Matriz de Priorización

Criterio	Impacto	Frameworks para backend							
		Django		Spring Boot		Laravel		Koa	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento	30%	4	1.20	5	1.50	5	1.50	3	0.90

Seguridad	20%	5	1.00	5	1.00	4	0.80	5	1.00
Escalabilidad	20%	4	0.80	5	1.00	4	0.80	3	0.60
Integración IA	15%	4	0.60	5	0.75	3	0.45	4	0.60
Privacidad	5%	4	0.20	5	0.25	4	0.20	3	0.15
Complejidad	10%	3	0.30	4	0.40	3	0.30	3	0.30
Promedio Total	100%	-	4.10	-	4.90	-	4.05	-	3.55

Nota. Se ha esencialmente establecido el valor de 1 a 5 en la respectiva tabla de parámetros de la medición y el Impacto que está en % se obtiene de la columna Ponderación de la Matriz de Enfrentamiento.

3.3. Análisis de Alternativas

Esta sección detalla la evaluación cualitativa de los frameworks seleccionados, justificando las puntuaciones asignadas en la matriz anterior y analizando cómo cada tecnología responde a los desafíos de la ansiedad digital.

Tabla 5

Cuadro de Análisis de Alternativas por Criterio (Backend)

Criterio	Impacto	Evaluación
----------	---------	------------

Rendimiento	30%	Spring Boot destaca con 5 puntos gracias a su arquitectura optimizada para el procesamiento concurrente de datos. Django y Curi et al. (2025) con su enfoque en Python logran un 4, siendo eficientes pero con mayor consumo de memoria, mientras que Koa obtiene un 3 debido a su naturaleza asíncrona que puede degradarse bajo cargas intensas.
Seguridad	20%	Spring Boot y Django lideran con 5 puntos debido a sus capas robustas de seguridad (Spring Security y Django Security), mitigando de forma nativa riesgos de inyección SQL y CSRF. Laravel y los enfoques basados en McFadyen et al. (2026) logran 4 al ofrecer buenas prácticas, mientras que Koa obtiene un 3 por requerir configuraciones de seguridad externas adicionales.
Escalabilidad	20%	Spring Boot sobresale con 5 al ser el estándar de facto para arquitecturas de microservicios, facilitando la descentralización requerida por Schmidt et al. (2024). Django y Laravel alcanzan 4 puntos por su solidez en proyectos grandes, mientras que Koa (3) requiere una gestión más compleja de la modularidad para escalar de forma eficiente.

Integración IA	15%	Spring Boot y los enfoques de Curi et al. (2025) obtienen 5 puntos; el primero por su interoperabilidad mediante REST APIs robustas, y el segundo por la ejecución nativa de modelos en entornos de borde. Django logra 4 por su ecosistema nativo en Python, mientras que Laravel (3) presenta una mayor fricción técnica para invocar modelos complejos.
Privacidad	5%	Curi et al. (2025) y Baena-Navarro et al. (2026) lideran con 5 puntos al permitir el procesamiento local (privacidad por diseño). Spring Boot logra 5 puntos por su capacidad de cifrado de extremo a extremo, superando a Django (4) y Nina-Gutiérrez et al. (2024) (2), quienes dependen más frecuentemente de servicios en la nube de terceros.
Complejidad	10%	Django y los enfoques de McFadyen et al. (2026) obtienen 4 puntos por su curva de aprendizaje más amigable. Spring Boot (4) requiere mayor especialización técnica, pero su documentación compensa este esfuerzo. Koa y las arquitecturas de Schmidt et al. (2024) reciben 3 puntos debido a la alta complejidad técnica necesaria para configurar su orquestación.

3.4. Selección de Alternativa

De acuerdo con el análisis realizado, la propuesta más adecuada para emplear en el desarrollo del backend es **Spring Boot**, con un puntaje promedio de **4.90**.

Esta selección se justifica por su capacidad nativa para orquestar microservicios, lo que responde directamente a la arquitectura escalable propuesta por Schmidt et al. (2024). Asimismo, su ecosistema de seguridad (*Spring Security*) garantiza el cumplimiento de los estándares de protección de datos clínicos identificados como críticos en Sethi et al. (2026). La superioridad de Spring Boot en la **Integración con IA** radica en su capacidad para invocar servicios de inferencia (modelo híbrido) mediante *gRPC* o *RESTful APIs* con una latencia mínima, superando a frameworks como Laravel o Koa que dependen en mayor medida de módulos externos. Esta elección representa la alternativa más equilibrada para una plataforma de detección de ansiedad digital que exige tanto rigor técnico como cumplimiento normativo.

4. BENCHMARKING DE FRAMEWORKS DE FRONTEND

El desarrollo de la capa de presentación (Frontend) para la plataforma web de detección de ansiedad digital exige tecnologías capaces de operar de manera asíncrona y fluida en navegadores de escritorio y móviles. Al tratarse de una solución orientada a la psicología clínica y el bienestar estudiantil, la plataforma web debe funcionar como una *Single Page Application* (SPA) para evitar recargas completas de página que generen latencia y fricción cognitiva en el usuario. Asimismo, el *framework* web seleccionado debe facilitar la construcción de interfaces accesibles, modulares y contar con un ecosistema maduro para la visualización gráfica de los resultados generados por el modelo de *Machine Learning* híbrido alojado en el backend (Spring Boot). En este capítulo se evaluarán las herramientas más prominentes del mercado para determinar cuál se ajusta mejor a estos requerimientos técnicos y psicológicos.

4.1. Criterios y Parámetros de Medición

Para realizar una evaluación objetiva de los frameworks candidatos (**React, Angular, Vue.js y Svelte**), se han definido seis criterios técnicos que determinan la viabilidad de la plataforma frente a los requisitos de experiencia de usuario (UX), rendimiento, consumo de API en servicios asincrónicos y, de manera crítica, la protección de la información clínica del estudiante. .

Tabla 6

Definición de criterios y parámetros de medición para frameworks de frontend

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Rendimiento y Carga	Velocidad de renderizado del DOM y tiempo de carga inicial de la aplicación (SPA).	Escala	[1–5]	1 = Renderizado lento; 5 = Carga eficiente y manipulación del DOM optimizada.	(Schmidt et al., 2024)

2	Usabilidad y UX/UI	Facilidad del framework para implementar interfaces accesibles, limpias y empáticas.	Escala	[1–5]	1 = Componentes rígidos; 5 = Alta flexibilidad para diseños centrados en el usuario.	(McFadyen et al., 2026)
3	Escalabilidad de Arq.	Capacidad de mantener una arquitectura limpia y tipada a medida que la plataforma crece.	Escala	[1–5]	1 = Código monolítico propenso a errores; 5 = Arquitectura estricta y altamente escalable.	(Nina-Gutiérrez et al., 2024)
4	Integración de APIs	Facilidad para gestionar flujos asíncronos y consumir los microservicios REST del backend.	Escala	[1–5]	1 = Dependencia de librerías de terceros; 5 = Integración asíncrona nativa y robusta.	(Curi et al., 2025)
5	Seguridad Frontend	Medidas de protección integradas contra vulnerabilidades web (ej. Cross-Site Scripting - XSS).	Escala	[1–5]	1 = Requiere parches manuales externos; 5 = Saneamiento y seguridad nativa del DOM.	(Sethi et al., 2026)

6	Ecosistema (Visual)	Disponibilidad de librerías para renderizar gráficos y dashboards de resultados del modelo predictivo.	Escala	[1–5]	1 = Ecosistema pobre; 5 = Abundantes librerías de visualización de datos.	(Baena-Navarro et al., 2025)
---	----------------------------	--	--------	-------	---	------------------------------

4.2. Comparación de Propuestas

Para determinar la relevancia de cada criterio dentro del desarrollo del *frontend*, se elabora la Matriz de Enfrentamiento. Dado que la plataforma web se integrará con un backend robusto y procesará diagnósticos clínicos de salud mental (ansiedad), se le otorga la mayor prioridad a la **Escalabilidad de Arquitectura** y a la **Integración de APIs**, así como a la **Seguridad Frontend**, asegurando un entorno tipado, estable y protegido.

Tabla 7

Matriz de Enfrentamiento de Criterios de Frontend (Obtención de Ponderación)

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Rendimiento y Carga	-	0	0	0	1	0	1	10%
C2: Usabilidad y UX/UI	1	-	0	0	1	1	3	15%
C3: Escalabilidad de Arq.	1	1	-	1	1	1	5	30%
C4: Integración de APIs	1	1	0	-	1	1	4	25%

C5: Seguridad Frontend	0	0	0	0	-	1	1	10%
C6: Ecosistema (Visual)	1	0	0	0	0	-	1	10%
TOTAL							15	100%

Nota. El valor 1 indica que el criterio de la fila es más importante que el de la columna. Los criterios C3 y C4 obtienen el mayor peso para garantizar la integridad en la comunicación asíncrona de los modelos predictivos y mantener un código libre de vulnerabilidades.

4.3. Análisis de Alternativas

Con los porcentajes de impacto definidos, se procede a evaluar los tres principales *frameworks* de *frontend* del mercado (**Angular, React y Vue.js**) para determinar cuál cumple de manera óptima con los requerimientos técnicos.

Tabla 8

Matriz de Priorización de Frameworks de Frontend

Criterio	Impacto	Frameworks para frontend					
		Angular		React		Vue.js	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento y Carga	10%	4	0.4	5	0.5	5	0.5
Usabilidad UX/UI	15%	4	0.6	5	0.75	4	0.6
Escalabilidad Arq.	30%	5	1.5	4	1.2	4	1.2

Integración APIs	25%	5	1.25	4	1	4	1
Seguridad Frontend	10%	5	0.5	3	0.3	4	0.4
Ecosistema (Visual)	10%	4	0.4	5	0.5	4	0.4
Promedio Total	100%	-	4.65	-	4.25	-	4.1

Tabla 9

Cuadro de Análisis de Alternativas por Criterio (Frontend)

Criterio	Impacto	Evaluación
Rendimiento y Carga	10%	React y Vue obtienen la puntuación máxima (5) por su manipulación rápida mediante Virtual DOM. Angular logra un sólido 4, ya que, aunque su empaquetado inicial puede ser ligeramente mayor, su motor de renderizado Ivy asegura una excelente optimización en tiempo de ejecución.
Usabilidad UX/UI	15%	React alcanza 5 puntos por su extensa flexibilidad para diseñar vistas interactivas. Angular (4) compensa mediante Angular Material, proporcionando componentes UI estandarizados y accesibles, esenciales para evitar la sobrecarga cognitiva en plataformas de salud.

Escalabilidad Arq.	30%	Angular lidera con 5 puntos al ser un framework "opinativo" que impone una estructura estricta (MVC) y el uso de TypeScript nativo, asegurando un código limpio. React y Vue (4) requieren que el equipo configure la arquitectura manualmente, aumentando el riesgo técnico.
Integración APIs	25%	Angular destaca con 5 puntos gracias a su potente módulo nativo HttpClient y la implementación de RxJS. Esto permite gestionar de manera asíncrona y predecible los flujos de datos complejos provenientes del modelo predictivo. React y Vue (4) dependen de librerías externas.
Seguridad Frontend	10%	Angular logra 5 puntos al incluir protección integrada contra ataques Cross-Site Scripting (XSS), realizando un saneamiento automático del DOM. React (3) no cubre todas estas brechas por defecto, obligando a implementar parches de seguridad externos.
Ecosistema (Visual)	10%	React (5) posee la comunidad más grande de librerías gráficas. No obstante, Angular (4) cuenta con integraciones robustas de nivel empresarial (como ECharts o componentes basados en D3.js) que son completamente adecuadas para visualizar dashboards de ansiedad.

4.4. Selección de Alternativas

De acuerdo con el análisis cualitativo y cuantitativo realizado, el *framework* web más adecuado para emplear en el desarrollo de la capa de presentación es **Angular**, con un puntaje promedio de **4.65**.

Esta selección se justifica por su superioridad en los pilares fundamentales para el proyecto: la **Escalabilidad de Arquitectura (30%)** y la **Integración de APIs (25%)**. Al tratarse de una plataforma tecnológica que consumirá predicciones de un modelo de *Machine Learning* híbrido alojado en un backend robusto (**Spring Boot**), Angular ofrece el entorno más seguro y estructurado. Su uso nativo de *TypeScript* y *RxJS* asegura una comunicación de datos tipada y libre de errores entre el cliente y el servidor.

Asimismo, al tratar con datos psicológicos sensibles (ansiedad digital), la protección de seguridad integrada de Angular frente a ataques (como XSS) otorga una garantía de nivel empresarial que *frameworks* más ligeros no pueden ofrecer por defecto. Finalmente, la sinergia técnica histórica entre Java (Spring Boot) y Angular garantiza que la plataforma será escalable, altamente mantenible y orientada a los estándares de la ingeniería de software moderna.

5. BENCHMARKING DE BASE DE DATOS

El almacenamiento y gestión de la información en una plataforma de salud mental requiere un nivel de rigor excepcional. Al procesar datos sensibles relacionados con la ansiedad digital, perfiles de estudiantes y resultados predictivos del modelo de *Machine Learning* híbrido, el sistema de base de datos debe garantizar la estricta confidencialidad, integridad y disponibilidad de la información. Además, debe integrarse de manera fluida con el ecosistema del *backend* (Spring Boot) y soportar consultas complejas de manera eficiente. En este capítulo se evaluarán los sistemas de gestión de bases de datos más relevantes del mercado para determinar cuál asegura el cumplimiento normativo (como la Ley 29733 de Protección de Datos Personales) y el soporte técnico necesario para el proyecto.

5.1. Criterios y Parámetros de Medición

Para realizar una evaluación objetiva de los motores de base de datos candidatos (**PostgreSQL, MySQL y MongoDB**), se han definido seis criterios técnicos basados en las arquitecturas del estado del arte. Estos parámetros determinan la viabilidad tecnológica frente a los requerimientos de transaccionalidad, seguridad clínica y soporte para modelos predictivos.

Tabla 10

Definición de criterios y parámetros de medición para Bases de Datos

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Integridad y Consistencia (ACID)	Capacidad del motor para garantizar transacciones seguras y consistentes sin pérdida de datos clínicos.	Escala	[1–5]	1 = Riesgo de inconsistencia; 5 = Cumplimiento estricto de propiedades ACID.	(Sethi et al., 2026)

2	Seguridad y Cifrado	Soporte para encriptación de datos en reposo y en tránsito, control de roles y cumplimiento de estándares (ISO 27001).	Escala	[1–5]	1 = Seguridad básica; 5 = Cifrado robusto nativo y gestión granular de accesos.	(Baena-Navarro et al., 2025)
3	Escalabilidad y Rendimiento	Capacidad de gestionar grandes volúmenes de datos y alta concurrencia de consultas sin latencia.	Escala	[1–5]	1 = Degradación rápida bajo carga; 5 = Alta escalabilidad vertical y horizontal.	(Schmidt et al., 2024)
4	Soporte de Datos (Estructurado/No Estructurado)	Flexibilidad para almacenar datos relacionales tradicionales y objetos JSON complejos provenientes del modelo híbrido.	Escala	[1–5]	1 = Esquema rígidamente estructurado; 5 = Soporte híbrido (Relacional + JSON/Vectorial).	(McFadyen et al., 2026)
5	Integración con el Backend	Nivel de compatibilidad y madurez del soporte (conectores/ORM) para integrarse con Java y Spring Boot.	Escala	[1–5]	1 = Integración compleja o inestable; 5 = Compatibilidad nativa y madura (Hibernate/JPA).	(Nina-Gutiérrez et al., 2024)
6	Mantenibilidad y Ecosistema	Esfuerzo administrativo requerido y disponibilidad de herramientas para copias de seguridad y monitoreo.	Escala	[1–5]	1 = Mantenimiento complejo; 5 = Herramientas avanzadas de administración y respaldo.	(Curi et al., 2025)

5.2. Comparación de Propuestas

Para determinar la relevancia de cada criterio, se elabora la Matriz de Enfrentamiento. Dado que el sistema manejará historiales de evaluación psicológica y predicciones de salud mental, la **Seguridad y Cifrado** y la **Integridad (ACID)** reciben la más alta prioridad para evitar vulnerabilidades. La **Integración con el Backend** también es crítica para mantener la cohesión técnica con el ecosistema estructurado previamente.

Tabla 11

Matriz de Enfrentamiento de Criterios de Base de Datos (Obtención de Ponderación)

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Integridad (ACID)	-	0	1	1	1	1	4	25%
C2: Seguridad y Cifrado	1	-	1	1	1	1	5	30%
C3: Escalabilidad	0	0	-	0	0	1	1	10%
C4: Soporte de Datos	0	0	1	-	0	1	2	10%
C5: Integración Backend	0	0	1	1	-	1	3	20%

C6: Mantenibilidad	0	0	0	0	0	-	0	5%
TOTAL							15	100%

Nota. El valor 1 indica que el criterio de la fila es más importante que el de la columna. El enfoque clínico demanda que C2 y C1 dominen la matriz.

5.3. Análisis de Alternativas

Con los porcentajes de impacto definidos, se procede a evaluar los sistemas gestores de bases de datos relacionales (**PostgreSQL y MySQL**) y no relacionales (**MongoDB**) para determinar el componente óptimo de almacenamiento.

Tabla 12

Matriz de Priorización de Bases de Datos

Criterio	Impacto	Bases de datos					
		PostgreSQL		MySQL		MongoDB	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Integridad (ACID)	25%	5	1.25	4	1	3	0.75
Seguridad y Cifrado	30%	5	1.5	4	1.2	4	1.2
Escalabilidad	10%	4	0.4	4	0.4	5	0.5

Soporte de Datos	10%	5	0.5	3	0.3	5	0.5
Integración Backend	20%	5	1	5	1	4	0.8
Mantenibilidad	5%	4	0.2	5	0.25	4	0.2
Promedio Total	100%	-	4.85	-	4.15	-	3.95

Tabla 13

Cuadro de Análisis de Alternativas por Criterio (Bases de Datos)

Criterio	Impacto	Evaluación
Integridad (ACID)	25%	PostgreSQL obtiene 5 puntos por su estricta adherencia a los estándares SQL y su robustez transaccional sin compromisos. MySQL logra un 4 (su motor InnoDB es muy capaz, pero permite configuraciones más laxas), mientras que MongoDB (3) históricamente favorece la disponibilidad sobre la consistencia transaccional absoluta.

Seguridad y Cifrado	30%	PostgreSQL lidera con 5 puntos gracias a sus características avanzadas de encriptación de datos, auditoría y control de acceso basado en roles sumamente granular, características fundamentales para cumplir con la normativa ISO 27001. MySQL y MongoDB (4) ofrecen opciones de seguridad robustas, pero a menudo dependen de versiones comerciales o configuraciones más complejas para igualar este estándar nativo.
Escalabilidad	10%	MongoDB destaca con 5 puntos al estar diseñado nativamente para la escalabilidad horizontal masiva (Sharding). PostgreSQL y MySQL obtienen un sólido 4, siendo excelentes escalando verticalmente y ofreciendo opciones robustas de replicación para escenarios de lectura concurrente.
Soporte de Datos	10%	PostgreSQL y MongoDB logran 5 puntos. MongoDB por su naturaleza nativa orientada a documentos NoSQL), y PostgreSQL por su extraordinario soporte híbrido para campos JSONB y extensiones como pgvector, vitales para almacenar vectores y logs complejos de modelos predictivos. MySQL se queda en 3 por tener un manejo de JSON menos optimizado.

Integración Backend	20%	PostgreSQL y MySQL alcanzan 5 puntos por su madurez histórica. Se integran perfectamente con el framework Spring Boot mediante Hibernate/JPA, asegurando un mapeo objeto-relacional (ORM) libre de fricciones. MongoDB (4) cuenta con Spring Data MongoDB, pero su paradigma difiere del ecosistema fuertemente tipado de Java.
Mantenibilidad	5%	MySQL logra un 5 debido a su enorme penetración de mercado, lo que garantiza una curva de aprendizaje mínima y abundancia de herramientas de administración visuales y de respaldo. PostgreSQL y MongoDB obtienen 4, requiriendo un nivel de experiencia técnica ligeramente superior para una afinación avanzada.

5.4. Selección de Alternativa

De acuerdo con el análisis cuantitativo y cualitativo desarrollado, la alternativa tecnológica más adecuada para el motor de base de datos de la plataforma es **PostgreSQL**, obteniendo la puntuación más alta con un promedio de **4.85**.

Esta decisión técnica se fundamenta principalmente en los requisitos innegociables de una plataforma de salud mental: la **Seguridad y Cifrado (30%)** y la **Integridad Transaccional (25%)**. Al gestionar información sensible de estudiantes (resultados de ansiedad digital y perfiles clínicos), PostgreSQL garantiza una consistencia absoluta de los datos y proporciona herramientas nativas de seguridad y control de acceso que blindan la información frente a vulnerabilidades externas.

Adicionalmente, PostgreSQL destaca como la opción definitiva debido a su capacidad híbrida en el soporte de datos. Su tipo de dato JSONB y su soporte para extensiones vectoriales permiten almacenar eficientemente las predicciones estructuradas y no estructuradas del motor de *Machine Learning*. Esta flexibilidad, combinada con su integración nativa y madura con el *framework de backend (Spring Boot)* mediante JPA/Hibernate, asegura la construcción de una arquitectura robusta, escalable y fuertemente tipada a través de todas las capas del sistema.

6. BENCHMARKING DE LENGUAJES DE PROGRAMACIÓN

La elección del lenguaje de programación constituye un pilar arquitectónico crítico para esta investigación. Dado que la plataforma no solo gestionará operaciones transaccionales comunes, sino que orquestrará un motor de *Machine Learning* híbrido para procesar evaluaciones psicométricas de ansiedad digital, el lenguaje seleccionado debe poseer capacidades excepcionales para el análisis de datos matemáticos y estadísticos. Asimismo, debe garantizar la interoperabilidad mediante microservicios, permitiendo que el motor de inferencia clínica se comunique de manera eficiente y segura con las demás capas del sistema. En este capítulo se evaluarán las opciones más consolidadas en el desarrollo de software orientado a la inteligencia artificial para determinar la herramienta óptima.

6.1. Criterios y Parámetros de Medición

Para asegurar un análisis profundo y alineado con los requerimientos de la psicología computacional, se han ampliado los parámetros a seis criterios técnicos, evaluando **Python, Java** y **C#**. Estos criterios abarcan desde la velocidad de procesamiento concurrente hasta la riqueza de su ecosistema para modelado predictivo.

Tabla 14

Definición de criterios y parámetros de medición para Lenguajes de Programación

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Rendimiento y Concurrencia	Eficiencia computacional para ejecutar lógica de negocio y gestionar múltiples peticiones	Escala	[1–5]	1 = Lento/Bloqueante bajo carga; 5 = Ejecución nativa/optimizada para alta	(Schmidt et al., 2024)

		asíncronas simultáneas.			concurrente.	
2	Ecosistema de Machine Learning	Madurez, disponibilidad y soporte de librerías estandarizadas en la industria para el diseño y entrenamiento de modelos de IA.	Escala	[1–5]	1 = Soporte nulo o incipiente; 5 = Estándar absoluto de la industria con librerías nativas.	(Curi et al., 2025)
3	Soporte para Análisis de Datos	Herramientas nativas o comunitarias para la manipulación, limpieza y transformación matemática de grandes <i>datasets</i> clínicos.	Escala	[1–5]	1 = Transformación de datos compleja; 5 = Estructuras de datos matriciales y analíticas nativas.	(Baena-Navarro et al., 2025)

4	Seguridad y Tipado	Resiliencia del lenguaje frente a vulnerabilidades de memoria y solidez en la validación de tipos de datos para prevenir inconsistencias.	Escala	[1–5]	1 = Débilmente tipado/propenso a fallos críticos; 5 = Tipado estricto y seguro por diseño arquitectónico.	(Sethi et al., 2026)
5	Curva de Aprendizaje y Agilidad	Esfuerzo técnico y tiempo requerido por el equipo de investigación para prototipar, iterar y desplegar el modelo predictivo.	Escala	[1–5]	1 = Curva de aprendizaje y configuración muy lenta; 5 = Sintaxis expresiva, legible y de desarrollo ágil.	(McFadyen et al., 2026)
6	Interoperabilidad de Microservicios	Facilidad del lenguaje para exponer modelos predictivos a través de APIs RESTful o gRPC para integrarse con otras arquitecturas.	Escala	[1–5]	1 = Ecosistema web deficiente; 5 = <i>Frameworks</i> ligeros y robustos para exponer servicios en la nube.	(Nina-Gutiérrez et al., 2024)

6.2. Comparación de Propuestas

Para determinar la prioridad de cada dimensión técnica, se elabora la Matriz de Enfrentamiento. Dado que el núcleo innovador de esta plataforma es la detección de la ansiedad digital mediante un enfoque algorítmico, el **Ecosistema de Machine Learning** y el **Soporte para Análisis de Datos** adquieren el mayor impacto porcentual, seguidos de cerca por la **Seguridad** exigida para el manejo de información clínica de los universitarios.

Tabla 15

Matriz de Enfrentamiento de Criterios de Lenguajes (Obtención de Ponderación)

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Rendimiento y Concurrencia	-	0	0	0	1	1	2	15%
C2: Ecosistema de ML	1	-	1	1	1	1	5	30%
C3: Soporte Análisis de Datos	1	0	-	0	1	1	3	20%
C4: Seguridad y Tipado	1	0	1	-	1	0	3	15%
C5: Curva de Aprend. y Agilidad	0	0	0	0	-	1	1	10%
C6: Interoperabilidad Microserv.	0	0	0	1	0	-	1	10%
TOTAL							15	100%

Nota. El valor 1 indica que el criterio de la fila es más importante que el de la columna. Se consolida el perfil analítico del proyecto al otorgar el 50% del peso combinado a las capacidades de IA y procesamiento de datos.

6.3. Análisis de Alternativas

Con los porcentajes de impacto definidos, se procede a evaluar las capacidades reales de **Python**, **Java** y **C#** para sustentar el motor de inferencia algorítmica de la investigación.

Tabla 16

Matriz de Priorización de Lenguajes de Programación

Criterio	Impacto	Lenguajes de Programación					
		Python		Java		C#	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Rendimiento y Concurrencia	15%	4	0.6	5	0.75	5	0.75
Ecosistema de ML	30%	5	1.5	3	0.9	3	0.9
Soporte Análisis Datos	20%	5	1	3	0.6	3	0.6
Seguridad y Tipado	15%	4	0.6	5	0.75	5	0.75
Curva de Aprend. / Agilidad	10%	5	0.5	3	0.3	4	0.4
Interoperabilidad (APIs)	10%	5	0.5	5	0.5	5	0.5

Promedio Total	100%	-	4.7	-	3.8	-	3.9
-----------------------	-------------	---	------------	---	------------	---	------------

Tabla 17

Cuadro de Análisis de Alternativas por Criterio (Lenguajes)

Criterio	Impacto	Evaluación
Rendimiento y Concurrency	15%	Java y C# alcanzan los 5 puntos gracias a su naturaleza compilada, recolección de basura altamente optimizada y soporte nativo profundo para multihilo (Multi-threading). Python obtiene un muy respetable 4; si bien el <i>Global Interpreter Lock (GIL)</i> puede ser un cuello de botella en CPU concurrente pura, su rendimiento es excelente al delegar operaciones matemáticas pesadas a librerías escritas en C.
Ecosistema de ML	30%	Python domina absolutamente esta categoría (5 puntos) , siendo el estándar indiscutible de la industria para Inteligencia Artificial. Centraliza <i>frameworks</i> de vanguardia requeridos para este proyecto (como <i>Scikit-Learn</i> para Random Forest o <i>TensorFlow/PyTorch</i> para redes neuronales profundas). Java y C# (3 puntos) requieren integraciones más complejas o el uso de librerías con menor comunidad, como <i>Deeplearning4j</i> o <i>ML.NET</i> .

Soporte Análisis de Datos	20%	Nuevamente, Python alcanza la puntuación máxima (5) debido a la existencia de librerías como <i>Pandas</i> y <i>NumPy</i> , que permiten manipular, limpiar e imputar <i>datasets</i> clínicos de ansiedad con solo unas líneas de código vectorial. Java y C# (3) carecen de este nivel de expresividad sintáctica para la manipulación matricial de datos en bruto.
Seguridad y Tipado	15%	Java y C# obtienen 5 puntos por su tipado estático fuerte, lo que permite detectar errores de memoria y tipos de datos en tiempo de compilación, una capa de seguridad vital. Python logra un 4; aunque es dinámicamente tipado, la implementación reciente de <i>Type Hints</i> (anotaciones de tipado) y el uso de linters estrictos como <i>MyPy</i> mitigan drásticamente los riesgos de seguridad en producción.
Curva de Aprend. / Agilidad	10%	Python (5 puntos) destaca por su sintaxis extremadamente legible e intuitiva (pseudo-código ejecutable), lo que acelera exponencialmente las fases de investigación, prueba y error (prototipado rápido) necesarias para afinar el modelo predictivo. C# (4) ofrece un ecosistema de desarrollo fluido gracias a Visual Studio, mientras que Java (3) exige una estructura de código más verbosa y rígida.

Interoperabilidad (APIs)	10%	Los tres lenguajes obtienen la máxima calificación (5). Python sobresale con <i>frameworks</i> modernos y ultraligeros como <i>FastAPI</i> , que generan documentación automática (Swagger) y manejan asincronismo nativo, permitiendo exponer el modelo híbrido como un microservicio independiente que se comunique a la perfección con cualquier <i>backend</i> y frontend.
---------------------------------	-----	--

6.4. Selección de Alternativa

De acuerdo con el análisis cualitativo y cuantitativo, el lenguaje de programación seleccionado para el núcleo predictivo e investigación analítica de la plataforma es **Python**, obteniendo la máxima puntuación general con **4.70**.

Esta selección está sólidamente justificada por las necesidades inherentes a una investigación enfocada en la salud mental asistida por inteligencia artificial. Para implementar el modelo de **Machine Learning híbrido** (que combinará reglas lógicas para interpretar test psicométricos con algoritmos estadísticos predictivos), **Python** es la única alternativa que ofrece un ecosistema de grado científico nativo (*Scikit-Learn*, *Pandas*, *NumPy*), abarcando un **50% de la ponderación crítica** del proyecto. Intentar desarrollar lógicas de clasificación clínica complejas en Java o C# representaría un alto riesgo técnico por la curva de adaptación matemática y la falta de comunidad de soporte analítico.

Asimismo, la flexibilidad arquitectónica de Python permite un diseño de software avanzado: el modelo predictivo puede encapsularse fácilmente dentro de un microservicio independiente (utilizando tecnologías como *FastAPI*). Esta estructura permitirá que el motor de IA en Python procese las inferencias de ansiedad digital con alta velocidad, comunicándose de manera segura, interoperable y mediante protocolos RESTful con la base de datos PostgreSQL y las demás capas de la plataforma web. Esta elección tecnológica garantiza la viabilidad del proyecto, reduciendo los tiempos de desarrollo sin comprometer el rigor matemático del diagnóstico clínico.

7. BENCHMARKING DE ALGORITMOS DE MACHINE LEARNING

El núcleo analítico de la plataforma reside en su motor de inferencia predictiva, el cual debe evaluar las métricas de comportamiento digital y las respuestas de los test psicométricos para clasificar los niveles de ansiedad en los estudiantes universitarios. Considerando que es un diagnóstico de salud mental, el algoritmo seleccionado en este caso no deberá sólo ofrecer una alta precisión estadística, sino que también deberá ser interpretado por los profesionales de la psicología (modelo de "caja blanca" o semi-transparentes). Este capítulo evalúa tres algoritmos de aprendizaje automático híbridos en cuanto a su eficiencia, escalabilidad y tolerancia al ruido en conjuntos de datos clínicos.

7.1. Criterios y Parámetros de Medición

Para realizar una selección rigurosa, se han definido seis criterios técnicos y científicos derivados de las metodologías aplicadas en la literatura médica y computacional.

Tabla 18

Definición de criterios y parámetros de medición para Algoritmos Predictivos

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Precisión y Exactitud (F1-Score)	Capacidad del algoritmo para minimizar falsos positivos y negativos en la detección de la ansiedad.	Escala	[1–5]	1 = Baja precisión/Sobreajuste; 5 = Altas métricas de validación (Recall/F1-Score).	(Schmidt et al., 2024)

2	Explicabilidad (Interpretabilidad)	Facilidad para extraer las reglas de decisión del modelo (ej. importancia de variables) para justificar el resultado clínico.	Escala	[1–5]	1 = Modelo de caja negra inescrutable; 5 = Transparencia total y extracción lógica.	(McFadyen et al., 2026)
3	Tolerancia al Ruido y Datos Nulos	Resiliencia del modelo frente a encuestas incompletas o valores atípicos (outliers) comunes en cuestionarios psicométricos.	Escala	[1–5]	1 = Altamente sensible a errores; 5 = Manejo robusto de datos asimétricos o nulos.	(Sethi et al., 2026)
4	Integración Híbrida	Capacidad del algoritmo para combinarse con sistemas basados en reglas clínicas (conocimiento experto predefinido).	Escala	[1–5]	1 = Difícil acoplamiento lógico; 5 = Arquitectura de ensamble natural (árboles lógicos).	(Nina-Gutiérrez et al., 2024)

5	Eficiencia Computacional	Consumo de recursos (CPU/Memoria) y latencia requerida durante el proceso de entrenamiento y la inferencia.	Escala	[1–5]	1 = Requiere hardware avanzado (GPU); 5 = Inferencia rápida, ideal para microservicios.	(Curi et al., 2025)
6	Escalabilidad del Conjunto de Datos	Comportamiento estadístico del modelo a medida que la base de datos de estudiantes crece a lo largo de los ciclos académicos.	Escala	[1–5]	1 = Se degrada con grandes volúmenes; 5 = Estabilidad y mejora continua con la escala.	(Baena-Navarro et al., 2025)

7.2. Comparación de Propuestas

Para estructurar la Matriz de Priorización, primero se aplica la Matriz de Enfrentamiento. En el dominio de la salud (psicología), la **Precisión** y la **Explicabilidad** conforman los pilares de la ética algorítmica. Un profesional de la salud necesita saber por qué el sistema determinó que el estudiante tiene ansiedad severa. La tolerancia al ruido ocupa el tercer lugar por la naturaleza de los datos humanos.

Tabla 19

Matriz de Enfrentamiento de Criterios Algorítmicos (Obtención de Ponderación)

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Precisión y Exactitud	-	1	1	1	1	1	5	30%
C2: Explicabilidad	0	-	1	1	1	1	4	25%
C3: Tolerancia al Ruido	0	0	-	1	1	1	3	20%
C4: Integración Híbrida	0	0	0	-	1	0	1	10%
C5: Eficiencia Computacional	0	0	0	0	-	1	1	10%
C6: Escalabilidad de Datos	0	0	0	1	0	-	1	5%
TOTAL							15	100%

Nota. Los criterios C1 y C2 suman el 55% del peso de la decisión, blindando la validez clínica y estadística de la plataforma de bienestar estudiantil.

7.3. Análisis de Alternativas

Con los porcentajes definidos, se procede a evaluar tres de los algoritmos más representativos en la literatura para clasificación de datos estructurados: **Regresión Logística**, **Random Forest (Ensamblaje)** y **Redes Neuronales Artificiales (Multicapa)**.

Tabla 20

Matriz de Priorización de Algoritmos de ML

Criterio	Impacto	Algoritmos de Machine Learning					
		Regresión Lineal		Random Forest		Red Neuronal	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Precisión (F1-Score)	30%	3	0.9	5	1.5	5	1.5
Explicabilidad	25%	5	1.25	4	1	2	0.5
Tolerancia Ruido	20%	3	0.6	5	1	4	0.8
Integración Híbrida	10%	3	0.3	5	0.5	2	0.2
Eficiencia Comput.	10%	5	0.5	4	0.4	3	0.3
Escalabilidad	5%	3	0.15	4	0.2	5	0.25
Promedio Total	100%	-	3.7	-	4.6	-	3.55

Tabla 21*Cuadro de Análisis de Alternativas por Criterio (Algoritmos)*

Criterio	Impacto	Evaluación
Precisión (F1-Score)	30%	Random Forest y las Redes Neuronales logran 5 puntos por su capacidad superior para mapear relaciones no lineales y complejas en factores de ansiedad. La Regresión Logística (3) asume linealidad, por lo que su precisión decae en datasets psicométricos multivariantes.
Explicabilidad	25%	La Regresión Logística obtiene 5 por su transparencia matemática pura (coeficientes). Random Forest (4) ofrece "Importancia de Variables" (Feature Importance), permitiendo saber qué factor causa más ansiedad. La Red Neuronal se castiga con 2 puntos por ser una "caja negra" que dificulta la justificación del diagnóstico al psicólogo.
Tolerancia al Ruido	20%	Random Forest lidera con 5 puntos gracias a su arquitectura de ensamblaje (Bagging), que promedia múltiples árboles minimizando el impacto de outliers y respuestas atípicas de los alumnos. Las Redes Neuronales (4) son sólidas, pero requieren un preprocesamiento exhaustivo. Regresión (3) es muy sensible a datos anómalos.

Integración Híbrida	10%	Random Forest alcanza la máxima puntuación (5). Al ser un conjunto de árboles de decisión, se integra de forma natural con arquitecturas híbridas donde un psicólogo puede insertar "reglas duras" directamente en los nodos (ej. Si ideación suicida = Sí, emitir alerta roja inmediata). Esta inyección clínica es extremadamente compleja en Redes Neuronales (2).
Eficiencia Comput.	10%	Regresión Logística (5) es la más ligera y rápida. Random Forest obtiene 4, ya que el entrenamiento puede paralelizar fácilmente en CPU y la inferencia requiere latencia de milisegundos en el backend de Python. Redes Neuronales (3) demandan mayor potencia de cómputo y memoria.
Escalabilidad	5%	Las Redes Neuronales (5) brillan verdaderamente cuando el dataset supera los cientos de miles de registros (Big Data). Random Forest (4) escala eficientemente con tamaños de muestra intermedios y grandes, siendo el punto dulce para un universo universitario.

7.4. Selección de Alternativa

De acuerdo con el análisis cualitativo y cuantitativo expresado en la Matriz de Priorización, el algoritmo óptimo para el motor de inferencia clínica de la plataforma es **Random Forest**, logrando un puntaje promedio sobresaliente de **4.60**.

Esta selección obedece a la naturaleza intrínseca de la psicología computacional. En el contexto de la detección de ansiedad digital, **Random Forest** ofrece el equilibrio perfecto entre **Precisión Estadística (30%)** y **Explicabilidad (25%)**. Mientras que una Red Neuronal puede igualar o superar marginalmente su precisión, falla críticamente en la transparencia, impidiendo que el equipo clínico valide las razones detrás de un diagnóstico. Random Forest, mediante el análisis de *Importancia de Características*, permite a los psicólogos de la UPC observar qué métricas digitales (ej. tiempo de pantalla nocturno, uso de redes sociales) están incidiendo directamente en la ansiedad del alumno.

Adicionalmente, su resiliencia natural frente a encuestas ruidosas o incompletas (**Tolerancia al Ruido, 20%**) reduce significativamente la tasa de error en la validación cruzada. Al estar codificado en **Python** (lenguaje seleccionado en el Cap. 6), se integrará mediante librerías estandarizadas como *Scikit-Learn* dentro de un microservicio, materializando con éxito el enfoque híbrido clínico-estadístico propuesto en el estado del arte.

8. BENCHMARKING DE MÉTRICAS DE EVALUACIÓN (MACHINE LEARNING)

La selección de la métrica de rendimiento adecuada es un factor crítico en el desarrollo de modelos predictivos orientados a la salud mental. En el contexto de la detección de ansiedad digital estudiantil, los errores de predicción no tienen el mismo impacto clínico: un Falso Negativo (clasificar a un alumno con ansiedad severa como "sano") conlleva un riesgo psicológico mucho mayor que un Falso Positivo (clasificar a un alumno sano con "ansiedad moderada"). Por lo tanto, el modelo de *Random Forest* debe optimizarse utilizando una métrica matemática que penalice adecuadamente estos riesgos y sea resiliente ante conjuntos de datos inherentemente desbalanceados.

8.1. Criterios y Parámetros de Medición

Para evaluar de manera objetiva las métricas candidatas (**Exactitud, Precisión, Recall y F1-Score**), se han definido seis parámetros basados en los estándares de la ciencia de datos aplicada a entornos clínicos.

Tabla 22

Definición de criterios y parámetros de medición para Métricas de Evaluación

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Penalización de Falsos Negativos	Capacidad de la métrica para priorizar la detección de todos los casos reales de ansiedad (minimizar omisiones).	Escala	[1–5]	1 = Ignora Falsos Negativos; 5 = Penalización máxima y estricta.	(Schmidt et al., 2024)

2	Resiliencia a Clases Desbalanceadas	Fiabilidad matemática del indicador cuando la mayoría del <i>dataset</i> pertenece a la clase "Sano/Sin Ansiedad".	Escala	[1–5]	1 = Arroja falsos éxitos; 5 = Matemáticamente robusto al desbalanceo.	(Baena-Navarro et al., 2025)
3	Penalización de Falsos Positivos	Evitar saturar al departamento de psicología con alertas falsas que consuman recursos de intervención clínica.	Escala	[1–5]	1 = Genera alta tasa de falsas alarmas; 5 = Filtro estricto de Falsos Positivos.	(Sethi et al., 2026)
4	Relevancia Clínica (Screening)	Aceptación y comprensión de la métrica por parte de los profesionales de la salud mental.	Escala	[1–5]	1 = Puramente computacional; 5 = Estándar en pruebas psicométricas (Sensibilidad).	(McFadyen et al., 2026)

5	Balance Armónico	Capacidad de encontrar un equilibrio matemático entre detectar todos los casos y asegurar que las detecciones sean correctas.	Escala	[1–5]	1 = Métrica sesgada a un solo extremo; 5 = Equilibrio matemático comprobable.	(Curi et al., 2025)
6	Estabilidad en Validación Cruzada	Consistencia de la métrica durante los procesos de entrenamiento iterativo (<i>K-Fold Cross Validation</i>).	Escala	[1–5]	1 = Alta varianza/inestable; 5 = Métrica consistente y generalizable.	(Nina-Gutiérrez et al., 2024)

8.2. Comparación de Propuestas

Para determinar la relevancia de cada criterio, se elabora la Matriz de Enfrentamiento. Dado el contexto de salud mental, la prioridad absoluta es no dejar a ningún estudiante vulnerable sin atención, por lo que la **Penalización de Falsos Negativos** y la **Resiliencia a Clases Desbalanceadas** obtienen el mayor impacto.

Tabla 23*Matriz de Enfrentamiento de Criterios de Métricas (Obtención de Ponderación)*

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Pen. Falsos Negativos	-	1	1	1	1	1	5	30%
C2: Clases Desbalanceadas	0	-	1	1	1	1	4	25%
C3: Balance Armónico	0	0	-	1	1	1	3	20%
C4: Relevancia Clínica	0	0	0	-	1	0	1	10%
C5: Pen. Falsos Positivos	0	0	0	0	-	1	1	10%
C6: Estabilidad Validación	0	0	0	1	0	-	1	5%
TOTAL							15	100%

Nota. En epidemiología y cribado psicológico, minimizar los falsos negativos -C1- salva vidas, por lo que domina la matriz.

8.3. Análisis de Alternativas

Evaluamos las métricas estadísticas clásicas aplicadas a matrices de confusión: **Exactitud (Accuracy)**, **Precisión (Precision)**, **Sensibilidad (Recall)** y la **Puntuación F1 (F1-Score)**.

Tabla 24

Matriz de Priorización de Métricas de Evaluación ML

Criterio	Impacto	Métricas de evaluación ML							
		Accuracy		Precision		Recall		F1-Score	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Pen. Falsos Negativos	30%	2	0.6	1	0.3	5	1.5	4	1.2
Desbalance de Clases	25%	1	0.25	4	1	4	1	5	1.25
Balance Armónico	20%	2	0.4	2	0.4	2	0.4	5	1
Relevancia Clínica	10%	3	0.3	3	0.3	5	0.5	4	0.4
Pen. Falsos Positivos	10%	3	0.3	5	0.5	1	0.1	4	0.4
Estabilidad Valid.	5%	2	0.1	3	0.15	3	0.15	5	0.25
Promedio Total	100%	-	1.95	-	2.65	-	3.65	-	4.5

Tabla 25*Cuadro de Análisis de Alternativas por Criterio (Métricas)*

Criterio	Impacto	Evaluación
Pen. Falsos Negativos	30%	<i>Recall</i> obtiene 5 puntos, ya que se centra exclusivamente en hallar todos los casos positivos reales (ansiedad). <i>F1-Score</i> logra un sólido 4, mientras que la Precisión (1) los ignora por completo.
Desbalance de Clases	25%	<i>F1-Score</i> alcanza la máxima calificación (5). La <i>Exactitud</i> (1) falla críticamente aquí: si el 90% de los alumnos está sano, un modelo que siempre predice "sano" tendrá 90% de exactitud, pero será inútil clínicamente.
Balance Armónico	20%	<i>F1-Score</i> es la única métrica (5 puntos) que calcula la media armónica entre Precisión y Recall, logrando un equilibrio global.
Relevancia Clínica	10%	<i>Recall</i> (5 puntos) es el equivalente estadístico de la "Sensibilidad" en medicina, siendo el estándar para pruebas de cribado. <i>F1-Score</i> logra un 4 por ser el estándar en ciencia de datos de salud.

Pen. Falsos Positivos	10%	La <i>Precisión</i> logra 5 puntos, garantizando diagnósticos exactos. <i>Recall</i> es castigado con 1 punto, ya que tiende a generar muchas falsas alarmas.
Estabilidad	5%	<i>F1-Score</i> (5 puntos) demuestra la menor varianza durante el entrenamiento iterativo de <i>Random Forest</i> .

8.4. Selección de Alternativa

De acuerdo con el análisis cuantitativo y cualitativo de la Matriz de Priorización, la métrica de evaluación principal seleccionada para optimizar y validar el algoritmo de *Machine Learning* es el **F1-Score (Puntuación F1)**, con un promedio de **4.50**, seguida por la métrica de *Recall* (3.65).

Esta decisión obedece a la naturaleza intrínseca del problema de investigación. La evaluación de la ansiedad digital presenta conjuntos de datos fuertemente desbalanceados; utilizar la *Exactitud (Accuracy)* generaría un modelo engañoso que aparenta funcionar bien, pero que falla en detectar a la minoría estudiantil verdaderamente afectada.

El **F1-Score** se impone como la métrica definitiva por su **Balance Armónico (20%)**. Aunque el *Recall* es excelente para detectar Falsos Negativos (asegurando que ningún estudiante con ansiedad pase desapercibido), optimizar el modelo *exclusivamente* para Recall generaría una avalancha de Falsos Positivos. Esto provocaría la saturación de los departamentos de apoyo psicológico con alertas innecesarias, generando "fatiga de alarmas". El F1-Score obliga al modelo *Random Forest* a mantener una alta sensibilidad clínica sin sacrificar drásticamente la precisión del diagnóstico predictivo

9. BENCHMARKING DE INFRAESTRUCTURA CLOUD

La implementación de una plataforma de bienestar digital orientado a la salud mental requiere una infraestructura subyacente que proporcione alta disponibilidad, tolerancia a fallos y, sobre todo, un estricto cumplimiento de las normas de privacidad de datos (Ley N.º 29733 en Perú y norma ISO 27001). Del mismo modo, la arquitectura debe proporcionar soporte para la implementación distribuida de microservicios en Java (Spring Boot) y para la ejecución de modelos predictivos en Python sin que eso produzca una degradación de los tiempos de respuesta. En este capítulo se evaluarán los principales proveedores de servicios en la nube (*Cloud Providers*) para determinar cuál ofrece el ecosistema más maduro y coherente con las decisiones tecnológicas previas.

9.1. Criterios y Parámetros de Medición

Para realizar una evaluación objetiva de los proveedores candidatos (**Amazon Web Services - AWS, Microsoft Azure y Google Cloud Platform - GCP**), se han definido seis criterios técnicos alineados con las arquitecturas distribuidas del estado del arte.

Tabla 26

Definición de criterios y parámetros de medición para Proveedores Cloud

#	Criterio	Descripción	Unidad	Valores	Parámetro de Medición	Fuente (APA 7)
1	Cumplimiento y Seguridad (Compliance)	Capacidad de cifrado de extremo a extremo, gestión de identidades y cumplimiento de normativas de datos de salud	Escala	[1–5]	1 = Seguridad básica compartida; 5 = Ecosistema nativo de <i>Compliance</i> avanzado y médico.	(Sethi et al., 2026)

		(HIPAA, ISO 27001).				
2	Orquestación de Microservicios	Madurez de los servicios gestionados para contenedores (Docker/Kubernetes) necesarios para desplegar Spring Boot.	Escala	[1–5]	1 = Gestión manual de contenedores; 5 = Orquestación gestionada de nivel <i>Enterprise</i> .	(Schmidt et al., 2024)
3	Servicios de Machine Learning	Soporte y herramientas MLOps nativas para entrenar, desplegar y monitorear el algoritmo Random Forest en Python.	Escala	[1–5]	1 = Despliegue manual en máquinas virtuales; 5 = Plataformas MLOps integrales (<i>End-to-End</i>).	(Curi et al., 2025)

4	Escalabilidad y Disponibilidad	Capacidad elástica para manejar picos de concurrencia durante periodos de evaluaciones universitarias (exámenes parciales/finales).	Escala	[1–5]	1 = Auto-escalado lento o complejo; 5 = Elasticidad instantánea y alta disponibilidad global.	(Baena-Navarro et al., 2025)
5	Entrega de Contenido (CDN/Frontend)	Eficiencia de la red global para entregar la aplicación <i>Single Page Application</i> (SPA) en Angular con mínima latencia.	Escala	[1–5]	1 = Latencia notable en bordes; 5 = CDN global nativa con seguridad perimetral.	(Nina-Gutiérrez et al., 2024)
6	Costo-Eficiencia (TCO)	Relación costo-beneficio para el ecosistema universitario, disponibilidad de capas gratuitas robustas y optimización de recursos.	Escala	[1–5]	1 = Costos ocultos o elevados; 5 = Precios predecibles y herramientas de control financiero.	(McFadyen et al., 2026)

9.2. Comparación de Propuestas

Para determinar la relevancia de cada criterio, se elabora la Matriz de Enfrentamiento. En el ámbito de la psicología computacional, la **Seguridad (Compliance)** es imperativa y no negociable. Le siguen en importancia la **Orquestación de Microservicios** (para asegurar que el *Backend* en Java y la base de datos PostgreSQL operen sin fallos) y los **Servicios de Machine Learning** (para el modelo predictivo de ansiedad).

Tabla 27

Matriz de Enfrentamiento de Criterios Cloud (Obtención de Ponderación)

Criterio	C1	C2	C3	C4	C5	C6	Subtotal	Ponderación (%)
C1: Cumplimiento y Seg.	-	1	1	1	1	1	5	34%
C2: Orquestación Microserv.	0	-	1	1	1	1	4	27%
C3: Servicios de ML (MLOps)	0	0	-	1	1	1	3	20%
C4: Escalabilidad	0	0	0	-	1	0	1	6%

C5: Entrega Contenido (CDN)	0	0	0	0	-	1	1	7%
C6: Costo-Eficienci a (TCO)	0	0	0	1	0	-	1	6%
TOTAL							15	100%

Nota. Para evitar la anulación matemática de los criterios secundarios, se aplicó una preferencia circular entre C4, C5 y C6, garantizando un subtotal mínimo válido para el cálculo porcentual sobre la base de 15 puntos.

9.3. Análisis de Alternativas

Con los porcentajes de impacto correctamente distribuidos, se evalúa el rendimiento de los tres proveedores líderes de infraestructura en la nube: **Amazon Web Services (AWS)**, **Microsoft Azure** y **Google Cloud Platform (GCP)**.

Tabla 28

Matriz de Priorización de Proveedores Cloud

Criterio	Impacto	Proveedores Cloud					
		AWS		Azure		GCP	
		Puntaje	Promedio	Puntaje	Promedio	Puntaje	Promedio
Seguridad y Compliance	34%	5	1.7	5	1.7	4	1.36

Orquestación Microserv.	27%	5	1.35	4	1.08	5	1.35
Servicios Machine Learning	20%	5	1	4	0.8	5	1
Entrega de Contenido	7%	5	0.35	4	0.28	4	0.28
Escalabilidad	6%	5	0.3	5	0.3	4	0.24
Costo-Eficiencia	6%	4	0.24	3	0.18	4	0.24
Promedio Total	100%	-	4.94	-	4.34	-	4.47

Tabla 29

Cuadro de Análisis de Alternativas por Criterio (Cloud)

Criterio	Impacto	Evaluación
Seguridad y Compliance	34%	AWS y Azure lideran con 5 puntos al poseer la mayor cantidad de certificaciones de seguridad globales (incluyendo normativas médicas) y servicios robustos de gestión de identidades. GCP (4) es altamente seguro, pero con una penetración histórica ligeramente menor en el cumplimiento de auditorías tradicionales de salud local.

Orquestación Microserv.	27%	AWS (EKS/ECS) y GCP (Google Kubernetes Engine) obtienen 5 puntos por ofrecer el estándar de la industria en gestión de contenedores, vital para desplegar Spring Boot de forma aislada. Azure (4) ofrece AKS, pero presenta configuraciones de red virtual más complejas para aislar clústeres.
Servicios Machine Learning	20%	AWS alcanza 5 puntos gracias a <i>Amazon SageMaker</i> , facilitando el entrenamiento y despliegue del modelo Random Forest (Python) como una API predictiva. GCP (5) empata con <i>Vertex AI</i> , mientras que Azure (4) requiere dependencias más pesadas para consolidar un flujo MLOps ágil.
Entrega de Contenido	7%	AWS logra 5 puntos por la eficiencia comprobada de <i>Amazon CloudFront</i> integrado con <i>S3</i> para servir aplicaciones Angular, sumando protección nativa <i>WAF</i> contra ataques perimetrales. GCP y Azure (4) requieren mayor configuración para lograr la misma cohesión en el <i>Frontend</i> .
Escalabilidad	6%	AWS y Azure logran 5 puntos por poseer la infraestructura global más robusta y herramientas de <i>Auto-Scaling</i> inmediatas, necesarias para soportar picos de usuarios durante las semanas de exámenes parciales.

Costo-Eficiencia	6%	AWS y GCP (4) ofrecen una capa gratuita (<i>Free Tier</i>) inmensamente generosa para la fase de investigación, con herramientas precisas para predecir gastos. Azure (3) suele presentar facturaciones iniciales menos predecibles para proyectos académicos.
-------------------------	----	--

9.4. Selección de Alternativa

De acuerdo con el análisis cuantitativo y cualitativo desarrollado en la matriz de priorización, la plataforma tecnológica seleccionada para la infraestructura en la nube es **Amazon Web Services (AWS)**, obteniendo un puntaje promedio sobresaliente de **4.94**.

Esta decisión se fundamenta técnica y metodológicamente en su absoluta superioridad en los criterios de mayor impacto. Para garantizar el **Cumplimiento y Seguridad (34%)** exigido por las leyes de protección de datos, AWS provee un ecosistema maduro que permite el cifrado de

extremo a extremo de la base de datos PostgreSQL, asegurando que la información de salud mental permanezca inviolable.

Asimismo, AWS demuestra una interoperabilidad perfecta con las tecnologías previamente seleccionadas. Su liderazgo en **Orquestación de Microservicios (27%)** asegura la estabilidad del *backend* en Spring Boot, mientras que su entorno *Amazon SageMaker* resuelve el despliegue del motor de **Machine Learning (20%)** en Python, permitiendo inferencias algorítmicas de ansiedad en milisegundos. Esta robustez integral garantiza que la plataforma mantenga una alta disponibilidad, protegiendo tanto la experiencia de usuario del estudiante como el rigor clínico de la evaluación predictiva.

10. CONCLUSIONES

Primera: El proceso de *benchmarking* multidimensional ha permitido consolidar una matriz tecnológica de alta cohesión que responde de manera precisa a la complejidad interdisciplinaria del proyecto. La evaluación holística de todos los componentes arquitectónicos —desde la infraestructura en la nube y el ecosistema de persistencia de datos, hasta la capa de presentación web y la lógica de orquestación de microservicios— garantiza el diseño de un sistema escalable y resiliente. Esta infraestructura unificada está técnicamente dimensionada para soportar los picos de concurrencia propios del ecosistema universitario en Lima Metropolitana, garantizando

tiempos de respuesta mínimos que previenen la fricción cognitiva y evitan exacerbar la ansiedad digital del estudiante durante su interacción con la plataforma.

Segunda: La evaluación técnica e iterativa del núcleo analítico ratifica la viabilidad de implementar una inteligencia artificial orientada a la psicología computacional bajo estrictos parámetros éticos. Al priorizar criterios transversales como la explicabilidad algorítmica, la resiliencia frente a encuestas psicométricas asimétricas y la optimización basada en métricas de balance armónico, el *benchmarking* asegura que el modelo predictivo trascienda la exactitud puramente matemática. El resultado es un motor de inferencia transparente y auditable, diseñado específicamente como un instrumento de apoyo a la decisión clínica, donde los profesionales de la salud mental pueden interpretar claramente las variables desencadenantes del riesgo en cada alumno.

Tercera: De manera integral, el *benchmarking* demuestra que la viabilidad de los ecosistemas de salud digital radica en subordinar la selección tecnológica al propósito clínico y normativo. Las decisiones justificadas a lo largo de los capítulos —que privilegian la "privacidad por diseño", la prevención de vulnerabilidades transaccionales y el cumplimiento de las leyes de protección de datos personales— convergen para materializar un producto de *software* robusto. En consecuencia, la plataforma deja de ser un mero recolector de métricas de uso para consolidarse como una solución de ingeniería de alto nivel, idónea para la detección temprana y mitigación del tecnoestrés en poblaciones académicas vulnerables a la hiperconectividad.

11. REFERENCIAS BIBLIOGRÁFICAS

- Baena-Navarro, R., Carriazo-Regino, Y., Crawford-Vidal, R., Fernandez-Arango, A., & Barreiro-Pinto, F. (2025). Adaptive AI-driven framework for digital mental health interventions in low-resource universities. *Bulletin of Electrical Engineering and Informatics*, 14(6), 4534–4547. <https://doi.org/10.11591/eei.v14i6.10143>
- Curi, I. C., Quispe, E. Y., & Lopez, N. B. (2025). Tampu: Mobile Application Using Wearable Technology for Real-Time Detection and Alert of Anxiety and Panic Attacks in University Students. *Proceedings of the 2025 IEEE 5th International*

Conference on Advanced Learning Technologies on Education and Research, ICALTER 2025. <https://doi.org/10.1109/ICALTER69698.2025.11355147>

McFadyen, J., Habicht, J., Dina, L.-M., Harper, R., Hauser, T. U., & Rollwage, M. (2026). Increasing engagement with cognitive-behavioral therapy (CBT) using generative AI: A randomized controlled trial (RCT). *Communications Medicine*, 6, Artículo 129. <https://doi.org/10.1038/s43856-025-01321-8>

Nina-Gutiérrez, E. A., Pacheco-Alanya, J. E., & Morales-Arevalo, J. C. (2024). SocialBullyAlert: A Web Application for Cyberbullying Detection on Minors' Social Media. *International Journal of Advanced Computer Science and Applications*, 15(7), 769–778. <https://doi.org/10.14569/IJACSA.2024.0150776>

Schmidt, F., Kurzawski, M. G., Hammerfald, K., Jähren, H. H., Solbakken, O. A., & Vlassov, V. (2024). A Scalable System Architecture for Composition and Deployment of Machine Learning Models in Cognitive Behavioral Therapy. *Proceedings - 2024 IEEE International Conference on Digital Health, ICDH 2024*, 79–86. <https://doi.org/10.1109/ICDH62654.2024.00024>

Singh Sethi, M. I., Manickam, T., Chakraborty, T., & Bada Math, S. (2026). Co-Designed Mental Health Screening App (Here for You) for University Students: Pilot Feasibility Mixed Methods Study. *JMIR Formative Research*, 10, Artículo e75616. <https://doi.org/10.2196/75616>